ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH

ĐẠI HỌC KHOA HỌC TỰ NHIÊN

KHOA CÔNG NGHỆ THÔNG TIN

Báo cáo thực hành Đồ án 3

Môn học: Khai thác dữ liệu và ứng dụng

CSC14004 - 23KHMT

Sinh viên thực hiện

Nguyễn Thị Khánh Linh - 23127082

Lê Chí Vỹ - 23127146

Nguyễn Trần Thiên An - 23127315

Giảng viên hướng dẫn:

Lê Hoài Bắc

Lê Nhựt Nam

Nguyễn Ngọc Đức

Ngày 15 tháng 1 năm 2026

Mục lục

Danh sách hình vẽ 4

Danh sách bảng 6

1 Thông tin chung 7
- 1.1 Thông tin bài báo . . . 7
- 1.2 Thông tin nhóm . . . 7
- 1.3 Bảng phân chia công việc . . . 8

2 Giới thiệu và Động lực nghiên cứu 9
- 2.1 Giới thiệu . . . 9
- 2.2 Động lực nghiên cứu . . . 9

3 Tổng quan nghiên cứu và Kiến thức cơ sở 10
- 3.1 Kiến thức cơ sở . . . 10
  - 3.1.1 Hàm Kernel và Không gian Hilbert (RKHS) . . . 10
  - 3.1.2 Xấp xỉ chuỗi Taylor (Taylor Approximation) . . . 11
  - 3.1.3 Thủ thuật Kernel (The Kernel Trick) . . . 11
  - 3.1.4 Thuật toán Kernel K-means . . . 12
  - 3.1.5 Cây quyết định và Thuật toán IMM (Iterative Mistake Minimization) . . . 14
  - 3.1.6 Thuật toán ExKMC (Expanding Explainable k-Means Clustering) . . . 16
- 3.2 Các nghiên cứu liên quan và Khoảng trống nghiên cứu . . . 19
  - 3.2.1 Tổng qua các nghiên cứu liên quan . . . 19
  - 3.2.2 Thuật toán Cây phân loại và hồi quy (CART) . . . 19
  - 3.2.3 Tại sao IMM gốc không áp dụng được cho Kernel Clustering? . . . 20

4 Phương pháp đề xuất 20
- 4.1 Định nghĩa và Hạn chế về Tính diễn giải . . . 20
- 4.2 Giải pháp của Kernel IMM . . . 21
  - 4.2.1 Kernel Tích Bị Chặn (Bounded Product Kernel) . . . 22
  - 4.2.2 Đặc trưng thay thế (Surrogate features) . . . 22
  - 4.2.3 Kernel Taylor có thể diễn giải (Interpretable Taylor kernels) . . . 23
- 4.3 Phân tích Lý thuyết . . . 26
  - 4.3.1 Cái giá phải trả cho sự giải thích (Price of Explainability - PoE) . . . 26
  - 4.3.2 Đảm bảo trường hợp xấu nhất (Worst-case Guarantees) . . . 26
  - 4.3.3 PoE cho Kernel Taylor có thể diễn giải . . . 29
- 4.4 Kernel Tích dựa trên khoảng cách (Distance-based Product Kernel) . . . 30

4.5 Tối ưu hóa chi phí bằng chiến lược tham lam . . . 31
4.5.1 Vấn đề của Kernel IMM và giải pháp . . . 31
4.5.2 Hàm mục tiêu của Kernel ExKMC và Kernel Expand . . . 32
4.5.3 Hiệu quả tính toán . . . 33
4.5.4 Những vấn đề mà chiến lược tham lam gặp phải . . . 33
4.6 Thuật toán . . . 34
4.6.1 Kernel IMM . . . 34
4.6.2 Kernel ExKMC . . . 35
4.6.3 Kernel Expand . . . 36

5 Phân tích thực nghiệm **37**
5.1 Tập dữ liệu . . . 37
5.2 Quy trình thực nghiệm . . . 40
5.3 Thước đo đánh giá . . . 41
5.3.1 Chỉ số Price of Explainabilty (PoE) . . . 41
5.3.2 Chỉ số Adjusted Rand Index . . . 41
5.4 Kết quả . . . 42

6 Minh họa cài đặt **44**
6.1 Môi trường thực nghiệm . . . 44
6.2 Mã giả cài đặt . . . 45
6.2.1 Cài đặt Xấp xỉ Taylor . . . 45
6.2.2 Quy trình Thực nghiệm Tổng thể . . . 47
6.2.3 Quy trình Tinh chỉnh và Đánh giá . . . 48
6.3 Phân tích kết quả . . . 49
6.3.1 Phân tích các tập dữ liệu tổng hợp (synthetic clustering datasets) . . . 49
6.3.2 Phân tích các tập dữ liệu thực tế . . . 55
6.3.3 Tổng hợp . . . 56
6.3.4 Phân tích tác động của tham số M . . . 59

7 Thảo luận phản biện **62**
7.1 Ưu điểm và Đóng góp chính . . . 62
7.2 Hạn chế và Thách thức . . . 62

8 Chứng minh các định lý **63**
8.1 Chứng minh Định lý 1 . . . 63
8.2 Chứng minh Định lý 2 . . . 64
8.3 Chứng minh Định lý 3 . . . 66

8.4 Chứng minh Định lý 4 66
8.5 Chứng minh Định lý 5 68
8.6 Chứng minh Định lý 6 69
8.7 Chứng minh Định lý 7 71

9 Kết luận **73**

10 Lời cảm ơn **74**

A Phụ lục: Chứng minh công thức đạo hàm bậc cao **75**

B Phụ lục: Hàm giải tích và Bất đẳng thức AM-GM **76**

C Phụ lục: Danh sách các bảng ký hiệu **77**

Danh sách hình vẽ

1 Minh họa Thủ thuật Kernel - Dữ liệu không phân tách tuyến tính trong không gian 2D được ánh xạ lên không gian 3D để dễ dàng phân tách bằng một mặt phẳng, mà không cần tính toán tọa độ 3D tường minh. . . . 12

2 Minh họa hoạt động của IMM trên dữ liệu 5 cụm. Các dấu chéo đỏ biểu thị các "sai lầm" (mistakes) - nơi điểm dữ liệu bị nhát cắt tách khỏi tâm cụm của nó (Nguồn: Dasgupta et al., 2020 [1]). . . . 15

3 Minh họa tác động của việc mở rộng số lượng lá trong thuật toán ExKMC. Khi tham số k' tăng lên (từ trái sang phải), cây quyết định tạo ra các ranh giới phân chia chi tiết hơn, giúp xấp xỉ cấu trúc hình học của các cụm dữ liệu chính xác hơn so với ràng buộc $k' = k$ của IMM (Nguồn: Frost et al., 2020 [2]). . . . 17

4 Thuật toán k-means tiêu chuẩn không phù hợp để phân cụm trên một số tập dữ liệu nhất định, ví dụ như *Pathbased*, trong khi đó Kernel k-means lại khôi phục tốt dữ liệu thực tế. Tuy nhiên, Kernel IMM không đủ mạnh để xấp xỉ các cụm ở dữ liệu thực do bị giới hạn ở 3 lá. Kernel ExKMC và Kernel Expand có thể khắc phục vấn đề này khi mở rộng cây lên 6 lá 32

5 Minh họa trực quan tập dữ liệu *Pathbased* . . . 38

6 Minh họa trực quan tập dữ liệu *Aggregation* . . . 38

7 Minh họa trực quan tập dữ liệu *Flame* . . . 39

8 Mô hình hỗn hợp của 4 phân phối rời rạc được phân cụm bằng cách kiểm tra tỉ lệ xuất hiện trong từng nhóm (bin). Các xác suất thực tế được thể hiện ở biểu đồ bên trái. Sau 100 lần lấy mẫu, thuật toán sử dụng χ^2 kernel, ở đây là kernel k-means, có kết quả tốt hơn với k-means thông thường, được thể hiện ở biểu đồ hộp bên phải. . . . 40

9 Kiểm chứng khả năng xấp xỉ của các thuật toán đề xuất theo thang đo Price of Explainability (biểu đồ bên trái). So sánh các cụm thu được từ các thuật toán k-means, IMM, kernel k-means và 3 thuật toán đề xuất với dữ liệu thực tế thông qua Rand Index (biểu đồ bên phải). . . . 42

10 Kết quả phân cụm trên tập Pathbased. K-means (trên-trái) thất bại trong việc tách cụm bao ngoài, trong khi Kernel ExKMC (dưới-phải) tái tạo tốt cấu trúc hình học này bằng các đường cắt song song trục. . . . 51

11 Kết quả phân cụm trên tập Aggregation. Kernel ExKMC (dưới-phải) bám sát ranh giới phân lớp tối ưu của Kernel K-means. . . . 53

12 Kết quả phân cụm trên tập Flame. Lưu ý sự thất bại của Taylor IMM (giữa-dưới) và sự phục hồi hiệu năng ấn tượng của Kernel ExKMC (dưới-phải). . . . 54

13 Biểu đồ ARI đầy đủ: So sánh hiệu năng của cả 6 thuật toán. . . . 57

14 Biểu đồ PoE: Kernel Expand và ExKMC giảm đáng kể sai số so với Kernel IMM. . . . 58

15 So sánh chi tiết Rand Score và PoE theo từng tập dữ liệu với các giá trị M khác nhau . . . 60

16 Biểu đồ xu hướng của Rand Score và PoE khi thay đổi M 60

Danh sách bảng

1 Thông tin thành viên nhóm . . . 7
2 Bảng phân chia công việc . . . 8
3 So sánh Price of Explainability giữa Kernel IMM và CART với các nhát cắt 1 phía cùng k lá. Cả 2 phương pháp đều giữ được độ chính xác cao và tương đương, trong đó CART đạt được giá trị tối ưu và ngang bằng với Kernel IMM ở các tập dữ liệu dùng Laplace Kernel. . 43
4 So sánh độ chính xác phân cụm (Adjusted Rand Index - ARI) giữa các phương pháp . . . 56
5 So sánh chi phí giải thích (Price of Explainability - PoE) (Giá trị càng gần 1 càng tốt) . . . 56
6 Tác động của tham số M đến hiệu suất của Kernel IMM trên các tập dữ liệu . . . 59
7 Các ký hiệu sử dụng chung . . . 77
8 Các ký hiệu sử dụng trong Định nghĩa 1 . . . 77
9 Các ký hiệu sử dụng trong Định nghĩa 2 . . . 77
10 Các ký hiệu sử dụng trong phần Surrogate Features . . . 78
11 Các ký hiệu sử dụng trong phần Interpretable Taylor Kernels . . . 78
12 Các ký hiệu sử dụng trong phân tích lý thuyết và Distance-based Kernels . . . 78
13 Các ký hiệu sử dụng trong phần Hàm mục tiêu của Kernel ExKMC và Kernel Expand . . . 79
14 Các ký hiệu sử dụng trong Định lý 1 . . . 79
15 Các ký hiệu sử dụng trong Định lý 2 . . . 79
16 Các ký hiệu sử dụng trong Định lý 3 (Tính diễn giải của các vết cắt) . . . 79
17 Các ký hiệu sử dụng trong Định lý 4 (Sai số xấp xỉ) . . . 80
18 Các ký hiệu sử dụng trong Định lý 5 (Distance-based Product Kernels) . . . 80
19 Các ký hiệu sử dụng trong Định lý 6 (ExKMC trong trường hợp xấu nhất) . . . 80

1 Thông tin chung

1.1 Thông tin bài báo

1. Tựa đề: Explaining Kernel Clustering via Decision Trees.
2. Các tác giả: Maximilian Fleissner, Leena Chennuru Vankadara, Debarghya Ghoshdastidar.
3. Thuộc Tạp chí: **ICLR 2024**
4. Nội dung sơ bộ: Dù các phương pháp học máy có khả năng diễn giải ngày càng phổ biến, nghiên cứu về phân cụm diễn giải cố hữu vẫn còn hạn chế. Gần đây, một số công trình đã giải thích k-means bằng cách xấp xỉ các cụm bằng cây quyết định căn chỉnh theo trục (axis-aligned decision trees), nhưng các phương pháp này kém linh hoạt trong thực tế. Nghiên cứu này đề xuất phân cụm kernel diễn giải được (interpretable kernel clustering), xây dựng cây quyết định để xấp xỉ kernel k-means, và chỉ ra cách lựa chọn đặc trưng giúp giữ được tính diễn giải mà vẫn đảm bảo chất lượng xấp xỉ.

1.2 Thông tin nhóm

MSSV	Họ và Tên	Email
23127082	Nguyễn Thị Khánh Linh	ntklinh23@clc.fitus.edu.vn
23127146	Lê Chí Vỹ	lcvy23@clc.fitus.edu.vn
23127315	Nguyễn Trần Thiên An	nttan23@clc.fitus.edu.vn

Bảng 1: Thông tin thành viên nhóm

1.3 Bảng phân chia công việc

MSSV	Họ và tên	Công việc	Hoàn thành
23127082	Nguyễn Thị Khánh Linh	– Đọc và tìm hiểu bài báo. – Viết phần Giới thiệu và Động lực nghiên cứu. – Viết phần Tổng quan nghiên cứu và Kiến thức cơ sở. – Viết phần chứng minh định lý 1, 2. – Viết phân tích kết quả sau khi thử nghiệm cài đặt.	100%
23127146	Lê Chí Vỹ	– Đọc và tìm hiểu bài báo. – Viết phần Phương pháp đề xuất về Tối ưu hoá chi phí bằng chiến lược tham lam, Thuật toán Kernel ExKMC và Kernel Expand. – Viết phần Phân tích thực nghiệm. – Viết phần chứng minh định lý 3, 6. – Viết mô tả môi trường thực nghiệm để tiến hành thử nghiệm cài đặt. – Viết phần Kết luận.	100%
23127315	Nguyễn Trần Thiên An	– Đọc và tìm hiểu bài báo. – Viết phần Phương pháp đề xuất về Tính diễn giải, Kernel IMM, Phân tích lý thuyết, Kernel tích dựa trên khoảng cách. – Viết phần chứng minh định lý 4, 5, 7. – Viết mã giả cho các hàm và đánh giá, việc thay đổi giá trị M sau khi thử nghiệm cài đặt. – Viết phần Thảo luận phản biện.	100%

Bảng 2: Bảng phân chia công việc

2 Giới thiệu và Động lực nghiên cứu

2.1 Giới thiệu

Trong bối cảnh học máy (machine learning) đang trở nên ngày càng phổ biến trong các lĩnh vực khoa học và đời sống, nhu cầu về khả năng giải thích (explainability) và tính minh bạch (interpretability) của mô hình trở nên cấp thiết, đặc biệt là trong các ứng dụng nhạy cảm như y tế hay xe tự lái. Tuy nhiên, phần lớn các mô hình hiện đại vẫn hoạt động như những "hộp đen", thiếu đi sự minh bạch cần thiết.
Mặc dù đã có nhiều công cụ được phát triển để giải thích các mô hình học có giám sát, lĩnh vực phân cụm (clustering) lại nhận được ít sự chú ý hơn. Gần đây, việc sử dụng cây quyết định (decision trees) để xấp xỉ và giải thích thuật toán k-means cổ điển đã thu hút được sự quan tâm lớn, cho phép tạo ra các phân hoạch dữ liệu dễ hiểu thông qua các luật cắt trục (axis-aligned cuts).
Tuy nhiên, các biến thể giải thích được của k-means lại gặp hạn chế lớn trong thực tế: hàm chi phí k-means thường thất bại trong việc nhận diện các cụm dữ liệu không phân tách tuyến tính (linearly separable). Để giải quyết vấn đề này, thuật toán **Kernel k-means** mở rộng khả năng phân cụm bằng cách ánh xạ dữ liệu vào không gian đặc trưng cao chiều (reproducing kernel Hilbert - RKHS), nhưng sự linh hoạt này lại đánh đổi bằng việc làm mất đi tính giải thích được của mô hình. Bài báo này giải quyết thách thức trên bằng cách đề xuất phương pháp phân cụm kernel có khả năng giải thích (interpretable kernel clustering), sử dụng cây quyết định để xấp xỉ các phân hoạch phi tuyến của Kernel k-means mà vẫn đảm bảo cả độ chính xác lẫn tính minh bạch.

2.2 Động lực nghiên cứu

Nghiên cứu này xuất phát từ nhu cầu thực tế cấp thiết về việc xây dựng các hệ thống AI vừa thông minh, vừa minh bạch, nhằm giải quyết ba mâu thuẫn lớn trong các phương pháp phân cụm hiện tại:

- **Sự đánh đổi giữa Độ chính xác và Tính giải thích:** Hiện nay, người dùng buộc phải lựa chọn một trong hai tính chất này. Nếu chọn các mô hình dễ hiểu như cây quyết định hay k-means truyền thống, họ phải chấp nhận hiệu suất kém trên các dữ liệu phức tạp (phi tuyến tính). Ngược lại, nếu chọn các mô hình mạnh mẽ như Kernel k-means để đạt độ chính xác cao, họ lại đối mặt với một "hộp đen" hoàn toàn không thể lý giải. Chưa có một giải pháp nào dung hòa được cả hai yếu tố này.

- **Sự "lệch pha" giữa tư duy con người và không gian đặc trưng:** Các phương pháp Kernel hoạt động bằng cách đưa dữ liệu vào một không gian trừu tượng cao chiều. Tuy nhiên, tư duy giải thích của con người (ví dụ: các luật "nếu... thì...") lại gắn liền với các đặc trưng của dữ liệu đầu vào. Sự khác biệt về không gian biểu diễn này tạo ra một rào cản lớn, khiến việc áp dụng trực tiếp các công cụ giải thích truyền thống vào mô hình Kernel trở nên bất khả thi.

- **Nhu cầu về một cơ chế xấp xỉ đáng tin cậy:** Các phương pháp giải thích hiện có thường chỉ mang tính chất hậu kiểm (post-hoc) hoặc phỏng đoán cục bộ, thiếu đi các đảm bảo toán học vững chắc về chất lượng. Cộng đồng nghiên cứu đang tìm kiếm một phương pháp có khả năng "dịch" các mô hình phức tạp sang dạng đơn giản mà vẫn giữ được cam kết về độ sai lệch tối thiểu (worst-case guarantees) so với mô hình gốc.

Từ những động lực trên, bài báo tập trung phát triển một phương pháp cầu nối, sử dụng kỹ thuật xấp xỉ đặc trưng để đưa sức mạnh của Kernel về dạng thức mà cây quyết định có thể xử lý được.

3 Tổng quan nghiên cứu và Kiến thức cơ sở

Chương này trình bày các cơ sở lý thuyết nền tảng về phương pháp Kernel, xấp xỉ Taylor, thuật toán phân cụm Kernel k-means và thuật toán cây quyết định giải thích được (IMM). Đồng thời, chúng em phân tích các nghiên cứu liên quan để làm rõ những hạn chế của các phương pháp hiện tại, từ đó dẫn dắt đến động lực phát triển phương pháp đề xuất.

3.1 Kiến thức cơ sở

3.1.1 Hàm Kernel và Không gian Hilbert (RKHS)

Để khắc phục hạn chế của các thuật toán tuyến tính, phương pháp Kernel đưa dữ liệu vào một không gian đặc trưng (Feature Space) có số chiều cao hơn, nơi các cấu trúc phi tuyến trở nên dễ phân tách. Hai khái niệm toán học cốt lõi hiện thực hóa ý tưởng này là Hàm Kernel và Không gian Hilbert.

Định nghĩa Kernel và RKHS: Một hàm Kernel $K : \mathcal{X} \times \mathcal{X} \to \mathbb{R}$ là một hàm đối xứng và xác định dương. Theo định lý Moore-Aronszajn, mỗi hàm Kernel K liên kết duy nhất với một không gian Hilbert hạt nhân sinh (Reproducing Kernel Hilbert Space - RKHS), ký hiệu là $\mathcal{H}$. Tồn tại một ánh xạ đặc trưng $\psi : \mathcal{X} \to \mathcal{H}$ sao cho giá trị của Kernel trong không gian gốc chính bằng tích vô hướng trong không gian RKHS:

$$K(x, y) = \langle \psi(x), \psi(y) \rangle_{\mathcal{H}}$$

Các loại Kernel phổ biến: Nghiên cứu này xem xét các hàm Kernel thông dụng sau, mỗi loại phù hợp với đặc thù dữ liệu khác nhau:

- **Gaussian Kernel (RBF):** Đây là Kernel phổ biến nhất, thường được sử dụng khi không có giả định trước về dữ liệu. Với băng thông $\gamma > 0$, công thức là:

$$K(x, y) = \exp(-\gamma \|x - y\|_2^2)$$

Đặc điểm quan trọng của Gaussian Kernel là nó tương ứng với một không gian đặc trưng $\mathcal{H}$ có số chiều vô hạn.

- **Laplace Kernel:** Tương tự Gaussian nhưng sử dụng chuẩn L_1, giúp giảm nhạy cảm với các điểm nhiễu (outliers):
$$K(x, y) = \exp(-\gamma \|x - y\|_1)$$

- **Additive Kernel (ví dụ χ^2):** Thường hiệu quả cho dữ liệu dạng histogram (như trong thị giác máy tính). Kernel χ^2 được định nghĩa là:
$$K(x, y) = \sum_{i=1}^{d} \frac{2x_i y_i}{x_i + y_i}$$

3.1.2 Xấp xỉ chuỗi Taylor (Taylor Approximation)

Để xây dựng các đặc trưng thay thế (Surrogate Features), tác giả sử dụng công cụ toán học nền tảng là chuỗi Taylor.
Định nghĩa: Chuỗi Taylor cho phép biểu diễn một hàm khả vi vô hạn lần $f(x)$ dưới dạng tổng vô hạn của các hạng tử lũy thừa. Khai triển Taylor của hàm $f(z)$ quanh điểm a được định nghĩa là:

$$f(z) = \sum_{j=0}^{\infty} \frac{f^{(j)}(a)}{j!}(z - a)^j$$

Trong đó $f^{(j)}(a)$ là đạo hàm bậc j của hàm số tại điểm a.

3.1.3 Thủ thuật Kernel (The Kernel Trick)

Một trong những thách thức lớn nhất khi làm việc với không gian đặc trưng $\mathcal{H}$ là chi phí tính toán. Nếu đi theo cách tiếp cận trực tiếp, ta phải thực hiện hai bước:

1. Biến đổi điểm dữ liệu x thành vector đặc trưng $\psi(x)$ trong không gian cao chiều.

2. Tính tích vô hướng giữa hai vector $\psi(x)$ và $\psi(y)$.

Việc này thường rất tốn kém tài nguyên hoặc thậm chí bất khả thi nếu không gian $\mathcal{H}$ có số chiều vô hạn (ví dụ như đối với Gaussian Kernel).
Thủ thuật Kernel giải quyết triệt để vấn đề này bằng cách thay thế quy trình trên. Thay vì phải xác định tọa độ của $\psi(x)$ một cách tường minh, ta tính toán trực tiếp tích vô hướng thông qua hàm Kernel ngay trong không gian dữ liệu ban đầu:

$$K(x, y) = \langle \psi(x), \psi(y) \rangle_{\mathcal{H}}$$

Lợi điểm cốt lõi: Phương pháp này cho phép thuật toán vận hành ngầm định trong không gian cao chiều $\mathcal{H}$ để tận dụng khả năng phân tách dữ liệu phi tuyến, trong khi chi phí tính toán thực tế chỉ đơn giản là việc đánh giá hàm $K(x, y)$ trong không gian thấp chiều.
Ví dụ, khoảng cách Euclid giữa hai điểm trong không gian đặc trưng có thể được tính hoàn toàn thông qua K mà không cần biết ψ:

$$\|\psi(x) - \psi(y)\|_{\mathcal{H}}^2 = K(x, x) + K(y, y) - 2K(x, y)$$

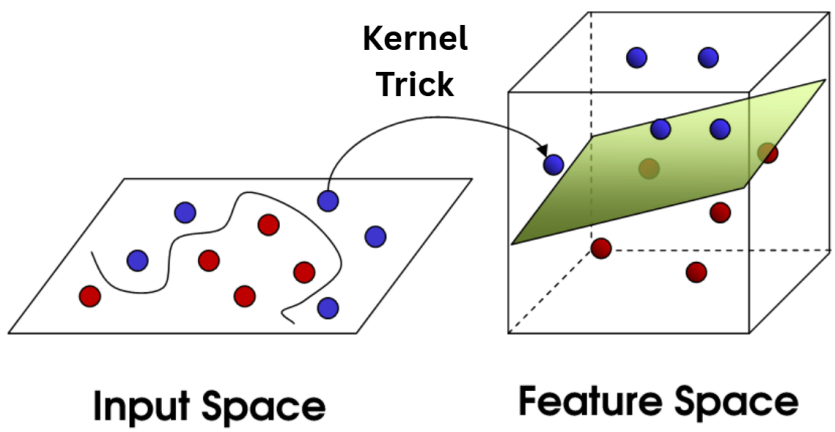

Hình 1: Minh họa Thủ thuật Kernel - Dữ liệu không phân tách tuyến tính trong không gian 2D được ánh xạ lên không gian 3D để dễ dàng phân tách bằng một mặt phẳng, mà không cần tính toán tọa độ 3D tường minh.

3.1.4 Thuật toán Kernel K-means

Nội dung phần này được xây dựng dựa trên các cơ sở lý thuyết và chứng minh trong Phụ lục B của bài báo gốc.
Thuật toán Kernel k-means là phiên bản mở rộng của thuật toán k-means cổ điển, được thiết kế để hoạt động trên các dữ liệu không phân tách tuyến tính. Mục tiêu của thuật toán là tìm một phân hoạch $C = \{C_1, \ldots, C_k\}$ của tập dữ liệu X sao cho tổng bình phương khoảng cách từ các điểm dữ liệu đến tâm cụm của chúng trong không gian đặc trưng $\mathcal{H}$ là nhỏ nhất:

$$cost(C_1, \ldots, C_k) = \sum_{l=1}^{k} \sum_{x \in C_l} \|\psi(x) - c_l\|_{\mathcal{H}}^2$$

trong đó c_l là tâm của cụm l trong không gian $\mathcal{H}$, được định nghĩa là trung bình của các vector đặc trưng trong cụm đó: $c_l = \frac{1}{|C_l|} \sum_{x \in C_l} \psi(x)$.
Vấn đề chính khi triển khai thuật toán này là chúng ta không thể tính toán trực tiếp các tâm cụm c_l vì

chúng nằm trong không gian cao chiều (thậm chí vô hạn chiều). Tuy nhiên, dựa vào Bổ đề 1 (Lemma 1), ta có thể thực hiện việc gán nhãn cụm hoàn toàn thông qua hàm Kernel mà không cần biết tọa độ thực của c_l.

Cơ chế tính toán khoảng cách: Khoảng cách Euclid bình phương từ một điểm đặc trưng $\psi(x)$ bất kỳ đến tâm cụm c_l có thể được khai triển như sau:

$$\|\psi(x) - c_l\|^2 = \|\psi(x)\|^2 + \|c_l\|^2 - 2\langle \psi(x), c_l \rangle$$

Sử dụng định nghĩa của hàm Kernel $K(x, y) = \langle \psi(x), \psi(y) \rangle$ và thay thế c_l bằng công thức trung bình cụm, các thành phần trên được viết lại như sau:

- $\|\psi(x)\|^2 = K(x, x)$
- $\|c_l\|^2 = \langle \frac{1}{|C_l|} \sum_{y \in C_l} \psi(y), \frac{1}{|C_l|} \sum_{z \in C_l} \psi(z) \rangle = \frac{1}{|C_l|^2} \sum_{y,z \in C_l} K(y, z)$
- $\langle \psi(x), c_l \rangle = \frac{1}{|C_l|} \sum_{y \in C_l} K(x, y)$

Để xác định cụm tối ưu cho điểm x, ta cần tìm chỉ số l làm cực tiểu hóa khoảng cách $\|\psi(x) - c_l\|^2$. Nhận thấy rằng $K(x, x)$ không phụ thuộc vào cụm l (là hằng số trong phép so sánh), ta có thể lược bỏ nó. Do đó, công thức gán cụm tối ưu trở thành:

$$l^*(x) = \arg\min_{l \in [k]} \left(\frac{1}{|C_l|^2} \sum_{y,z \in C_l} K(y, z) - \frac{2}{|C_l|} \sum_{y \in C_l} K(x, y) \right) \tag{1}$$

Công thức trên cho phép thuật toán Kernel k-means vận hành chỉ bằng cách truy xuất ma trận Kernel. Quy trình cụ thể được mô tả trong Thuật toán 1 dưới đây.

Độ phức tạp thuật toán: Nhược điểm chính của Kernel k-means là chi phí tính toán cao. Việc xây dựng ma trận Kernel K tiêu tốn $O(n^2 d)$ và mỗi vòng lặp cập nhật cụm tiêu tốn $O(n^2)$, với n là số lượng điểm dữ liệu và d là số chiều. Do đó, thuật toán khó mở rộng với các bộ dữ liệu quá lớn.

Algorithm 1 Kernel k-means (tham khảo Phụ lục B của bài báo gốc)

Input: Ma trận Kernel K cho dữ liệu $X \subset \mathbb{R}^d$, số cụm $k \in \mathbb{N}$
Output: Phân hoạch các cụm $C = (C_1, \ldots, C_k)$
Khởi tạo ngẫu nhiên k cụm ban đầu $C_1, \ldots, C_k$
$Converged \leftarrow$ **FALSE**
while $Converged =$ **FALSE do**
  $C' \leftarrow (\emptyset, \ldots, \emptyset)$ ▷ Khởi tạo cụm tạm thời cho vòng lặp mới
  for $x \in X$ **do**
    Tìm cụm l tốt nhất cho x theo công thức (1):

$$l \leftarrow \arg\min_{j \in [k]} \left(\frac{1}{|C_j|^2} \sum_{y,z \in C_j} K(y,z) - \frac{2}{|C_j|} \sum_{y \in C_j} K(x,y) \right)$$

    Gán x vào cụm C'_l
  end for
  if $C'_l = C_l$ với mọi $l \in [k]$ **then**
    $Converged \leftarrow$ **TRUE**
  end if
  Cập nhật $C \leftarrow C'$
end while

3.1.5 Cây quyết định và Thuật toán IMM (Iterative Mistake Minimization)

Nội dung phần này được xây dựng dựa trên thuật toán và các phân tích lý thuyết bài báo **"Explainable k-Means and k-Medians Clustering"** (năm 2020) [1].
Để giải thích kết quả phân cụm, cây quyết định (Decision Tree) là công cụ được ưa chuộng nhờ tính trực quan. Yếu tố cốt lõi tạo nên tính dễ hiểu của cây quyết định là các lát cắt song song với trục (axis-aligned cuts) có dạng $x_i \leq \theta$.
Khác với các thuật toán cây quyết định trong học có giám sát (như CART dùng Entropy hay Gini), thuật toán **IMM (Iterative Mistake Minimization)** được thiết kế chuyên biệt để xấp xỉ kết quả của k-means. Mục tiêu của IMM là xây dựng một cây quyết định sao cho các điểm dữ liệu rơi vào cùng một lá với tâm cụm k-means tương ứng của nó.

Cơ chế hoạt động: Thuật toán hoạt động theo cơ chế đệ quy từ trên xuống (top-down). Tại mỗi bước phân chia, IMM không quan tâm đến độ tinh khiết của nhãn (purity) mà tập trung tối thiểu hóa số lượng **"sai lầm" (mistakes)**.

- **Định nghĩa Mistake:** Một điểm dữ liệu x được coi là một "sai lầm" tại một nút nếu nhát cắt tại nút đó tách x và tâm cụm của nó ($c(x)$) sang hai nhánh khác nhau.

Hình 2 minh họa quy trình này: tại mỗi bước (b, c, d), thuật toán chọn đường cắt sao cho số lượng các điểm màu đỏ (bị tách khỏi tâm cụm) là ít nhất.

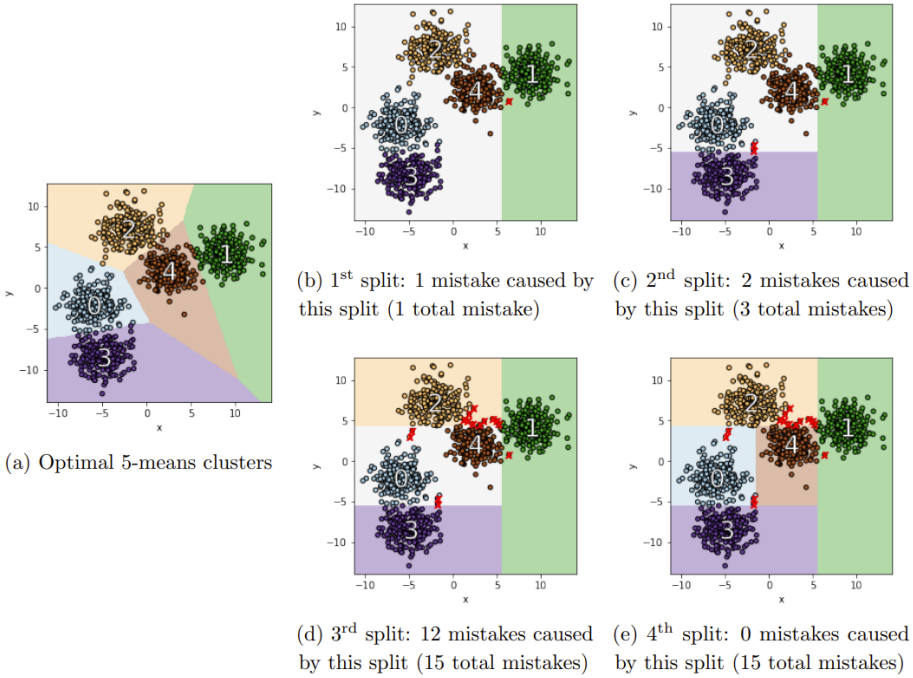
(a) Optimal 5-means clusters

(b) 1st split: 1 mistake caused by this split (1 total mistake)

(c) 2nd split: 2 mistakes caused by this split (3 total mistakes)

(d) 3rd split: 12 mistakes caused by this split (15 total mistakes)

(e) 4th split: 0 mistakes caused by this split (15 total mistakes)

Hình 2: Minh họa hoạt động của IMM trên dữ liệu 5 cụm. Các dấu chéo đỏ biểu thị các "sai lầm" (mistakes) - nơi điểm dữ liệu bị nhát cắt tách khỏi tâm cụm của nó (Nguồn: Dasgupta et al., 2020 [1]).

Quy trình chi tiết được mô tả trong Thuật toán 2, trong đó hàm $MISTAKE(x, \mu, i, \theta)$ trả về 1 nếu nhát cắt θ trên trục i tách x khỏi tâm μ, và trả về 0 nếu ngược lại.

Độ phức tạp tính toán: Theo phân tích của Dasgupta et al. (2020), thuật toán IMM có thể được thực thi hiệu quả với độ phức tạp là $O(k \cdot d \cdot n \log n)$. Chi phí này thấp hơn đáng kể so với việc duyệt toàn bộ không gian, nhờ vào kỹ thuật quy hoạch động để tính toán số lượng mistake tại mỗi nút.

Algorithm 2 Iterative Mistake Minimization (Tham khảo Algorithm 1 của [1])

Input: Các vector $x^1, \ldots, x^n \in \mathbb{R}^d$, số cụm k
Output: Gốc của cây quyết định (threshold tree)
$\mu^1, \ldots, \mu^k \leftarrow$ k-Means$(x^1, \ldots, x^n, k)$
for $j \in \{1, \ldots, n\}$ **do**
  $y^j \leftarrow \arg\min_{l \in \{1,\ldots,k\}} \|x^j - \mu^l\|$ ▷ Gán nhãn theo tâm gần nhất
end for
return BuildTree$(\{x^j\}_{j=1}^n, \{y^j\}_{j=1}^n, \{\mu^j\}_{j=1}^k)$

function BuildTree$(\{x^j\}_{j=1}^m, \{y^j\}_{j=1}^m, \{\mu^j\}_{j=1}^k)$
  if tập nhãn $\{y^j\}_{j=1}^m$ là đồng nhất **then**
    leaf.cluster $\leftarrow y^1$
    return leaf
  end if
  $(i, \theta) \leftarrow \arg\min_{i,\theta} \sum_{j=1}^m \text{mistake}(x^j, \mu^{y^j}, i, \theta)$
  $M \leftarrow \{j \mid \text{mistake}(x^j, \mu^{y^j}, i, \theta) = 1\}_{j=1}^m$ ▷ Tập các điểm bị lỗi
  $L \leftarrow \{j \mid (x_i^j \leq \theta) \wedge (j \notin M)\}_{j=1}^m$ ▷ Nhánh trái (không lỗi)
  $R \leftarrow \{j \mid (x_i^j > \theta) \wedge (j \notin M)\}_{j=1}^m$ ▷ Nhánh phải (không lỗi)
  node.condition $\leftarrow$ "$x_i \leq \theta$"
  node.lt $\leftarrow$ BuildTree$(\{x^j\}_{j \in L}, \{y^j\}_{j \in L}, \{\mu^j\}_{j=1}^k)$
  node.rt $\leftarrow$ BuildTree$(\{x^j\}_{j \in R}, \{y^j\}_{j \in R}, \{\mu^j\}_{j=1}^k)$
  return node
end function

function mistake(x, μ, i, θ)
  return $(x_i \leq \theta) \neq (\mu_i \leq \theta)?1 : 0$
end function

3.1.6 Thuật toán ExKMC (Expanding Explainable k-Means Clustering)

Nội dung phần này được xây dựng dựa trên đề xuất và các phân tích thực nghiệm từ bài báo **"ExKMC: Expanding Explainable k-Means Clustering"** (năm 2020) [2].

Cần lưu ý rằng, thuật toán ExKMC được trình bày trong mục này là phiên bản gốc dành cho bài toán k-means tiêu chuẩn (trong không gian Euclidean). Đây là cơ sở lý thuyết nền tảng để phát triển thuật toán "Kernel ExKMC" – phiên bản mở rộng cho không gian phi tuyến – sẽ được đề cập chi tiết tại Chương 4.

Một hạn chế cơ bản của IMM là việc giới hạn số lượng lá của cây quyết định đúng bằng số cụm k. Điều này tuy đảm bảo tính đơn giản tối đa nhưng thường dẫn đến độ chính xác thấp do biên giới phân cụm thực tế phức tạp hơn nhiều so với k hình hộp chữ nhật.

Để khắc phục điều này, thuật toán **ExKMC** được đề xuất nhằm nới lỏng ràng buộc về kích thước cây. Mục tiêu của ExKMC là xây dựng một cây quyết định có k' lá (với $k' \geq k$), cho phép nhiều lá cùng trỏ về một cụm.

Hình 3 minh họa trực quan sự cải thiện này: các ranh giới phân chia trở nên chi tiết hơn khi số lượng lá tăng lên.

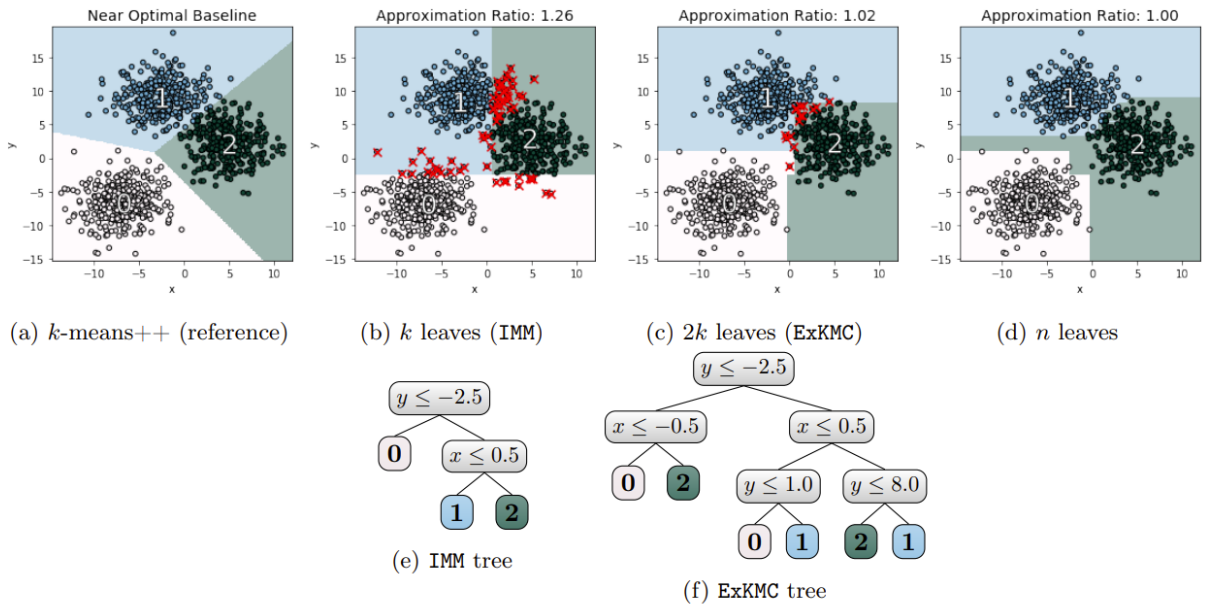

(a) k-means++ (reference) (b) k leaves (IMM) (c) $2k$ leaves (ExKMC) (d) n leaves

(e) IMM tree (f) ExKMC tree

Hình 3: Minh họa tác động của việc mở rộng số lượng lá trong thuật toán ExKMC. Khi tham số k' tăng lên (từ trái sang phải), cây quyết định tạo ra các ranh giới phân chia chi tiết hơn, giúp xấp xỉ cấu trúc hình học của các cụm dữ liệu chính xác hơn so với ràng buộc $k' = k$ của IMM (Nguồn: Frost et al., 2020 [2]).

Cơ chế hoạt động: Khác với chiến lược "chia để trị" đệ quy của IMM, ExKMC hoạt động theo cơ chế **mở rộng tham lam (greedy expansion)** dựa trên một hàm chi phí thay thế (surrogate cost).

- **Mở rộng cây:** Bắt đầu từ một nút gốc, tại mỗi bước, thuật toán tìm kiếm lá nào tốt nhất để phân chia nhằm giảm thiểu hàm chi phí thay thế nhiều nhất. Quá trình lặp lại cho đến khi cây đạt đủ k' lá.
- **Gán nhãn lại:** Sau khi cấu trúc cây hoàn tất, mỗi lá sẽ được gán nhãn lại theo tâm cụm k-means gần nhất với trọng tâm của dữ liệu trong lá đó.

Quy trình chi tiết được mô tả trong Thuật toán 3. Thuật toán áp dụng chiến lược tham lam để mở rộng cây quyết định cho đến khi đạt đủ số lượng lá k' yêu cầu. Tại mỗi bước lặp, thuật toán sử dụng hàm AddGain để đánh giá mức giảm chi phí (gain) tiềm năng của việc phân chia từng lá, từ đó chọn ra lá có mức giảm lớn nhất để thực hiện cắt. Sau khi xác định được điểm cắt tối ưu (i, θ), hàm FindLabels được sử dụng để gán lại các tâm tham chiếu gần nhất từ tập $\mathcal{M}$ cho hai node con mới được tạo thành.

Độ phức tạp thuật toán: Về mặt hiệu năng, ExKMC có độ phức tạp tính toán là $O(k' \cdot d \cdot n \log n)$, trong đó k' là số lá mục tiêu. Mặc dù chi phí này tăng tuyến tính theo số lượng lá, nhưng nhờ hàm chi phí thay thế được thiết kế hiệu quả, thuật toán vẫn duy trì tốc độ thực thi nhanh và khả năng mở rộng tốt trên các tập dữ liệu lớn.

Algorithm 3 ExKMC (Tham khảo Algorithm 1 của [2])

Input: Tập các vector $\mathcal{X} \subset \mathbb{R}^d$, tập k tâm tham chiếu $\mathcal{M}$, cây cơ sở T, số lá mục tiêu k'
Output: Cây quyết định đã gán nhãn với k' lá
splits ← dict()
gains ← dict()
for each leaf $\in T$.leaves **do**
  AddGain(leaf, $\mathcal{X}, \mathcal{M}$, splits, gains)
end for
while $|T.\text{leaves}| < k'$ **do**
  leaf ← $\arg\max_{\text{leaf}}$ gains[leaf] ▷ Chọn lá có mức giảm chi phí (gain) lớn nhất
  i, θ ← splits[leaf]
  μ^L, μ^R ← FindLabels($\mathcal{X}, \mathcal{M}, i, \theta$)
  leaf.condition ← "$x_i \leq \theta$"
  leaf.l ← new Leaf(label = μ^L)
  leaf.r ← new Leaf(label = μ^R)
  AddGain(leaf.l, $\mathcal{X}, \mathcal{M}$, splits, gains) ▷ Tính gain cho node con mới
  AddGain(leaf.r, $\mathcal{X}, \mathcal{M}$, splits, gains)
  delete(splits[leaf], gains[leaf])
end while
return T

function AddGain(leaf, $\mathcal{X}, \mathcal{M}$, splits, gains)
  $\mathcal{X}_l \leftarrow \{\mathbf{x} \in \mathcal{X} \mid \mathbf{x}$ đi đến leaf$\}$
  $i, \theta \leftarrow \arg\min_{i,\theta}$ SplitCost($\mathcal{X}_l, \mathcal{M}, i, \theta$)
  best_cost ← SplitCost($\mathcal{X}_l, \mathcal{M}, i, \theta$)
  splits[leaf] ← (i, θ)
  gains[leaf] ← $\text{cost}_{\mathcal{M}}(\mathcal{X}_l) - \text{best_cost}$
end function

function SplitCost($\mathcal{X}, \mathcal{M}, i, \theta$)
  $\mathcal{X}_L \leftarrow \{\mathbf{x} \in \mathcal{X} \mid x_i \leq \theta\}$
  $\mathcal{X}_R \leftarrow \{\mathbf{x} \in \mathcal{X} \mid x_i > \theta\}$
  return $\text{cost}_{\mathcal{M}}(\mathcal{X}_L) + \text{cost}_{\mathcal{M}}(\mathcal{X}_R)$
end function

function FindLabels($\mathcal{X}, \mathcal{M}, i, \theta$)
  $\mu^L \leftarrow \arg\min_{\mu \in \mathcal{M}} \sum_{\mathbf{x} \in \mathcal{X}: x_i \leq \theta} \|\mathbf{x} - \mu\|_2^2$
  $\mu^R \leftarrow \arg\min_{\mu \in \mathcal{M}} \sum_{\mathbf{x} \in \mathcal{X}: x_i > \theta} \|\mathbf{x} - \mu\|_2^2$
  return μ^L, μ^R
end function

3.2 Các nghiên cứu liên quan và Khoảng trống nghiên cứu

3.2.1 Tổng qua các nghiên cứu liên quan

Lĩnh vực giải thích mô hình phân cụm (Explainable Clustering) đã có những bước tiến đáng kể. Các phương pháp hậu kiểm (post-hoc) như SHAP hay LIME cung cấp giải thích cục bộ cho từng điểm dữ liệu. Trong khi đó, các phương pháp tiếp cận mô hình nội tại (intrinsic) như ExKMC hay IMM tập trung xây dựng cây quyết định xấp xỉ mô hình k-means, đảm bảo tính giải thích toàn cục và có các chứng minh lý thuyết về giới hạn sai số (Price of Explainability).

3.2.2 Thuật toán Cây phân loại và hồi quy (CART)

Theo tổng quan của Loh và Wei-Yin (2011) [3], CART (Classification and Regression Trees) là một phương pháp học máy kinh điển để xây dựng mô hình dự đoán bằng cách phân hoạch đệ quy không gian dữ liệu và khớp một mô hình đơn giản cho mỗi phân hoạch. Kết quả của quá trình này được biểu diễn trực quan dưới dạng cấu trúc cây quyết định.

Cơ chế hoạt động: Khác với các phương pháp tạo ra ranh giới phân lớp phức tạp, CART chia không gian đặc trưng thành các vùng hình chữ nhật rời rạc thông qua các bước xử lý sau:

- **Phân chia nhị phân (Binary Split):** Tại mỗi nút, CART luôn phân chia dữ liệu thành đúng hai nhánh con (dạng $x_i \leq c$), khác với các thuật toán đa nhánh như CHAID hay C4.5.
- **Chiến lược tìm kiếm:** Thuật toán thực hiện tìm kiếm toàn diện (exhaustive search) trên tất cả các biến và các điểm cắt có thể để tìm ra phương án phân chia tối ưu nhất tại mỗi bước.
- **Tiêu chuẩn phân chia:** Đối với bài toán phân loại, CART sử dụng chỉ số *Gini index* để đo lường độ tinh khiết của nút. Đối với bài toán hồi quy, tiêu chuẩn là tối thiểu hóa tổng bình phương sai số (least squares).

Kỹ thuật Cắt tỉa (Pruning): Một đặc điểm cốt lõi giúp CART tránh hiện tượng quá khớp (overfitting) là chiến lược "phát triển rồi cắt tỉa". Thay vì dừng sớm, thuật toán xây dựng một cây quá khổ (overly large tree) rồi sau đó cắt tỉa ngược từ dưới lên (pruning) để giảm thiểu sai số ước lượng. Quá trình này thường kết hợp với kỹ thuật kiểm chứng chéo (cross-validation) 10-fold để đảm bảo tính ổn định của mô hình.

Xử lý dữ liệu và Hạn chế: CART có ưu điểm lớn là khả năng xử lý các giá trị bị thiếu (missing values) bằng cách sử dụng các “phân chia thay thế” (surrogate splits) – tức là tìm các biến có độ tương quan cao với biến chính để thay thế khi cần thiết. Tuy nhiên, do sử dụng tìm kiếm toàn diện, CART có xu hướng thiên vị (selection bias) đối với các biến đặc trưng có nhiều giá trị phân biệt (nhiều cấp độ) hơn so với các biến ít giá trị.

3.2.3 Tại sao IMM gốc không áp dụng được cho Kernel Clustering?

Mặc dù IMM hoạt động rất hiệu quả trên k-means chuẩn, việc áp dụng trực tiếp thuật toán này cho Kernel k-means gặp phải ba rào cản lớn, tạo nên khoảng trống nghiên cứu mà đề tài này cần giải quyết:

1. **Tâm cụm ẩn (Implicit Centers):** Thuật toán IMM (như mô tả ở Algorithm 2) bắt buộc phải biết tọa độ của các tâm cụm μ để tính toán xem một điểm x có bị "lạc" khỏi tâm của nó sau nhát cắt hay không (tính mistake). Tuy nhiên, trong Kernel k-means, các tâm cụm này nằm trong không gian $\mathcal{H}$ và không có tọa độ tường minh trong không gian đầu vào. Do đó, hàm tính lỗi của IMM trở nên vô hiệu.

2. **Không gian vô hạn chiều:** IMM hoạt động bằng cách duyệt qua từng đặc trưng (feature) để tìm điểm cắt tối ưu. Đối với các kernel như Gaussian, không gian đặc trưng $\mathcal{H}$ có số chiều tiến tới vô cùng ($D \to \infty$). Việc duyệt qua vô hạn chiều là bất khả thi về mặt tính toán thực tế.

3. **Mất tính giải thích (Non-interpretable Feature Maps):** Ngay cả khi chúng ta tìm được một nhát cắt dạng $x'_i \leq \theta$ trong không gian $\mathcal{H}$, khi chiếu ngược nhát cắt này về không gian dữ liệu gốc, nó thường tương ứng với một đường ranh giới phi tuyến cực kỳ phức tạp. Điều này vi phạm nguyên tắc cốt lõi của cây quyết định giải thích được là phải sử dụng các lát cắt song song trục (axis-aligned cuts) để con người có thể hiểu được (ví dụ: $x_1 < 5$).

Chính vì những lý do trên, cần thiết phải có một phương pháp mới kết hợp sức mạnh của Kernel với tính minh bạch của cây quyết định thông qua các kỹ thuật xấp xỉ đặc trưng (Surrogate Features), thay vì áp dụng trực tiếp IMM.

4 Phương pháp đề xuất

4.1 Định nghĩa và Hạn chế về Tính diễn giải

Định nghĩa 1. (Bản đồ đặc trưng có thể diễn giải). Xét $\phi : X \to \mathbb{R}^D$ là một bản đồ đặc trưng được định nghĩa trên tập dữ liệu $X \subseteq \mathbb{R}^d$ sao cho $K(x, y) = \langle \phi(x), \phi(y) \rangle = \sum_{j=1}^{D} \phi_j(x)\phi_j(y)$ với mọi $x, y \in X$. Ta nói rằng bản đồ đặc trưng $\phi = (\phi_1, \ldots, \phi_D)$ là có thể diễn giải (interpretable) nếu mỗi $\phi_j(x)$ phụ thuộc chính xác vào một tọa độ của x.

Định nghĩa này đặt ra tiêu chuẩn cao cho tính minh bạch, yêu cầu mỗi đặc trưng trong không gian mới phải đại diện trực tiếp cho một thuộc tính gốc. Tuy nhiên, kết quả sau đây chỉ ra rằng không có bản đồ đặc trưng nào cho Gaussian kernel có thể thỏa mãn tính chất diễn giải này, ngay cả khi chúng ta cho phép các bản đồ đặc trưng phụ thuộc vào dữ liệu.

Định lý 1. (Gaussian kernel không thể có bản đồ đặc trưng có thể diễn giải). Xét Gaussian kernel $K(x, y) = e^{-\gamma\|x-y\|_2^2}$ trong không gian $d > 1$ chiều. Tồn tại một tập dữ liệu X sao cho với mọi bản đồ đặc trưng $\phi : X \to \mathbb{R}^D$ thỏa mãn $\langle \phi(x), \phi(y) \rangle = K(x, y)$ với mọi $x, y \in X$, luôn tồn tại một chỉ số $j \in [D]$ sao cho ϕ_j phụ thuộc vào nhiều hơn một chiều đầu vào của $x \in X$.

Chứng minh ngắn gọn được trình bày trong phần chứng minh định lý bên dưới. Điều này khẳng định sự mâu thuẫn cơ bản giữa cấu trúc của Gaussian kernel và yêu cầu về tính diễn giải từng chiều. Trong phần tiếp theo, tác giả đề xuất giải quyết vấn đề này bằng cách sử dụng các đặc trưng thay thế. Tuy nhiên, ngay cả khi dùng đặc trưng thay thế, tính đơn điệu của ϕ_j vẫn không được đảm bảo đối với Gaussian kernel.

Định lý 2. (Gaussian kernel không chấp nhận các đặc trưng đơn điệu). Xét Gaussian kernel một chiều $K(x, y) = e^{-\gamma|x-y|^2}$. Khi đó, tồn tại một tập dữ liệu $X \subseteq \mathbb{R}$ sao cho với mọi bản đồ đặc trưng $\phi : X \to \mathbb{R}^D$ luôn tồn tại một thành phần $\phi_j, j \in [D]$ không đơn điệu.

Chứng minh được trình bày trong phần chứng minh định lý. Kết quả này cho thấy các luật quyết định đơn giản dạng 'ngưỡng cắt' là không đủ để mô tả hành vi của Gaussian kernel. Định lý 2 gợi ý rằng khái niệm diễn giải hiện tại, được xác định thông qua các vết cắt ngưỡng $x_i \gtrless \theta$, là quá hạn chế để suy ra các cây quyết định có thể diễn giải cho các kernel. Do đó, nhóm tác giả đã đề xuất mở rộng định nghĩa về tính diễn giải. Mặc dù các phân hoạch tại mỗi nút vẫn nên căn chỉnh với các trục của $\mathbb{R}^d$ (điều này đảm bảo rằng các đặc trưng quan trọng có thể được xác định), họ cho phép phân hoạch tại nút là bất kỳ khoảng nào và phần bù của nó.

Định nghĩa 2. (Cây quyết định có thể diễn giải). Xét một cây quyết định T phân hoạch tập dữ liệu $X \subseteq \mathbb{R}^d$ thành k lá. Ta gọi T là một cây quyết định có thể diễn giải nếu tại mọi nút $u \in T$, tồn tại $i \in [d], \theta_1 < \theta_2 \in \mathbb{R}$ sao cho dữ liệu X^u đến nút u được chia thành hai tập con rời nhau

$$X_L^u = \{x \in X^u : x_i \in [\theta_1, \theta_2]\} \quad \text{và} \quad X_R^u = \{x \in X^u : x_i \notin [\theta_1, \theta_2]\}$$

Định nghĩa này cho phép các luật dạng 'nếu giá trị nằm trong khoảng $[a, b]$', phù hợp hơn với tính chất cục bộ của các kernel khoảng cách. Để kết luận phần này, tác giả đã nhận xét rằng một số kernel cộng tính quan trọng thực tế thừa nhận các bản đồ đặc trưng tạo ra các cây quyết định có thể diễn giải theo cấu trúc mới này.

4.2 Giải pháp của Kernel IMM

Như Định lý 1 và Định lý 2 đã đề cập, Gaussian kernel không thỏa mãn tính chất có thể diễn giải (không có bản đồ đặc trưng diễn giải được và không chấp nhận các đặc trưng đơn điệu). Ngoài ra, cũng có những Kernel tích dựa trên khoảng cách khác (**Laplace Kernel** $e^{-\gamma\|x-y\|_1}$) không thỏa mãn tính diễn giải. Vì vậy, ở phần này, tác giả giới thiệu giải pháp sử dụng **đặc trưng thay thế (surrogate features)** để khắc phục các hạn chế trên cũng như là đưa ra thuật toán **Kernel IMM** tổng quát. Trước hết, ta cùng xem xét về 1 khái niệm mà bài báo có đề cập nhưng chưa giải thích kĩ:

4.2.1 Kernel Tích Bị Chặn (Bounded Product Kernel)

Trong phần này tác giả có đề cập đến khái niệm **Bounded Product Kernel**, để dễ nắm bắt ngữ cảnh và tính chất, chúng em xin làm rõ khái niệm này như sau:

1. **Product Kernel (Kernel dạng tích):** Một Kernel K được gọi là Product Kernel trên không gian nhiều chiều ($\mathbb{R}^d$) nếu nó có thể được tách thành tích của các Kernel con (K_i) trên từng chiều riêng lẻ.
$$K(x, y) = \prod_{i=1}^{d} K_i(x_i, y_i)$$
Ví dụ: Kernel Gaussian $e^{-\|x-y\|^2} = \prod e^{-(x_i-y_i)^2}$ là một Product Kernel vì nó tách được thành tích của các hàm mũ.

2. **Bounded Kernel (Kernel bị chặn):** Một Kernel được gọi là Bounded nếu giá trị của nó luôn nằm trong một khoảng hữu hạn (thường là $K(x, x) \leq 1$), không bao giờ tiến tới vô cực. *Ví dụ:* Kernel Gaussian luôn trả về giá trị từ 0 đến 1.

Bounded product kernels trên $\mathbb{R}^d$ có thể được biểu diễn dưới dạng $K(x, y) = \prod_{i=1}^{d} K_i(x_i, y_i)$, trong đó mỗi K_i là một kernel trên $\mathbb{R}$ với $K_i(x, y) \leq K_i(x, x) = 1$.

4.2.2 Đặc trưng thay thế (Surrogate features)

Tính chất của Product Kernel:

- **Không gian RKHS:** Không gian Hilbert sinh bởi kernel (RKHS) của K được cho bởi phép tensor hóa $\mathcal{H} = \mathcal{H}_1 \otimes \cdots \otimes \mathcal{H}_d$, với $\mathcal{H}_i$ là RKHS của kernel con K_i.
- **Bản đồ đặc trưng ngầm định:** $\psi : \mathbb{R}^d \to \mathcal{H}$ liên quan đến các bản đồ đặc trưng con $\psi_i : \mathbb{R} \to \mathcal{H}_i$ thông qua tích vô hướng:
$$\langle \psi(x), \psi(y) \rangle = \prod_{i=1}^{d} \langle \psi_i(x_i), \psi_i(y_i) \rangle$$

Giới thiệu Surrogate Features: Để bảo toàn các cấu trúc căn chỉnh theo trục (*axis-aligned structures*) giúp tăng tính diễn giải, bài báo đề xuất sử dụng một *bản đồ đặc trưng thay thế (surrogate feature map)* $\phi = (\phi_1, \ldots, \phi_d)$ thay vì ψ.
Công thức và vai trò của Surrogate Features: Mỗi ϕ_i là một xấp xỉ hữu hạn chiều của ψ_i. Điểm đáng lưu ý là ϕ **không** xấp xỉ một ánh xạ tới $\mathcal{H}$ mà thay vào đó ánh xạ tới không gian Descartes $\mathcal{H}_1 \times \cdots \times \mathcal{H}_d$ và tính chất xấp xỉ tích vô hướng bằng tổng:

$$\langle \phi(x), \phi(y) \rangle \approx \sum_{i=1}^{d} \langle \psi_i(x_i), \psi_i(y_i) \rangle \neq \langle \psi(x), \psi(y) \rangle \tag{2}$$

Điều này cho phép các vết cắt trên không gian đặc trưng ϕ tương ứng trực tiếp với các phân hoạch trên không gian đầu vào $\mathbb{R}^d$. Với Gaussian kernel, ϕ_i là các xấp xỉ Taylor của ψ_i.
Lưu ý: Quan trọng hơn, tác giả đã nói rằng *"sai số do bước xấp xỉ này được chứng minh là bị chặn (bounded)"*. Theo đó, phương pháp IMM sẽ hoạt động trên tập các tâm cụm $\mathcal{M}$ được tính toán trong không gian đặc trưng thay thế này. Cuối cùng, bên cạnh việc sử dụng chuỗi Taylor, phương pháp cũng đề xuất một lựa chọn thay thế tổng quát cho ϕ_i hoạt động với mọi kernel dạng tích dựa trên khoảng cách (distance-based product kernels), dẫn đến các đảm bảo xấp xỉ phụ thuộc vào dữ liệu.

4.2.3 Kernel Taylor có thể diễn giải (Interpretable Taylor kernels)

Để giải quyết mâu thuẫn giữa tính chất nhân của Product Kernel (Định lý 1) và yêu cầu tính chất cộng để đảm bảo khả năng diễn giải, chúng ta cần xây dựng một bản đồ đặc trưng xấp xỉ $\phi(x)$ sao cho tích vô hướng của nó có thể được biểu diễn dưới dạng tổng. Dưới đây là định nghĩa hình thức cho giải pháp này của nhóm tác giả:

Định nghĩa 3. (Kernel Taylor có thể diễn giải và đặc trưng thay thế tương ứng) Xét K_i là một kernel bị chặn trên miền liên thông $\mathcal{X}_i \subseteq \mathbb{R}$, có dạng $K_i(z, z') = f(z)f(z')g(zz')$ với f là một hàm khả vi và g là một hàm giải tích. Gọi $g^{(j)}$ là đạo hàm bậc j của g. Giả sử $g^{(j)}(0) \geq 0$ với mọi $j \in \mathbb{N}$ và phương trình $z^{j-1}(zf'(z) + jf(z)) = 0$ có tối đa một nghiệm z trên $\mathcal{X}_i$. Khi đó, ta gọi K_i là một *kernel Taylor có thể diễn giải*. Hơn nữa, giả sử K là tích của d kernel Taylor có thể diễn giải $K_1, \ldots, K_d$, xác định trên miền liên thông $\mathcal{X} \subset \mathbb{R}^d$. Với một số nguyên M cho trước, ta định nghĩa bản đồ đặc trưng thay thế cho K là $\phi(x) = (\phi_i(x_i))_{i=1}^d$, trong đó mỗi $\phi_i : \mathbb{R} \to \mathbb{R}^{M+1}$ được xác định bởi $\phi_i(z) = (\phi_{i,j}(z))_{j=0}^M$ với $\phi_{i,j}(z) = z^j f(z)\sqrt{g^{(j)}(0)/j!}$ cho mọi $j \leq M$.

Tóm tắt ý nghĩa: Định nghĩa trên thiết lập nền tảng lý thuyết vững chắc cho việc xây dựng các đặc trưng thay thế, tập trung vào hai yếu tố cốt lõi:

- **Khả năng phân tách (Decomposability):** Yêu cầu hàm kernel có thể được tách thành các thành phần cấu trúc đơn giản hơn thông qua các hàm f và g.
- **Điều kiện về số lượng nghiệm và tính không âm:** Yêu cầu các hệ số Taylor không âm ($g^{(j)}(0) \geq 0$) đảm bảo tồn tại phép khai căn thực số, trong khi điều kiện về nghiệm duy nhất đảm bảo tính chất đơn điệu (unimodality) của các đặc trưng. Điều này đồng nghĩa với việc không gian đặc trưng mới vẫn bảo toàn được tính chất diễn giải căn chỉnh theo trục (như yêu cầu của Định lý 1).

Áp dụng với Gaussian Kernel

Để làm rõ Định nghĩa 3, nhóm chúng em sẽ kiểm chứng trường hợp cụ thể khi áp dụng cho Gaussian Kernel:

Xét công thức của một thành phần con Gaussian $K_i(z, z') = e^{-\gamma(z-z')^2}$. Bằng cách khai triển hằng đẳng thức và tách các thành phần, ta có:

$$K_i(z, z') = e^{-\gamma z^2} \cdot e^{-\gamma z'^2} \cdot e^{2\gamma zz'} = f(z)f(z')g(zz'), \tag{3}$$

trong đó $f(z) = e^{-\gamma z^2}$, $f(z') = e^{-\gamma z'^2}$ và $g(u) = e^{2\gamma u}$ với $u = zz'$.
Vấn đề chính nằm ở số hạng $g(zz')$, nơi hai biến z và z' tương tác với nhau trong hàm mũ. Để tách biệt chúng, ta sử dụng khai triển chuỗi Taylor của hàm mũ $e^u = \sum_{j=0}^{\infty} \frac{u^j}{j!}$:

$$g(zz') = e^{2\gamma zz'} = \sum_{j=0}^{\infty} \frac{(2\gamma)^j}{j!}(zz')^j = \sum_{j=0}^{\infty} \left(\sqrt{\frac{(2\gamma)^j}{j!}} z^j\right) \left(\sqrt{\frac{(2\gamma)^j}{j!}} (z')^j\right). \tag{4}$$

Đặt $h_{i,j}(z) = \sqrt{\frac{(2\gamma)^j}{j!}} z^j$, ta thu được biểu diễn tích vô hướng $g(zz') = \sum_{j=0}^{\infty} h_{i,j}(z) \cdot h_{i,j}(z')$. Từ (3) và (4), suy ra $K_i(z, z')$ là tích vô hướng:

$$K_i(z, z') = f(z)f(z') \sum_{j=0}^{\infty} h_{i,j}(z)h_{i,j}(z') = \sum_{j=0}^{\infty} \left(f(z) \cdot z^j \cdot \sqrt{\frac{(2\gamma)^j}{j!}}\right) \left(f(z') \cdot z'^j \cdot \sqrt{\frac{(2\gamma)^j}{j!}}\right) \tag{5}$$

Nhưng vì đây là chuỗi vô hạn nên để tính toán thực tế, chuỗi vô hạn này được cắt cụt tại bậc M:

$$K_i(z, z') \approx \sum_{j=0}^{M} \left(f(z) \cdot z^j \cdot \sqrt{\frac{(2\gamma)^j}{j!}}\right) \left(f(z') \cdot z'^j \cdot \sqrt{\frac{(2\gamma)^j}{j!}}\right)$$

Kết hợp với hệ số chuẩn hóa $f(z)$, ta định nghĩa thành phần thứ j của bản đồ đặc trưng thay thế (Surrogate Feature) cho chiều thứ i là:

$$\phi_{i,j}(z) = f(z) \cdot z^j \cdot \sqrt{\frac{(2\gamma)^j}{j!}}. \tag{6}$$

với mọi $j \leq M$. Sau đó, ta có được vector $\phi_i : \mathbb{R} \to \mathbb{R}^{M+1}$ là $\phi_i(z) = (\phi_{i,j}(z))_{j=0}^{M}$.
Cuối cùng, bằng cách ghép nối các vector đặc trưng con từ tất cả các chiều, ta thu được bản đồ đặc trưng tổng quát $\phi(x) = (\phi_i(x_i))_{i=1}^{d}$. Khi đó, kernel xấp xỉ trong không gian mới này trở thành tổng của các kernel con, thỏa mãn yêu cầu về tính diễn giải:

$$K_{Surrogate}(x, y) = \langle \Phi(x), \Phi(y) \rangle \approx \sum_{i=1}^{d} K_i(x_i, y_i). \tag{7}$$

Kiểm chứng các điều kiện đối với Gaussian Kernel Ngoài ra, để Gaussian Kernel được công nhận là *Interpretable Taylor Kernel* theo Định nghĩa 3, nó phải thỏa mãn hai điều kiện sau và nhóm em cũng tiến hành kiểm chứng với Gaussian Kernel:

Điều kiện 1: Hệ số Taylor không âm ($g^{(j)}(0) \geq 0$ với mọi $j \in \mathbb{N}$)
Với Gaussian kernel, xét hàm $g(u) = e^{2\gamma u}$ (với $\gamma > 0$). Đạo hàm bậc j của g (chứng minh tại Phụ lục A):

$$g^{(j)}(u) = (2\gamma)^j e^{2\gamma u}$$

Tại điểm $u = 0$, ta có:

$$g^{(j)}(0) = (2\gamma)^j e^0 = (2\gamma)^j$$

Vì bandwidth $\gamma > 0$ nên $(2\gamma)^j > 0$. Do đó, điều kiện 1 được thỏa mãn.

Điều kiện 2: Số lượng nghiệm duy nhất
Xét phương trình $z^{j-1}(zf'(z) + jf(z)) = 0$ trên miền xác định dương $(0, \infty)$. Với $f(z) = e^{-\gamma z^2}$, ta có đạo hàm $f'(z) = -2\gamma z e^{-\gamma z^2}$. Thay vào phương trình:

$$\begin{aligned} z^{j-1}\left[z(-2\gamma z e^{-\gamma z^2}) + j e^{-\gamma z^2}\right] &= 0 \\ z^{j-1} e^{-\gamma z^2}(-2\gamma z^2 + j) &= 0 \end{aligned}$$

Trên miền $z > 0$, ta luôn có $z^{j-1} \neq 0$ và $e^{-\gamma z^2} > 0$. Do đó phương trình chỉ triệt tiêu khi:

$$-2\gamma z^2 + j = 0 \quad \Rightarrow \quad z^2 = \frac{j}{2\gamma} \quad \Rightarrow \quad z = \sqrt{\frac{j}{2\gamma}}$$

Phương trình có duy nhất một nghiệm dương. Điều kiện 2 được thỏa mãn.
Kết luận: Gaussian Kernel thỏa mãn cả hai điều kiện của Định nghĩa 3, đảm bảo sự tồn tại của các hệ số khai triển và tính chất đơn điệu từng khúc cần thiết cho tính diễn giải.

Với việc đảm bảo các điều kiện này, chúng ta đã có thể áp dụng phương pháp đề xuất cho Gaussian kernel. Tác giả đưa ra định lý sau để thể hiện mối liên hệ giữa việc phân hoạch trên không gian đặc trưng thay thế và cấu trúc của cây quyết định diễn giải được:

Định lý 3. (Các vết cắt ngưỡng trong không gian đặc trưng thay thế của kernel Taylor có thể diễn giải tạo ra các cây quyết định có thể diễn giải). Xét K là tích của các kernel Taylor có thể diễn giải, và gọi ϕ là bản đồ đặc trưng thay thế của nó. Khi đó, một vết cắt ngưỡng có dạng $\phi_{i,j}(x_i) \gtrless \theta$ dẫn đến một cây quyết định có thể diễn giải trong $\mathbb{R}^d$.

Định lý này có ý nghĩa quan trọng vì nó đảm bảo rằng việc tối ưu hóa trên không gian đặc trưng thay thế (vốn có số chiều lớn hơn) vẫn dẫn đến các mô hình có thể giải thích được trong không gian gốc. Hơn nữa, việc lựa chọn các đặc trưng này không chỉ cung cấp tính diễn giải mà còn giúp bảo toàn các giới hạn sai số trong trường hợp xấu nhất (worst-case guarantees), điều sẽ được làm rõ thông qua khái niệm Price of Explainability (PoE) ở phần tiếp theo.

4.3 Phân tích Lý thuyết

4.3.1 Cái giá phải trả cho sự giải thích (Price of Explainability - PoE)

Ở phần này tác giả mở rộng khái niệm Price of Explainability (PoE) cho các kernel, trong đó có định nghĩa như sau:

Định nghĩa 4. (Price of Explainability). Với một tập hợp $X \subset \mathbb{R}^d$ và một cây quyết định có thể diễn giải T, price of explainability (PoE) của T trên X được định nghĩa là tỷ lệ $p(T, X) = \text{cost}(T, X)/\text{cost}_{opt}(X)$, trong đó $\text{cost}_{opt}(X)$ là chi phí tối ưu của Kernel k-means. Price of explainability của tập dữ liệu X được cho bởi $p(X) = \min_T p(T, X)$, trong đó giá trị nhỏ nhất được lấy trên tất cả các cây quyết định có thể diễn giải.

Với định nghĩa trên, ta dễ dàng thấy rằng chỉ số PoE đóng vai trò thước đo định lượng cho sự đánh đổi giữa hiệu suất tối ưu và khả năng giải thích:

- $PoE \geq 1$: Luôn đúng vì chi phí của cây quyết định không bao giờ nhỏ hơn chi phí tối ưu.
- PoE gần 1: Cây quyết định mô phỏng tốt mô hình phức tạp.
- PoE lớn: Để đổi lấy sự dễ hiểu, ta phải chấp nhận sai số lớn.

4.3.2 Đảm bảo trường hợp xấu nhất (Worst-case Guarantees)

Trong bối cảnh tuyến tính (k-means thông thường), thuật toán IMM gốc có giới hạn sai số là $O(k^2)$. Tuy nhiên, đối với Kernel IMM, bài báo chứng minh rằng sai số trong trường hợp xấu nhất bị chặn bởi giới hạn mới: $O(d \cdot k^2)$. Sự xuất hiện của hệ số chiều dữ liệu d xuất phát từ việc sử dụng các **đặc trưng thay thế (surrogate features)** để tách biệt các chiều dữ liệu:

- **Kernel gốc (Product Kernel):** Tính toán khoảng cách dựa trên tích tương tác giữa các chiều ($K = \prod K_i$).
- **Kernel thay thế (Additive Kernel):** Để xây dựng cây quyết định (cắt trên từng trục), thuật toán xấp xỉ Kernel gốc bằng tổng các Kernel con ($K_{surrogate} = \sum K_i$).

Cơ sở toán học cho điều này được trình bày trong Phụ lục E của bài báo (Bổ đề 3). Dựa trên Bất đẳng thức AM-GM, tác giả chứng minh được rằng chi phí của việc xấp xỉ (tách chiều) luôn nằm trong khoảng từ 1 đến d lần chi phí thực tế:

$$\text{cost}(C) \leq \sum_{i=1}^{d} \text{cost}_i(C) \leq d \cdot \text{cost}(C) \tag{8}$$

Đây chính là nguyên nhân cốt lõi khiến sai số tối đa có thể bị nhân thêm hệ số d khi biến đổi một Kernel phức tạp thành các luật đơn giản trên từng trục.

Chứng minh chi tiết cho giới hạn sai số (Phụ lục E của bài báo):
Trong phần này, chúng ta chứng minh rằng việc tách các chiều đầu vào của các kernel tích bị chặn sẽ tạo ra sai số không lớn hơn $O(d)$. Nhắc lại rằng bản đồ đặc trưng thay thế của chúng ta được cho bởi

$$\phi(x) = (\phi_i(x))_{i=1}^{d}$$

trong đó mỗi ϕ_i là một bản đồ đặc trưng hợp lệ cho kernel một chiều K_i. Bản thân bản đồ đặc trưng thay thế này liên kết với một kernel cộng thay thế:

$$\langle \phi(x), \phi(y) \rangle = \sum_{i=1}^{d} \langle \phi_i(x), \phi_i(y) \rangle = \sum_{i=1}^{d} K_i(x, y) \neq K(x, y)$$

Điều này đảm bảo tính giải thích nhưng cần chứng minh nó bảo toàn các giới hạn trường hợp xấu nhất.

Bổ đề 3. Cho $X \subset \mathbb{R}^d$ là một tập dữ liệu, được phân hoạch thành k cụm $C_1, \ldots, C_k$. Gọi $cost(C_1, \ldots, C_k)$ là hàm chi phí kernel k-means liên kết với một kernel tích dựa trên khoảng cách K trên $\mathbb{R}^d$, và $cost_i$ là chi phí đối với bản đồ đặc trưng ϕ_i. Khi đó:

$$cost(C_1, \ldots, C_k) \leq \sum_{i=1}^{d} cost_i(C_1, \ldots, C_k) \leq d \cdot cost(C_1, \ldots, C_k)$$

Chứng minh. Đầu tiên, chứng minh dựa vào **Bất đẳng thức AM-GM**.

1. Ta có $K(x, y) = \prod K_i(x, y)$.
2. Theo AM-GM (và tính chất $K_i(x, y) \leq 1$): Tích các số (Geometric Mean) luôn nhỏ hơn hoặc bằng Trung bình cộng (Arithmetic Mean) của chúng.

$$\left(\prod_{i=1}^{d} K_i(x, y) \right)^{1/d} \leq \frac{1}{d} \sum_{i=1}^{d} K_i(x, y)$$

3. Vì $K_i(x, y) \leq 1$ (tính chất của Gaussian/Laplace), nên:

$$K(x, y) = \prod_{i=1}^{d} K_i(x, y) \leq \left(\prod_{i=1}^{d} K_i(x, y) \right)^{1/d}.$$

4. Kết hợp lại:

$$K(x, y) \leq \frac{1}{d} \sum_{i=1}^{d} K_i(x, y)$$

Suy ra,

$$K(x, y) = \prod_{i=1}^{d} K_i(x, y) \leq \left(\prod_{i=1}^{d} K_i(x, y) \right)^{1/d} \leq \frac{1}{d} \sum_{i=1}^{d} K_i(x, y)$$

Do đó, viết lại hàm chi phí kernel k-means, ta thấy rằng:

$$\begin{aligned}
cost(C_1, \ldots, C_k) &= |X| - \sum_{l=1}^{k} \frac{1}{|C_l|} \sum_{x,y \in C_l} K(x, y) \\
&\geq |X| - \sum_{l=1}^{k} \frac{1}{|C_l|} \sum_{x,y \in C_l} \frac{1}{d} \sum_{i=1}^{d} K_i(x, y) \\
&= \frac{1}{d} \sum_{i=1}^{d} \left(|X| - \sum_{l=1}^{k} \frac{1}{|C_l|} \sum_{x,y \in C_l} K_i(x, y) \right) \\
&= \frac{1}{d} \sum_{i=1}^{d} cost_i(C_1, \ldots, C_k)
\end{aligned}$$

Điều này dẫn đến cận trên từ Bổ đề 3. Đối với cận dưới, lưu ý rằng với mọi $x, y \in \mathbb{R}^d$:

$$\begin{aligned}
\|\phi(x) - \phi(y)\|^2 &= \langle \phi(x), \phi(x) \rangle - 2\langle \phi(x), \phi(y) \rangle + \langle \phi(y), \phi(y) \rangle \\
&= K(x, x) - 2K(x, y) + K(y, y) \\
&= 1 - 2K(x, y) + 1 \\
&= 2(1 - K(x, y)) \\
&= 2 \left(1 - \prod_{i=1}^{d} K_i(x, y) \right) \\
&\leq 2 \left(\sum_{i=1}^{d} (1 - K_i(x, y)) \right) \\
&= \sum_{i=1}^{d} \|\phi_i(x) - \phi_i(y)\|^2
\end{aligned}$$

trong đó ta sử dụng thực tế rằng $|\prod a_i - \prod b_i| \leq \sum |a_i - b_i|$ với mọi $|a_i|, |b_i| \leq 1$.
Viết lại chi phí kernel k-means để sử dụng quan sát này, ta thu được:

$$\begin{aligned} cost(C_1, \ldots, C_k) &= \sum_{l=1}^{k} \frac{1}{2|C_l|} \sum_{x,y \in C_l} \|\phi(x) - \phi(y)\|^2 \\ &\leq \sum_{i=1}^{d} \sum_{l=1}^{k} \frac{1}{2|C_l|} \sum_{x,y \in C_l} \|\phi_i(x) - \phi_i(y)\|^2 \\ &= \sum_{i=1}^{d} cost_i(C_1, \ldots, C_k) \end{aligned}$$

□

Sau đó, tác giả khẳng định: *"This is a result of operating on the surrogate features that decouple the d input dimension."* Câu này cho thấy cái giá phải trả cho việc *xé lẻ* (decouple) đó chính là sai số tăng lên d lần.

- Khi chúng ta chuyển từ *Tích* (Coupled) sang *Tổng* (Decoupled), chúng ta đã thay đổi cấu trúc hình học của dữ liệu.
- Mỗi lần tách một chiều i ra để xử lý riêng, chúng ta chấp nhận một chút sai lệch so với bản gốc.
- Chúng ta có d chiều $\rightarrow$ Chúng ta tích tụ sai lệch d lần.

4.3.3 PoE cho Kernel Taylor có thể diễn giải

Dựa trên các định nghĩa về PoE và việc sử dụng các đặc trưng thay thế đã trình bày, chúng ta có thể thiết lập một giới hạn cụ thể cho các kernel Taylor có thể diễn giải. Việc sử dụng khai triển Taylor không chỉ giúp tách biệt các chiều dữ liệu mà còn cho phép kiểm soát sai số xấp xỉ thông qua bậc cắt cụt M. Kết quả chính về giới hạn PoE cho lớp kernel này được thể hiện qua Định lý 4 như sau:

Định lý 4. (Chi phí diễn giải cho các kernel Taylor có thể diễn giải). Xét $C_1, \ldots, C_k$ là các cụm của một tập dữ liệu $X \subset \mathbb{R}^d$ thu được từ kernel k-means, trong đó kernel K là một kernel Taylor có thể diễn giải. Gọi $\Phi = \phi(X)$ là các đặc trưng thay thế cho K trên X. Khi đó, cây quyết định có thể diễn giải T thu được từ Kernel IMM trên Φ thỏa mãn $p(T, X) = O(dk^2) + \frac{O(dk^2\delta)}{\text{cost}_{opt}(X)}$ trong đó $\delta = \delta(M)$ phụ thuộc vào bậc M của bản đồ đặc trưng thay thế và $\lim_{M\to\infty} \delta(M) = 0$ với mọi tập dữ liệu X. Do đó, bằng cách chọn M một cách thích ứng sao cho $\delta = O(\text{cost}_{opt})$, ta thu được các giới hạn $O(dk^2)$.

Định lý này đóng vai trò là cơ sở lý thuyết quan trọng cho thuật toán Kernel IMM, khẳng định rằng thuật toán không chỉ khả thi mà còn đảm bảo sai số không vượt quá một giới hạn xác định so với kết quả tối ưu.

Cụ thể, các thành phần trong giới hạn sai số được phân tích như sau:

- **Thành phần chính $O(dk^2)$:** Đây là giới hạn sai số cốt lõi. Trong đó, k^2 là thừa hưởng từ thuật toán IMM gốc (tuyến tính). Hệ số d xuất hiện do chi phí của việc tách biệt các chiều dữ liệu (decoupling dimensions). Khi chuyển từ Kernel tích (các chiều phụ thuộc lẫn nhau) sang dạng tổng của các đặc trưng thay thế (độc lập để dễ diễn giải), sai số có thể tăng lên tối đa d lần (theo Bổ đề 3).
- **Sai số xấp xỉ $\delta(M)$:** sai số phát sinh do việc cắt cụt chuỗi Taylor ở bậc M (Lý do cần cắt cụt được trình bày ở 4.2.3). Nếu M nhỏ, δ lớn (xấp xỉ thô); nếu $M \to \infty$ thì $\delta \to 0$ (xấp xỉ chính xác).
- **Khả năng triệt tiêu sai số phụ:** Thành phần thứ hai trong công thức đại diện cho phần nhiễu do xấp xỉ. Định lý khẳng định rằng ta có thể làm cho phần này nhỏ tùy ý bằng cách tăng bậc M.

Ý nghĩa thực tiễn: Định lý cho thấy sự đánh đổi giữa độ phức tạp tính toán và độ chính xác có thể kiểm soát được. Trong thực tế, tác giả khẳng định rằng ngay cả các bậc thấp $M \leq 5$ của các đặc trưng thay thế Taylor đã cung cấp đủ độ linh hoạt để thu được các phân cụm diễn giải tốt, và do đó Kernel IMM về mặt tính toán *không tốn kém hơn nhiều* so với IMM chuẩn. Nhận định này sẽ được nhóm chúng em kiểm chứng cụ thể thông qua các số liệu thực nghiệm tại Mục 6.3.4.

4.4 Kernel Tích dựa trên khoảng cách (Distance-based Product Kernel)

Mặc dù phương pháp khai triển Taylor đã cho thấy sự hiệu quả đối với Gaussian Kernel, việc áp dụng nó cho lớp các kernel tích dựa trên khoảng cách (Distance-based Product Kernels) khác lại gặp nhiều thách thức. Cụ thể, xét các kernel có dạng

$$K(x, y) = \prod_{i=1}^{d} h(|x_i - y_i|)$$

với ví dụ điển hình là **Laplace Kernel** có $h(t) = e^{-|t|}$. Do hàm trị tuyệt đối $|t|$ không trơn (không khả vi) tại 0, việc áp dụng khai triển Taylor trở nên khó khăn và không mang lại hiệu quả như mong đợi.
Để khắc phục hạn chế này, thay vì cố gắng tìm kiếm một công thức toán học phức tạp để xấp xỉ đặc trưng ϕ, tác giả đề xuất một phương pháp thực dụng hơn: sử dụng chính dữ liệu làm mốc (landmarks). Cụ thể, các điểm dữ liệu $x^{(j)}$ trong tập dữ liệu X sẽ được chọn làm các "điểm neo". Khi đó, đặc trưng thay thế thứ j cho chiều i được định nghĩa là khoảng cách từ điểm dữ liệu đang xét x tới điểm mốc $x^{(j)}$:

$$\phi_{i,j}(x) = h(|x_i - x_i^{(j)}|) \tag{9}$$

Phương pháp này vẫn đảm bảo tính diễn giải của mô hình bởi vì một vết cắt ngưỡng trên đặc trưng mới $\phi_{i,j}(x) \leq \theta$ tương đương với điều kiện $h(|x_i - x_i^{(j)}|) \leq \theta$. Do h là một hàm giảm, điều này đồng nghĩa với $|x_i - x_i^{(j)}| \geq h^{-1}(\theta)$, tức là giá trị của x_i phải nằm cách xa điểm mốc $x^{(j)}$ một khoảng nhất định. Về mặt

hình học, điều này dẫn đến việc phân chia không gian thành các đoạn (intervals) trên từng trục tọa độ, tương ứng với các luật `if-then` đơn giản, do đó vẫn duy trì được khả năng giải thích của cây quyết định. Tuy nhiên, việc sử dụng phương pháp dựa trên mốc này cũng đi kèm với một sự đánh đổi quan trọng: chúng ta mất đi các đảm bảo sai số trường hợp xấu nhất (worst-case bounds) vốn có ở phương pháp Taylor (sai số $O(dk^2)$). Thay vào đó, sai số của phương pháp mới sẽ phụ thuộc vào dữ liệu (data-dependent). Kết quả này được chính thức hóa trong định lý sau:

Định lý 5. (Chi phí diễn giải cho các kernel tích dựa trên khoảng cách). Xét $C_1, \ldots, C_k$ là các cụm của tập dữ liệu $X \subset \mathbb{R}^d$ thu được từ kernel k-means, trong đó kernel K là một kernel tích dựa trên khoảng cách. Ký hiệu $\Phi = \phi(X)$ là các đặc trưng thay thế cho K trên X, với $\phi_{i,j}(x) = K_i(x, x^{(j)})$. Khi đó, cây quyết định diễn giải được thu được từ Kernel IMM trên Φ thỏa mãn $p(T, X) = O(Cdk^2)$, trong đó C phụ thuộc vào tập dữ liệu X và kernel K.

Như vậy, nếu phân bố dữ liệu *xấu* (làm cho hằng số C lớn), sai số có thể tăng lên đáng kể. Tóm lại, đây là một phương án thay thế linh hoạt: nếu sử dụng Gaussian Kernel, phương pháp Taylor là lựa chọn tối ưu với đảm bảo lý thuyết chặt chẽ; ngược lại, với các kernel khó tính đạo hàm như Laplace, phương pháp dùng điểm mốc cung cấp một giải pháp khả thi, dễ cài đặt và vẫn đảm bảo tính diễn giải, mặc dù phải chấp nhận rủi ro cao hơn về mặt sai số lý thuyết.

4.5 Tối ưu hóa chi phí bằng chiến lược tham lam

4.5.1 Vấn đề của Kernel IMM và giải pháp

Kernel IMM vẫn có thể sẽ gặp 1 vài trường hợp *không thể áp dụng được* cho mọi loại kernel nếu kernel không tồn tại đặc trưng thay thế phù hợp, hay *không đủ mạnh* để có thể xấp xỉ và mô phỏng kết quả kernel k-means bởi ràng buộc chỉ có k lá - tương ứng với số cụm - trong cây quyết định được tạo ra. Như ví dụ minh họa ở hình 4, thuật toán Kernel k-means có thể phân tách khá hoàn hảo các cụm phi tuyến như cụm hình vòng cung. Tuy nhiên, với giới hạn chỉ có 3 lá, Kernel IMM chỉ có thể tạo ra các nhát cắt thô và ít khiến 1 phần của cụm vòng cung bị gán chung với 2 cụm ở bên trong dẫn đến sai số đáng kể. Các thuật toán với cơ chế tham lam như Kernel ExKMC và Kernel Expand sắp đề xuất sẽ có khả năng giải quyết những vấn đề mà Kernel IMM gặp phải bằng cách xây dựng cây quyết định thông qua việc thêm từng lá để tối ưu hóa chi phí.

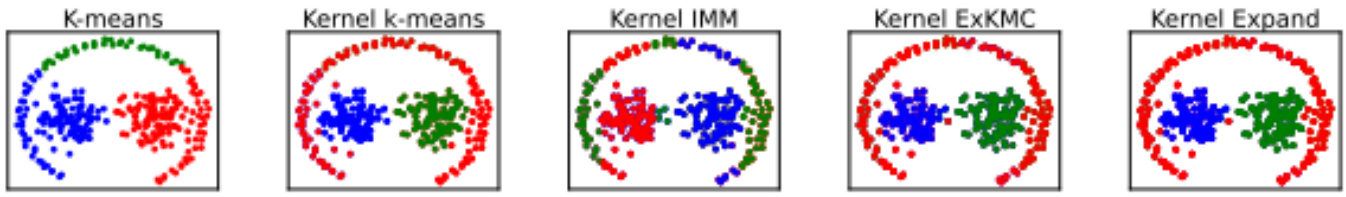

Hình 4: Thuật toán k-means tiêu chuẩn không phù hợp để phân cụm trên một số tập dữ liệu nhất định, ví dụ như *Pathbased*, trong khi đó Kernel k-means lại khôi phục tốt dữ liệu thực tế. Tuy nhiên, Kernel IMM không đủ mạnh để xấp xỉ các cụm ở dữ liệu thực do bị giới hạn ở 3 lá. Kernel ExKMC và Kernel Expand có thể khắc phục vấn đề này khi mở rộng cây lên 6 lá

4.5.2 Hàm mục tiêu của Kernel ExKMC và Kernel Expand

Kernel ExKMC: Thuật toán hoạt động tuần tự với mỗi nút u của cây quyết định và tập dữ liệu X^u của nút đó. Một ngưỡng cắt (threshold cut) tại chiều i với điểm ngưỡng là θ được chọn để tách X^u theo (i, θ) thành 2 tập con ở 2 bên điểm ngưỡng cắt với $X_L^u = X^u \cap x_i \leq \theta$ và $X_R^u = X^u \cap x_i > \theta$. Hàm mục tiêu của thuật toán Kernel ExKMC được tính dựa trên khoảng cách trong không gian đặc trưng như sau:

$$cost_{exkmc}(u, i, \theta) = \min_{j,l \in [k]} \sum_{x \in X_u^L} \|\psi(x) - c_j\|^2 + \sum_{x \in X_u^R} \|\psi(x) - c_l\|^2 \tag{10}$$

tức với mỗi nhát cắt (i, θ), cặp tâm tham chiếu (c_j, c_l) được chọn từ tập các tâm cụm k cho 2 nút con của u sao cho tổng bình phương khoảng cách từ các điểm dữ liệu đến các tâm tương ứng là nhỏ nhất.
Trong đó, khoảng cách từ các điểm đến các tâm cụm ở công thức (10) không yêu cầu tính toán trong không gian đặc trưng hay tính toán tường minh tâm cụm mà nhờ vào thủ thuật Kernel: Với các cụm $C_1, ..., C_k$ cùng tập $\mathcal{M} = \{c_1, ..., c_k\} \subset \mathcal{H}$ các tâm cụm tham chiếu thu được từ kernel k-means, bình phương khoảng cách giữa ảnh của điểm dữ liệu $\psi(x) \in \mathcal{H}$ trên bản đồ đặc trưng và tâm cụm c_l được tính thông qua hàm Kernel K theo công thức:

$$\|\psi(x) - c_l\|^2 = K(x, x) + \frac{1}{|C_l|^2} \sum_{y,z \in C_l} K(y, z) - \frac{2}{|C_l|} \sum_{y \in C_l} K(x, y) \tag{11}$$

Như vậy các phép tính liên quan trong (10) đều diễn ra trên dữ liệu đầu vào và cũng không yêu cầu bản đồ đặc trưng cụ thể ψ nào, thuật toán có thể áp dụng cho bất kỳ kernel K *tùy ý*.
Mỗi ngưỡng cắt (i^*, θ^*) tối ưu sẽ được chọn với mục tiêu tối thiểu hóa hàm mất mát (cost function) ở mỗi nút u. Để quyết định nút nào để phân chia, thuật toán Kernel ExKMC sẽ chọn dựa trên việc tối đa hóa khoảng cách giữa chi phí khi giữ nguyên nút - $\min_{j \in [k]} \sum_{x \in X^u} \|\psi(x) - c_j\|^2$ - so với khi tách nút - $cost_{exkmc}(u, i, \theta)$, tức là chọn nút nào sẽ làm giảm thiểu sai số nhiều nhất tại nút đó.
Ngoài ra, Kernel ExKMC còn có thể dùng để tinh chỉnh những cây quyết định đã có sẵn các cụm $\hat{C}_1, ..., \hat{C}_p$. Đặc biệt, nếu thuật toán được chạy để tinh chỉnh cho kết quả tạo ra từ Kernel IMM - một cây quyết định

sử dụng nhát cắt ngưỡng từ hai phía (two-side threshold cuts) theo định nghĩa 2, Kernel ExKMC cũng tuân thủ khái niệm diễn giải mở rộng này để đảm bảo tính nhất quán cấu trúc của Kernel IMM. Cụ thể, Kernel ExKMC chọn ngưỡng cắt tối ưu $(i, \theta_1, \theta_2) \in [d] \times \mathbb{R}^2$ thay vì ngưỡng đơn (i, θ) và sẽ kiểm tra xem x_i có thuộc khoảng $[\theta_1, \theta_2]$ hay không.

Kernel Expand: Thuật toán Kernel Expand tập trung đến việc tối đa hóa sự tinh khiết của từng nút lá trong cây, giúp cây quyết định có thể mô phỏng chính xác cấu trúc nhãn của mô hình phân cụm gốc thay vì giảm thiểu sai số khoảng cách như Kernel ExKMC. Điều này dẫn đến sự thay đổi của hàm mục tiêu nhằm tối thiểu hóa chi phí phân loại sai nhãn như sau:

$$cost_{exp}(i, \theta) = \min_{j,l \in [k]} (|\{x \in X_L^u : c(x) \neq c_j\}| + |\{x \in X_R^u : c(x) \neq c_l\}|) \tag{12}$$

Trong đó, $c(x)$ biểu thị cho tâm cụm thực tế của x theo $\mathcal{M}$. Hàm chi phí sẽ thực hiện đếm số lượng điểm dữ liệu bị gán sai nhãn ở 2 tập con X_L^u và X_R^u khi so sánh với tâm cụm đại diện c_j và c_l.

Thuật toán Kernel Expand quyết định nút để phân tách bằng cách chọn nút có khoảng cách tối đa giữa chi phí không tách nút - $\min_{j \in [k]} |\{x \in X^u : c(x) \neq c_j\}|$ - và $cost_{exp}(i, \theta)$.

4.5.3 Hiệu quả tính toán

Để tối ưu hóa hiệu suất, thuật toán Kernel ExKMC và Kernel Expand chỉ cần kiểm tra chi phí của các ngưỡng cắt (threshold cuts) tại nút mới được tạo ra trong mỗi bước chứ không cần tính toán lại ở toàn bộ cây. Do đó, việc thêm m lá vào cây hiện có p lá chỉ tốn $p + 2m$ vòng lặp duyệt qua các điểm cắt khả thi: Với lượt đầu duyệt p lá, mỗi lần tách nút sẽ mất 1 nút cha và thêm 2 nút con $\rightarrow$ thêm 1 nút và lần duyệt sau đó sẽ duyệt thêm 2 lần. Như vậy để thêm m nút thì sẽ duyệt thêm $2m$ lần.

4.5.4 Những vấn đề mà chiến lược tham lam gặp phải

Tuy nhiên, ta có thể chứng minh rằng nếu triển khai Kernel ExKMC với đầu vào là một cây rỗng thì sẽ không đảm bảo được khả năng xấp xỉ khi bị giới hạn với k lá, được phát biểu ở định lý 6.

Định lý 6. (ExKMC không thừa nhận các giới hạn trong trường hợp xấu nhất). Với bất kỳ số nguyên $m \in \mathbb{N}$, luôn tồn tại một tập dữ liệu $X \subset \mathbb{R}$ sao cho price of explainability trên X là $p(X) = 1$ khi IMM đạt được giá trị tối thiểu này, nhưng thuật toán ExKMC khi được khởi tạo trên một cây rỗng lại xây dựng nên một cây quyết định T với $p(T, X) \geq m$.

Tương tự với Kernel ExKMC, Kernel Expand không đảm bảo các giới hạn sai số trong trường hợp xấu nhất (worst-case bounds) nếu không khởi tạo từ kết quả của Kernel IMM. Lý do là Kernel Expand sẽ mắc phải hạn chế của các cây quyết định top-down tiêu chuẩn khi tách các cụm mật độ cao để giảm độ hỗn loạn mà vô tình tách đôi 1 cụm khác, khiến sai số phân cụm tăng không giới hạn [1]. Ngoài ra, ở thuật toán "tham lam"như Kernel ExKMC và Kernel Expand, cần có sự đánh đổi giữa khả năng diễn giải và

độ chính xác vì khi thêm nhiều lá hơn vào cây để cải thiện hiệu quả phân cụm thì cây cũng trở nên cồng kềnh và khó giải thích hơn.

4.6 Thuật toán

4.6.1 Kernel IMM

Thuật toán này là trái tim của bài báo, kết nối giữa Kernel K-means mạnh nhưng khó hiểu và Decision Trees dễ hiểu. Tác giả đề xuất mã giả quy trình như sau:

Algorithm 4 Kernel IMM cho các kernel Taylor có thể diễn giải hoặc kernel tích dựa trên khoảng cách

Input: Dữ liệu X, số nguyên k, kernel K với bản đồ đặc trưng thay thế ϕ. Đối với các kernel Taylor có thể diễn giải xem Định nghĩa 3, đối với các kernel dựa trên khoảng cách xem Phương trình 9.
Output: Cây quyết định có thể diễn giải T phân hoạch X thành k lá

Thu thập phân cụm tham chiếu $C_1, \ldots, C_k \leftarrow$ KERNEL k-MEANS(X, K, k)
Tính toán các đặc trưng thay thế $\Phi = [\phi_1(x) \ldots \phi_d(x)]$ và các tâm $\mathcal{M} = \{c_1, \ldots, c_k\}$ theo ϕ.
Xây dựng cây quyết định $T \leftarrow \text{IMM}(\Phi, y, \mathcal{M})$, trong đó y biểu thị gán nhãn cụm.
Chuyển đổi các vết cắt ngưỡng của T trở lại thành cây quyết định trên X.

Thuật toán Kernel IMM đóng vai trò trung tâm trong phương pháp đề xuất, hoạt động như một cầu nối chuyển đổi từ mô hình Kernel K-means (hiệu quả cao nhưng hộp đen) sang mô hình Cây quyết định (dễ dàng diễn giải). Quy trình này có thể được chia thành 4 bước chính như sau:

Bước 1: Tìm tham chiếu từ thuật toán phân lớp

- *Mục tiêu:* Xác định phân cụm tốt nhất có thể làm chuẩn.
- *Thực hiện:* Thuật toán bắt đầu bằng việc chạy Kernel K-means trên dữ liệu gốc X với kernel K đã chọn. Kết quả đầu ra là các nhãn cụm y (ground truth) đại diện cho cấu trúc dữ liệu mà chúng ta muốn mô hình cây quyết định sau này xấp xỉ lại.

Bước 2: Tính toán đặc trưng thay thế (Surrogate Features)

- *Mục tiêu:* Chuyển đổi bài toán từ không gian phi tuyến sang không gian tuyến tính cao chiều Φ.
- *Thực hiện:* Dựa vào loại kernel, ta áp dụng phép biến đổi ϕ phù hợp:
  - Với Gaussian Kernel: Sử dụng khai triển Taylor (Định nghĩa 3).
  - Với Laplace Kernel: Sử dụng phương pháp Cột mốc (Phương trình 4).

  Đồng thời, các tâm cụm $c_1, \ldots, c_k$ cũng được tính toán lại trong không gian mới này. Bước này tạo tiền đề quan trọng để các mô hình tuyến tính (như cây quyết định trục dọc) có thể hoạt động hiệu quả.

Bước 3: Xây dựng cây quyết định

- *Mục tiêu:* Tìm mô hình diễn giải xấp xỉ tốt nhất các tâm cụm M.
- *Thực hiện:* Sử dụng thuật toán **IMM (Iterative Mistake Minimization)** ở phần Kiến thức cơ sở 3.1.5 đề cập. Ưu điểm vượt trội của IMM là có các chứng minh toán học đảm bảo sai số tái tạo thấp (trong giới hạn $O(k^2)$).

Bước 4: Dịch ngược về không gian gốc (Translation)

- *Mục tiêu:* Chuyển đổi các luật phức tạp về dạng người dùng có thể hiểu.
- *Thực hiện:* Cây quyết định ban đầu T chứa các luât trên biến $\phi_{i,j}$ (ví dụ: $x^2e^{-x^2} > 0.5$). Nhờ vào tính chất đơn điệu từng khúc của các hàm đặc trưng thay thế được thiết kế, ta có thể giải ngược bất phương trình $\phi_{i,j}(x) > \theta$ để tìm ra khoảng giá trị tương ứng của x (ví dụ: $x \in [a, b]$). Kết quả cuối cùng là một tập hợp các luật `if-then` trên các biến đầu vào gốc, hoàn toàn minh bạch và dễ hiểu.

Tóm lại, quy trình này thực chất là một chiến lược *mượn đường*: thay vì đi trực tiếp từ dữ liệu gốc đến cây quyết định (khó khăn do tính chất phi tuyến), ta đi vòng qua Kernel K-means để lấy đáp án chuẩn, chuyển sang không gian Φ để dễ dàng xấp xỉ bằng IMM, và cuối cùng dịch ngược kết quả về lại ngôn ngữ tự nhiên bằng các luật.

4.6.2 Kernel ExKMC

Tác giả đề xuất mã giả quy trình ở thuật toán 5 như sau:

Algorithm 5 Kernel ExKMC

Input: Số lượng lá $m \in \mathbb{N}$, các tâm cụm tham chiếu $C_1, ..., C_k$, cây quyết định T với các lá $\hat{C}_1, ..., \hat{C}_p$ của cây
Output: Cây $\mathcal{L}$ với m lá

```
Khởi tạo tập hợp các lá L = {Ĉ_1, ..., Ĉ_p}
while |L| < m do
    Chọn nút X^u ∈ L và một ngưỡng cắt (i, θ) sao cho cực tiểu hóa hàm (10)
    Cập nhật L bằng cách thay thế X^u ∈ L bằng hai nút con X^u_L, X^u_R của nó
end while
```

Quy trình này có thể được chia thành 3 bước:

Bước 1: Khởi tạo tập hợp lá

- *Mục tiêu:* Thiết lập cấu trúc cây ban đầu dựa trên đầu vào (input).
- *Thực hiện:* Thuật toán bắt đầu với tập hợp các lá $L = \{\hat{C}_1, \ldots, \hat{C}_p\}$ thu được từ cây quyết định T. Đây là khung xương cơ bản để thuật toán tiếp tục mở rộng nhằm đạt được độ chính xác cao hơn.

Bước 2: Lựa chọn nút và ngưỡng chia tối ưu

- *Mục tiêu:* Xác định vị trí phân tách dữ liệu giúp giảm thiểu sai số tái tạo nhiều nhất.
- *Thực hiện:* Trong mỗi vòng lặp, thuật toán duyệt qua các nút lá hiện có $X_u \in L$ và chưa được duyệt. Với mỗi nút, ta tìm kiếm một cặp chiều và ngưỡng cắt (i, θ) sao cho giá trị hàm mục tiêu (10) là nhỏ nhất.

Bước 3: Phân tách và mở rộng cây

- *Mục tiêu:* Tăng số lượng lá của cây cho đến khi đạt số lượng lá tối đa m.
- *Thực hiện:* Sau khi tìm được điểm cắt tối ưu, nút X_u sẽ được thay thế bằng hai nút con mới là X_u^L và X_u^R. Quá trình này lặp lại cho đến khi số lượng lá $|L|$ chạm ngưỡng m (với $m \geq k$). Việc mở rộng này cho phép mô hình linh hoạt hơn trong việc bao phủ các vùng dữ liệu phức tạp.

4.6.3 Kernel Expand

Tác giả đề xuất mã giả quy trình ở thuật toán 6 như sau:

Algorithm 6 Kernel Expand

Input: Số lượng lá $m \in \mathbb{N}$, các tâm cụm tham chiếu $C_1, ..., C_k$, cây quyết định T với các lá $\hat{C}_1, ..., \hat{C}_p$ của cây
Output: Cây $\mathcal{L}$ với m lá
  Khởi tạo tập hợp các lá $\mathcal{L} = \{\hat{C}_1, ..., \hat{C}_p\}$
  while $|\mathcal{L}| < m$ **do**
    Chọn tập dữ liệu $X^u \in \mathcal{L}$ tại một nút lá và một ngưỡng cắt (i, θ) sao cho cực tiểu hóa hàm (12)
    Cập nhật $\mathcal{L}$ bằng cách thay thế $X^u \in \mathcal{L}$ bằng hai nút con X_L^u, X_R^u của nó
  end while

Quy trình này có thể được chia thành 3 bước:

Bước 1: Khởi tạo tập hợp lá

- *Mục tiêu:* Thiết lập cấu trúc cây ban đầu dựa trên đầu vào (input).
- *Thực hiện:* Thuật toán bắt đầu với tập hợp các lá $L = \{\hat{C}_1, \ldots, \hat{C}_p\}$ thu được từ cây quyết định T. Đây là khung xương cơ bản để thuật toán tiếp tục mở rộng nhằm đạt được độ chính xác cao hơn.

Bước 2: Lựa chọn nút và ngưỡng chia tối ưu

- *Mục tiêu:* Xác định vị trí phân tách dữ liệu giúp giảm thiểu sai số tái tạo nhiều nhất.
- *Thực hiện:* Trong mỗi vòng lặp, thuật toán duyệt qua các nút lá hiện có $X_u \in L$ và chưa được duyệt. Với mỗi nút, ta tìm kiếm một cặp chiều và ngưỡng cắt (i, θ) sao cho giá trị hàm mục tiêu (12) là nhỏ nhất.

Bước 3: Phân tách và mở rộng cây

- *Mục tiêu:* Tăng số lượng lá của cây cho đến khi đạt số lượng lá tối đa m.
- *Thực hiện:* Sau khi tìm được điểm cắt tối ưu, nút X_u sẽ được thay thế bằng hai nút con mới là X_u^L và X_u^R. Quá trình này lặp lại cho đến khi số lượng lá $|L|$ chạm ngưỡng m (với $m \geq k$). Việc mở rộng này cho phép mô hình linh hoạt hơn trong việc bao phủ các vùng dữ liệu phức tạp.

5 Phân tích thực nghiệm

Thực nghiệm chính được tiến hành cho Laplace hay Gaussian kernel với các thuật toán Kernel IMM, Kernel ExKMC, Kernel Expand được đề xuất và kết quả được so sánh với CART. Ngoài ra, thực nghiệm cũng thực hiện đánh giá cho additive χ^2 kernel, một kernel phù hợp cho phân cụm histogram hay distribution.

5.1 Tập dữ liệu

Thực nghiệm chính: Thuật toán được kiểm chứng trên các tập dữ liệu tiêu chuẩn, bao gồm:

- Tập dữ liệu tổng hợp cho bài toán phân cụm: *Pathbased*, *Aggregration* và *Flame* [4]. Với các đặc điểm hình học phức tạp và phi tuyến của dữ liệu trong không gian 2 chiều, bài toán có thể kiểm chứng khả năng của các phương pháp được đề xuất và có thể trực quan hóa kết quả phân cụm để so sánh.
  - Tập dữ liệu *Pathbased* được minh họa trong hình 5 có 300 điểm dữ liệu với $k = 3$ cụm: 1 cụm vòng cung không khép kín bao bọc bên ngoài và 2 cụm có phân phối Gaussian nằm bên trong, trong đó các điểm nhiễu có xu hướng kết nối các cụm với nhau, làm ranh giới giữa chúng không rõ ràng và gây khó khăn trong phân cụm.

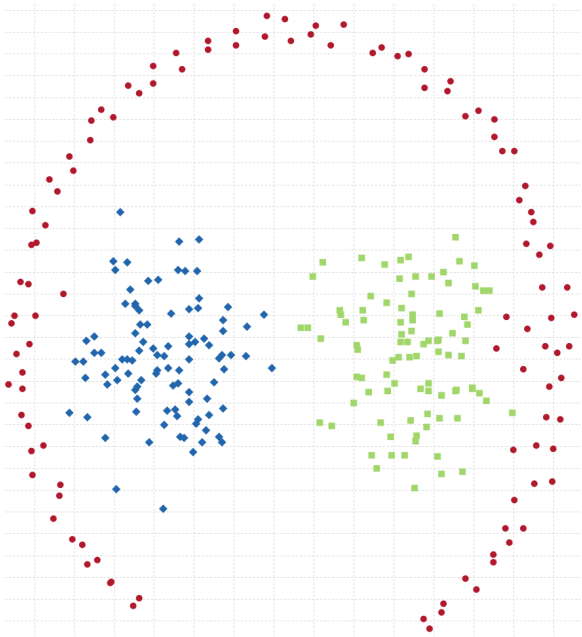

Hình 5: Minh họa trực quan tập dữ liệu *Pathbased*

– Tập dữ liệu *Aggregation* được minh họa trong hình 6 có 788 điểm dữ liệu với $k = 7$ cụm với các cầu nối hẹp giữa các cụm gây khó khăn cho các thuật toán phân cụm theo khoảng cách, cùng với sự không đồng đều về kích thước và mật độ giữa các cụm.

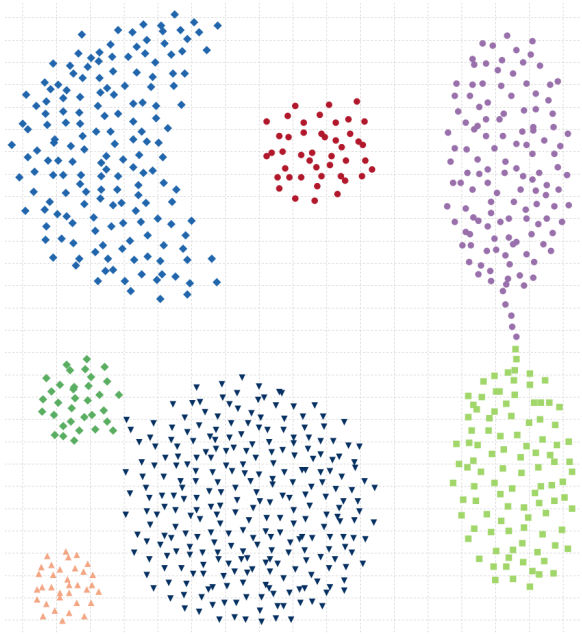

Hình 6: Minh họa trực quan tập dữ liệu *Aggregation*

– Tập dữ liệu *Flame* được minh họa trong hình 7 có 240 điểm dữ liệu với $k = 2$ cụm được phân theo mật độ, có hình dạng ngọn lửa với ranh giới không rõ rệt gây khó khăn cho các thuật toán.

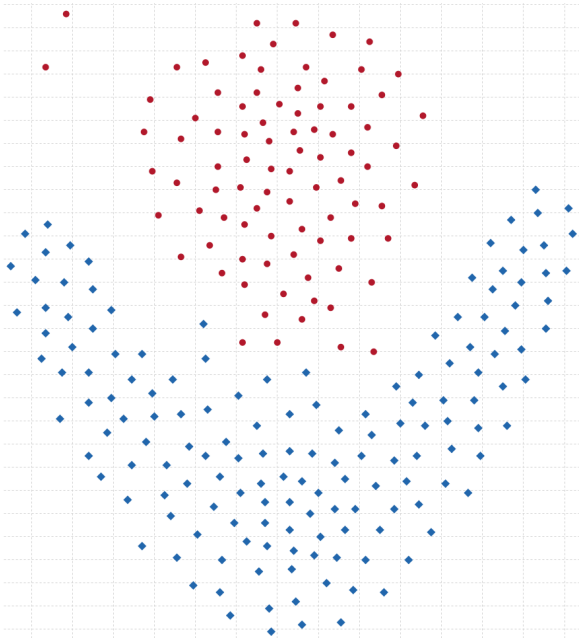

Hình 7: Minh họa trực quan tập dữ liệu *Flame*

- Tập dữ liệu thực tế *Iris* [5] có 150 mẫu và 4 đặc trưng về kích thước của đài hoa và cánh hoa, được chia thành 3 lớp với 50 mẫu mỗi lớp, tương ứng với 1 loại cây diên vĩ. Trong các lớp chỉ có 1 lớp có thể phân tách tuyến tính rõ ràng, phù hợp để kiểm chứng thuật toán với dữ liệu có tính phi tuyến.

- Tập dữ liệu thực tế *Wisconsin breast cancer* [6] bao gồm 569 mẫu quan sát về tế bào ung thư vú lành tính (benign) - 357 mẫu và ác tính (maligant) - 212 mẫu. Dữ liệu có 30 đặc trưng, mô tả các đặc điểm của nhân tế bào được quan sát trong từng ảnh. Số chiều lớn và các đặc điểm phi tuyến của hình ảnh trong dữ liệu giúp kiểm chứng tổng quát về khả năng phân tách và giải thích cao cho dữ liệu chẩn đoán y khoa.

Thực nghiệm cho χ^2 kernel: Tập dữ liệu giả lập thu được từ mô hình hỗn hợp của 4 phân phối rời rạc, với các giá trị nằm trong 4 nhóm (bins). Hình 8 cho thấy biểu đồ của các phân phối khác nhau. Đối với cả 4 phân phối, thực hiện 5 lần lấy 100 mẫu ngẫu nhiên, sau đó tính toán tỉ lệ xuất hiện trong mỗi bin cho mỗi lần thực hiện, do đó $n = 20$ và $d = 4$. Quy trình này được lặp lại 100 lần.

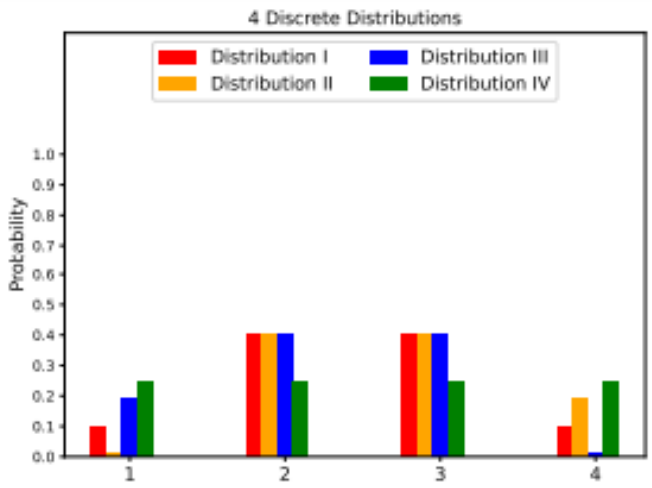

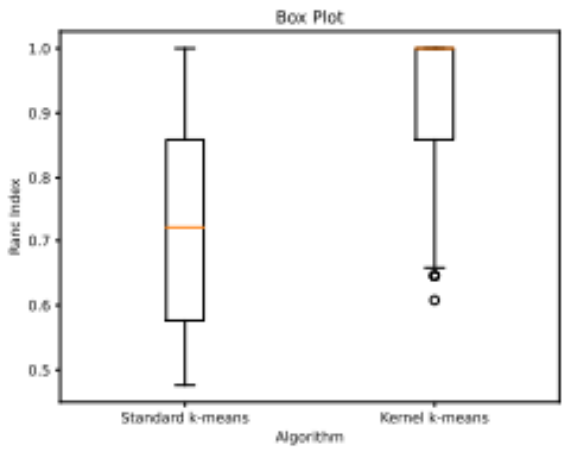

Hình 8: Mô hình hỗn hợp của 4 phân phối rời rạc được phân cụm bằng cách kiểm tra tỉ lệ xuất hiện trong từng nhóm (bin). Các xác suất thực tế được thể hiện ở biểu đồ bên trái. Sau 100 lần lấy mẫu, thuật toán sử dụng χ^2 kernel, ở đây là kernel k-means, có kết quả tốt hơn với k-means thông thường, được thể hiện ở biểu đồ hộp bên phải.

5.2 Quy trình thực nghiệm

Quy trình thực hiện các **thực nghiệm chính** như sau:

- Quy trình bắt đầu với thuật toán k-means tuyến tính trên dữ liệu và IMM trên kết quả của k-means.
- Sau đó chạy kernel k-means với cả 2 kernel Laplace và Gaussian cùng các giá trị siêu tham số γ khác nhau để chọn ra kernel và γ có kết quả tốt nhất làm đầu vào cho Kernel IMM.
- Nếu kernel Laplace được chọn, Kernel IMM được chạy với các đặc trưng thay thế từ ma trận kernel. Ngược lại, trong trường hợp Gaussian Kernel được chọn, thuật toán sẽ được chạy trên cả các đặc trưng thay thế sử dụng khai triển Taylor với $M = 5$, và các đặc trưng thay thế dựa trên ma trận kernel để chọn ra kết quả tốt hơn.
- Tinh chỉnh kết quả được tạo ra từ Kernel IMM bằng thuật toán Kernel ExKMC và Kernel Expand, với số lá tối đa của các tập dữ liệu *Pathbased*, *Aggregation*, *Flame*, *Iris* và *Wisconsin breast cancer* lần lượt là $m = 6$, $m = 10$, $m = 4$, $m = 6$ và $m = 4$.
- Cuối cùng, kết quả từ Kernel IMM được so sánh với kết quả từ CART, một thuật toán tạo cây quyết định tiêu chuẩn.

5.3 Thước đo đánh giá

5.3.1 Chỉ số Price of Explainabilty (PoE)

Khái niệm "Price of Explainability"(PoE) là tỉ lệ chi phí sai số của 1 cây quyết định có khả năng giải thích so với sai số của các thuật toán phức tạp, tối ưu như Kernel k-means. Giá trị của thang đo này càng gần 1 thì cây quyết định có tính diễn giải càng có độ chính xác cao.
Định nghĩa: Đối với 1 tập hợp $X \subset \mathbb{R}^d$ và 1 cây quyết định T có tính diễn giải, giá trị PoE của T trên tập X được định nghĩa như sau:

$$p(T, X) = \frac{\text{cost}(T, X)}{\text{cost}_{\text{opt}}(X)}$$

với $\text{cost}(T, X)$ là chi phí sai số của việc phân cụm bằng cây quyết định T; $\text{cost}_{\text{opt}}(X)$ là chi phí tối ưu của mô hình Kernel k-means.

5.3.2 Chỉ số Adjusted Rand Index

Rand Index: Chỉ số Rand Index [7] là thước đo sự tương đồng giữa các kết quả phân cụm dữ liệu trong thống kê, tức tỉ lệ giữa các cặp dữ liệu đồng thuận, được phân loại như nhau ở cả hai kết quả phân cụm so với tổng số cặp của dữ liệu.
Định nghĩa: Cho 1 tập hợp X và hai kết quả phân cụm của chúng, với $\mathcal{C} = \{C_1, \ldots, C_r\}$ chia X thành r tập con, và $\mathcal{C}' = \{C'_1, \ldots, C'_s\}$ chia X thành s tập con, ta có:

- a là số cặp của các phần tử trong X mà đều nằm **cùng** 1 tập con trong cả $\mathcal{C}$ và $\mathcal{C}'$
- b là số cặp của các phần tử trong X mà nằm **khác** tập con trong cả $\mathcal{C}$ và $\mathcal{C}'$
- c là số cặp của các phần tử trong X mà nằm **cùng** tập con trong $\mathcal{C}$ nhưng **khác** tập con trong $\mathcal{C}'$
- d là số cặp của các phần tử trong X mà nằm **khác** tập con trong $\mathcal{C}$ nhưng **cùng** tập con trong $\mathcal{C}'$

Giá trị Rand Index, R, được định nghĩa như sau:

$$R = \frac{a + b}{a + b + c + d} = \frac{a + b}{\binom{n}{2}}$$

Adjusted Rand Index: Bởi vì giá trị kì vọng của Rand Index không cố định, ta không thể đánh giá được kết quả phân cụm tốt hay không khi chỉ dựa vào giá trị Rand Index. Chỉ số Adjusted Rand Index [8] là phiên bản được điều chỉnh cho yếu tố ngẫu nhiên của Rand Index dựa trên giả định các cụm được tạo ngẫu nhiên với số lượng nhóm và kích thước cụm cố định.
Định nghĩa: Giá trị Adjusted Rand Index, R_{adj}, được định nghĩa là phiên bản chuẩn hóa của Rand Index như sau:

$$R_{adj} = \frac{R - \mathbb{E}[R]}{\max(R) - \mathbb{E}[R]}$$

Giá trị của chỉ số càng cao và càng gần 1 thì thuật toán phân cụm đưa ra kết quả càng giống với các cụm thực (ground truth).

5.4 Kết quả

Kết quả ở thực nghiệm chính: Mặc dù Kernel IMM có thể đưa ra kết quả chưa tối ưu vì giới hạn số lượng lá - với Price of Explainability luôn cao nhất trong 3 thuật toán đề xuất, các phương pháp tinh chỉnh bằng cơ chế thêm lá 1 cách tham lam đã tạo ra cây quyết định vừa dễ hiểu vừa giữ được độ chính xác của mô hình Kernel k-means. Giá trị PoE quan sát được trên hình 9 ở các tập dữ liệu cho thấy thuật toán Kernel ExKMC và Kernel Expand hầu như giảm sai sót gần đến mức tối ưu khi giá trị của chúng giảm xuống gần bằng 1; đặc biệt ghi nhận sự giảm đi rõ rệt trên tập dữ liệu *Pathbased*, chứng minh sức mạnh của việc tinh chỉnh ở 2 thuật toán này. Ta cũng có thể nhìn thấy kết quả của tập *Pathbased* được minh họa trực quan ở hình 4 khi thành phẩm tinh chỉnh của Kernel ExKMC và Kernel Expand có thể mô phỏng Kernel k-means rất tốt nhờ việc thêm lá vào cây quyết định từ Kernel IMM.
Khi so với thuật toán k-means thông thường, kernel k-means đạt kết quả vượt trội hơn hẳn theo giá trị Rand Index được quan sát ở hình 9; và 3 thuật toán được đề xuất cũng xấp xỉ tốt giá trị thực tế của dữ liệu, đặc biệt có thể quan sát được thuật toán Kernel ExKMC và Kernel Expand hầu như đạt giá trị Rand Index tương đương với kernel k-means. Ngoài ra, tuy thuật toán Kernel IMM đôi khi chưa đưa ra kết quả tối ưu với Rand Index thấp hơn, thuật toán này vẫn cải thiện độ chính xác so với k-means và IMM trong phân cụm dữ liệu thực tế. Những kết quả này khẳng định khả năng của các thuật toán trong việc phân cụm dữ liệu.

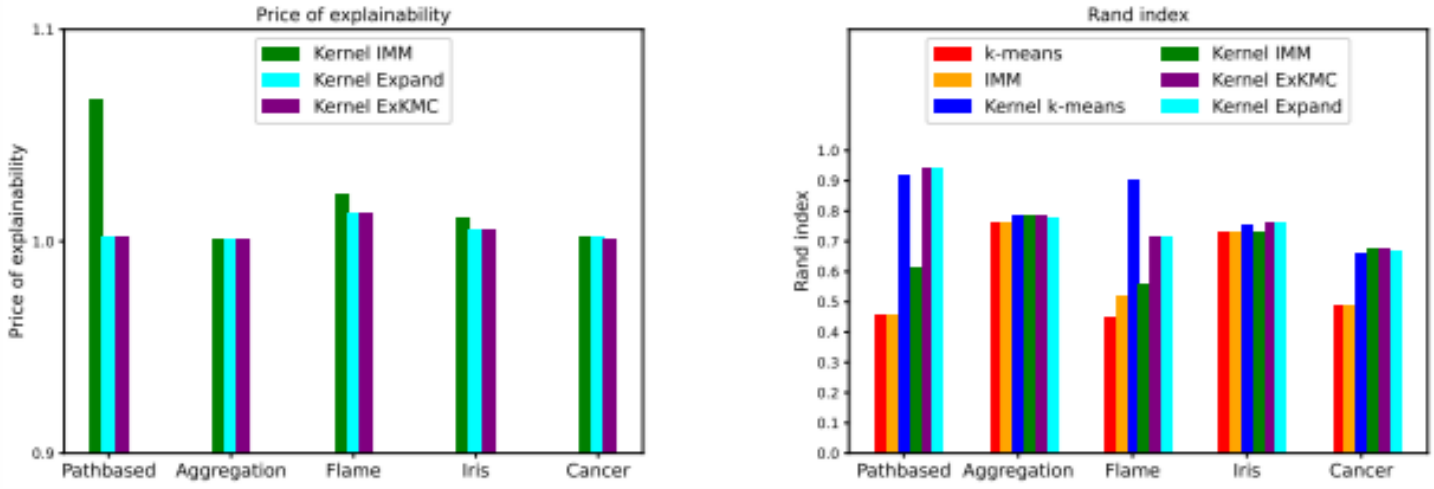

Hình 9: Kiểm chứng khả năng xấp xỉ của các thuật toán đề xuất theo thang đo Price of Explainability (biểu đồ bên trái). So sánh các cụm thu được từ các thuật toán k-means, IMM, kernel k-means và 3 thuật toán đề xuất với dữ liệu thực tế thông qua Rand Index (biểu đồ bên phải).

Kết quả ở thực nghiệm cho χ^2 kernel: Thuật toán sử dụng χ^2 kernel luôn đạt được giá trị Rand Index cao hơn k-means thông thường, cụ thể với kernel k-means như trong hình 8 cho kết quả vượt trội với Rand Index luôn tập trung ở gần 1.0, và cũng có thể triển khai tốt với Kernel IMM. Đó là vì mẫu số của χ^2 kernel tính đến tổng số quan sát trong mỗi nhóm (bin), cũng như là phạt sai lệch nhiều hơn ở những bin ít xuất hiện hơn - đây là đặc tính phi tuyến tính mà k-means tiêu chuẩn còn thiếu. Kết quả nhấn mạnh tính hữu ích và tổng quát của các phương pháp đề xuất đã vượt ra ngoài phạm vi của các kernel tích dựa trên khoảng cách.

Kết quả so sánh với CART: Trong kết quả thực nghiệm được ghi nhận ở bảng 3, thuật toán CART có kết quả khá chính xác và tương đồng với Kernel IMM một cách bất ngờ khi PoE của chúng rất gần nhau, dù chưa có cơ sở thông tin đảm bảo CART có thể có kết quả xấp xỉ tốt trong bài toán phân cụm k-means tiêu chuẩn. Đáng chú ý, đối với tập dữ liệu *Wisconlin breast cancer*, CART thậm chí còn cải thiện kết quả phân cụm tốt hơn so với thuật toán tối ưu kernel k-means khi Price of Explainabity nhỏ hơn 1.

Tập dữ liệu	Kernel	PoE (Kernel IMM)	PoE (CART)
Pathbased	Gaussian	**1.06645**	1.07004
Aggregation	Laplace	**1.00125**	**1.00125**
Flame	Gaussian	**1.02256**	1.02732
Iris	Laplace	**1.00502**	**1.00502**
Cancer	Gaussian	1.00179	**0.99330**

Bảng 3: So sánh Price of Explainability giữa Kernel IMM và CART với các nhát cắt 1 phía cùng k lá. Cả 2 phương pháp đều giữ được độ chính xác cao và tương đương, trong đó CART đạt được giá trị tối ưu và ngang bằng với Kernel IMM ở các tập dữ liệu dùng Laplace Kernel.

6 Minh họa cài đặt

6.1 Môi trường thực nghiệm

Môi trường thực nghiệm:

- **Công cụ triển khai:** Jupyter Notebook triển khai trên local.
- **Ngôn ngữ lập trình:** Python 3.12.7
- **Thư viện hỗ trợ:**
  - `NumPy`: dùng để tính toán trên các ma trận.
  - `Matplotlib`: dùng để trực quan hóa cấu trúc của các kết quả từ các thuật toán.
  - `Pandas`: dùng để đọc và quản lý các tập dữ liệu
  - `Scikit-learn`: dùng để tính toán ma trận Kernel h.ay cung cấp một số tập dữ liệu, độ đo đánh giá hay thuật toán.

Tập dữ liệu sử dụng: Pathbased, Aggregation, Flame; Iris và Wisconsin Breast Cancer được cung cấp từ thư viện `Scikit-learn`.
Thước đo đánh giá kết quả:

- Price of Explainability với chi phí được triển khai theo công thức:

$$
\begin{aligned}
Cost(T) &= \sum_{i=1}^{k} Cost(C_k) \\
&= \sum_{i=1}^{k} (\sum_{x \in C_k} (K(x,x) + \frac{1}{|C_k|^2} \sum_{y,z \in C_k} K(y,z) - \frac{2}{|C_k|} \sum_{y \in C_k} K(x,y))) \\
&= \sum_{i=1}^{k} (\sum_{x \in C_k} K(x,x) + |C_k| \frac{1}{|C_k|^2} \sum_{y,z \in C_k} K(y,z) - \frac{2}{|C_k|} \sum_{x,y \in C_k} K(x,y)) \\
&= \sum_{i=1}^{k} (\sum_{x \in C_k} K(x,x) + \frac{1}{|C_k|} \sum_{y,z \in C_k} K(y,z) - \frac{2}{|C_k|} \sum_{y,z \in C_k} K(y,z)) \\
&= \sum_{i=1}^{k} (\sum_{x \in C_k} K(x,x) - \frac{1}{|C_k|} \sum_{y,z \in C_k} K(y,z))
\end{aligned}
$$

- Adjusted Rand Index được cung cấp trong thư viện `Scikit-learn`.

Tham số tính toán:

- Kernel sử dụng: Nhóm triển khai trên Gaussian và Laplace Kernel và lựa chọn loại Kernel đem lại kết quả tốt cho từng tập dữ liệu.
- Siêu tham số `gamma` γ: được dùng để tính trên ma trận kernel và được tinh chỉnh (tuning) qua nhiều lần thử nghiệm với nhiều giá trị khác nhau, trong phần triển khai của nhóm chỉ chạy với 1 giá trị tối ưu cho một số tập dữ liệu để giảm bớt thời gian chạy.
- Tham số $M = 5$: là bậc xấp xỉ Taylor khi dùng cho Gaussian Kernel.
- Số lượng cụm k: tùy thuộc vào từng dữ liệu (như *Pathbased* với $k = 3$, *Aggregation* với $k = 7$, *Flame* với $k = 2$, *Iris* với $k = 3$, *Wisconsin Breast Cancer* với $k = 2$)
- Số lượng lá tối đa của cây `max_leaves`: được thiết lập dựa vào từng dữ liệu (như *Pathbased* với $m = 6$, *Aggregation* với $m = 10$, *Flame* với $m = 4$, *Iris* với $m = 6$, *Wisconsin Breast Cancer* với $m = 4$)

6.2 Mã giả cài đặt

Bên cạnh các thuật toán cốt lõi đã trình bày ở phần 4 (Kernel IMM, Kernel ExKMC và Kernel Expand) hay các thuật toán cơ sở về phân cụm như ở phần 3 (IMM, Kernel k-means), việc hiện thực hóa phương pháp còn đòi hỏi một hệ thống các hàm phụ trợ để xử lý dữ liệu, lựa chọn tham số tối ưu và đánh giá kết quả. Trong phần này, tôi xin trình bày mã giả và phân tích các hàm quan trọng trong pipeline thực nghiệm, bao gồm: lựa chọn siêu tham số, cài đặt Kernel K-means cơ sở, và quy trình tinh chỉnh kết quả.

6.2.1 Cài đặt Xấp xỉ Taylor

Đối với Gaussian Kernel, thay vì tính toán trên ma trận Kernel đầy đủ (chi phí $O(N^2)$), chúng ta có thể xấp xỉ không gian đặc trưng bằng chuỗi Taylor hữu hạn. Hàm `taylor_imm` thực hiện việc chuyển đổi dữ liệu gốc sang không gian đặc trưng xấp xỉ Φ và chạy IMM trên đó.

Algorithm 7 Xấp xỉ Taylor cho Gaussian Kernel (taylor_imm)

Input: X (Dữ liệu $N \times d$), y (Nhãn từ Kernel K-means), γ, $features_per_dim$ (M - số bậc xấp xỉ), $check_all_cuts$
Output: $y_imm, threshold_cuts$

```
true_k ← số lượng nhãn duy nhất trong y
Khởi tạo ma trận đặc trưng Φ kích thước N × (d · features_per_dim)
for i = 0 to d − 1 do
    for n = 0 to N − 1 do
        for j = 0 to features_per_dim − 1 do
            Tính thành phần Taylor thứ j cho chiều thứ i:
            Φ[n, i · features_per_dim + j] = √((2γ)^j) / √(j!) · x_{n,i}^j · e^{−γ x_{n,i}^2}
        end for
    end for
end for
Tính tâm cụm taylor_centers trong không gian Φ dựa trên nhãn y
y_imm, threshold_cuts ← IMM(Φ, y, taylor_centers, check_all_cuts)
return y_imm, threshold_cuts
```

Kỹ thuật này cho phép áp dụng IMM hiệu quả trên các tập dữ liệu lớn bằng cách phân rã quá trình tính toán qua 3 bước:

Bước 1: Chuyển đổi đặc trưng

- *Mục tiêu:* Ánh xạ dữ liệu từ không gian gốc $\mathbb{R}^d$ sang không gian xấp xỉ $\mathbb{R}^{d \times m}$.
- *Thực hiện:* Với mỗi chiều i của dữ liệu và mỗi bậc j (từ 0 đến $m-1$), ta tính toán đặc trưng mới dựa trên công thức khai triển Taylor của hàm mũ. Việc này được thực hiện độc lập cho từng điểm dữ liệu, do đó độ phức tạp chỉ là $O(N \cdot d \cdot m)$, tuyến tính với số lượng điểm dữ liệu, hiệu quả hơn nhiều so với $O(N^2)$ của ma trận Kernel.

Bước 2: Tính toán Tâm cụm

- *Mục tiêu:* Xác định vị trí các tâm cụm trong không gian mới Φ.
- *Thực hiện:* Tương tự như K-Means thường, ta tính trung bình các vector đặc trưng Φ thuộc cùng một cụm (dựa trên nhãn y đầu vào từ bước Kernel K-Means trước đó). Các tâm $taylor_centers$ này sẽ đóng vai trò là các mỏ neo để thuật toán IMM tìm kiếm các nhát cắt phân tách.

Bước 3: Xây dựng cây với IMM

- *Mục tiêu:* Tìm các ngưỡng quyết định trên các đặc trưng Taylor.

- *Thực hiện:* Gọi thuật toán IMM tiêu chuẩn trên dữ liệu Φ và các tâm $taylor_centers$. Vì Φ là không gian Euclide, IMM có thể hoạt động trực tiếp. Kết quả trả về là cấu trúc cây và các ngưỡng cắt trên các biến Taylor (ví dụ: cắt trên thành phần $x^2e^{-\gamma x^2}$).

6.2.2 Quy trình Thực nghiệm Tổng thể

Hàm `imm_experiments` là trái tim của quá trình đánh giá thực nghiệm, đóng vai trò kết nối và so sánh trực tiếp hiệu quả giữa các phương pháp phân cụm tuyến tính truyền thống và phương pháp Kernel IMM đề xuất.

Algorithm 8 Quy trình Thực nghiệm (imm_experiments)

Input: Tập dữ liệu X, nhãn thật y_{true}, danh sách tham số Γ.
Output: Các chỉ số đánh giá $(Rand, PoE)$ và cấu trúc cây quyết định.

```
Thiết lập kết quả cơ sở (Baseline): y_base ← K-MEANS(X); T_base ← IMM(X, y_base)
Tối ưu hóa tham số Kernel: γ*, K* ← GRID-SEARCH(X, y_true, Γ)
Tạo phân cụm mục tiêu trên không gian Kernel: y_target ← KERNEL-K-MEANS(X, K*, γ*)
if K* là Gaussian Kernel then
    Xấp xỉ Taylor: T_approx ← TAYLOR-IMM(X, y_target, γ*)
else (K* là Laplace Kernel)
    Chính xác (Exact): T_exact ← KERNEL-MATRIX-IMM(X, y_target, γ*)
end if
Tính toán các chỉ số Rand Index, PoE cho T_approx, T_exact so với y_target
return Báo cáo tổng hợp kết quả
```

Quy trình thực nghiệm được thiết kế chặt chẽ qua 4 bước chính để đảm bảo tính công bằng và toàn diện trong so sánh:

Bước 1: Thiết lập đường cơ sở

- *Mục tiêu:* Xác định hiệu suất của các phương pháp tuyến tính truyền thống để làm mốc so sánh.
- *Thực hiện:* Chạy K-Means chuẩn trên dữ liệu gốc X để lấy kết quả phân cụm cơ bản. Sau đó, áp dụng IMM ngay trên kết quả này. Nếu dữ liệu có cấu trúc phi tuyến phức tạp, các phương pháp này thường sẽ có điểm số Rand Index thấp, chứng minh nhu cầu cần thiết của phương pháp Kernel.

Bước 2: Tối ưu hóa tham số Kernel

- *Mục tiêu:* Tìm cấu hình Kernel tốt nhất cho bộ dữ liệu cụ thể.
- *Thực hiện:* Sử dụng hàm `get_hyperparam` để quét qua các giá trị γ và loại kernel (RBF hoặc Laplace). Cấu hình cho điểm Rand Index cao nhất sẽ được chọn làm môi trường chuẩn cho các bước tiếp theo.

Bước 3: Tạo phân cụm tham chiếu, mục tiêu

- *Mục tiêu:* Tạo ra bộ nhãn "chuẩn"trong không gian Kernel để các biến thể IMM cố gắng xấp xỉ.
- *Thực hiện:* Chạy thuật toán Kernel K-Means với tham số tối ưu vừa tìm được. Kết quả y_{kkm} này được xem là giới hạn trên (upper bound) về độ chính xác mà các phương pháp xấp xỉ cây quyết định có thể đạt được.

Bước 4: So sánh các biến thể IMM

- *Mục tiêu:* Đánh giá khả năng xấp xỉ và độ phức tạp của model.
- *Thực hiện:*
  - **Taylor IMM:** Nếu sử dụng Gaussian Kernel, ta chạy Taylor IMM. Đây là phương pháp xấp xỉ nhanh, sử dụng các đặc trưng đa thức.
  - **Exact Kernel IMM:** Chạy IMM trực tiếp trên ma trận Kernel. Phương pháp này chính xác hơn nhưng tốn kém chi phí tính toán hơn.

  Kết quả cuối cùng bao gồm cả độ chính xác (Rand Score) và "giá phải trả"(Price of Explainability - PoE) của từng phương pháp.

Tóm lại, quy trình này không chỉ đo lường con số chính xác cuối cùng mà còn cho thấy bức tranh toàn cảnh: từ giới hạn của phương pháp tuyến tính, tiềm năng của phương pháp Kernel, đến sự đánh đổi giữa các chiến lược xấp xỉ khác nhau.

6.2.3 Quy trình Tinh chỉnh và Đánh giá

Sau khi có cây quyết định ban đầu từ IMM (y_{imm}), chúng ta cần một quy trình để: (1) Áp dụng các thuật toán mở rộng (ExKMC, Expand) nhằm cải thiện kết quả, và (2) Tính toán các chỉ số đánh giá như Rand Score và Price of Explainability (PoE).

Algorithm 9 Tinh chỉnh và Đánh giá (refine_imm)

Input: X, y_true, y_kkm (Nhãn Kernel K-means), y_imm (Nhãn IMM), $Kmat$, max_leaves
Output: $results$ (Các chỉ số PoE, Rand), $labels$ (Nhãn sau tinh chỉnh)

Xây dựng cây mở rộng ExKMC: $T_{exkmc} \leftarrow$ ExKMC-BUILD-ON-IMM$(X, y_{imm}, \mathcal{K})$
Gán nhãn tối ưu chi phí cho các lá của ExKMC: $y_{exkmc} \leftarrow \arg\min_l \sum_{C \in Leaves(T_{exkmc})} \text{Cost}(C, l)$
Xây dựng cây mở rộng Expand: $T_{expand} \leftarrow$ EXPAND-BUILD-ON-IMM(X, y_{imm})
Gán nhãn tối ưu sai số cho các lá của Expand (Majority Voting): $y_{expand} \leftarrow$ VOTE(T_{expand}, y_{kkm})
Tính toán chỉ số Rand Index và PoE cho y_{exkmc}, y_{expand}
return Kết quả so sánh

Quy trình tinh chỉnh là lá chắn cuối cùng để đảm bảo cây quyết định không chỉ dễ hiểu mà còn phải hiệu quả, được thực hiện qua 3 chiến lược:

Bước 1: Tinh chỉnh dựa trên hàm chi phí (Kernel ExKMC)

- *Mục tiêu:* Giảm thiểu hàm mục tiêu gốc của bài toán phân cụm (Kernel K-Means objective).
- *Thực hiện:* Sử dụng thuật toán tham lam ExKMC để mở rộng thêm các nút lá từ cây IMM ban đầu. Tại mỗi bước, thuật toán chọn cắt nút lá nào mang lại sự giảm thiểu lớn nhất về chi phí phân cụm (Cost Delta). Đây là cách tiếp cận hướng tới bản chất toán học của bài toán.

Bước 2: Tinh chỉnh dựa trên sai số (Expanding IMM)

- *Mục tiêu:* Giảm thiểu trực tiếp số lượng điểm dữ liệu bị phân loại sai so với nhãn mục tiêu từ Kernel K-Means (y_{kkm}).
- *Thực hiện:* Tương tự như ExKMC nhưng hàm đơn mục tiêu thay đổi. Thay vì tính Cost Delta, thuật toán Expand chọn nhát cắt giúp giảm tối đa số lượng điểm lệch nhãn so với y_{kkm}. Cách tiếp cận này thực dụng hơn, hướng tới tối ưu hóa chỉ số Accuracy/Rand Score.

Bước 3: Tổng hợp chỉ số

- *Mục tiêu:* Định lượng sự đánh đổi giữa tính dễ hiểu và độ chính xác.
- *Thực hiện:* Với mỗi kết quả cây (ExKMC cây và Expand cây), ta tính hai chỉ số cốt lõi:
  - **Rand Score:** Đo lường độ chính xác so với nhãn thật (y_{true}).
  - **Price of Explainability (PoE):** Tỷ lệ giữa chi phí của cây quyết định so với chi phí tối ưu của Kernel K-Means ($Cost_{tree}/Cost_{kkm}$). PoE càng gần 1.0 nghĩa là ta diễn giải được mô hình mà không làm giảm đáng kể hiệu suất.

6.3 Phân tích kết quả

6.3.1 Phân tích các tập dữ liệu tổng hợp (synthetic clustering datasets)

Phần này phân tích khả năng nắm bắt cấu trúc hình học và ranh giới phân lớp của thuật toán trên các không gian 2 chiều, nơi có thể trực quan hóa kết quả.

a) Tập dữ liệu Pathbased

- **Đặc điểm dữ liệu:** Cấu trúc phi tuyến dạng móng ngựa bao quanh (non-convex), thách thức lớn với các bộ phân lớp tuyến tính.

- **Thiết lập:** Sử dụng Gaussian Kernel với $\gamma = 0.05$.
- **Kết quả định lượng:**
  - K-means: Adjusted Rand Index (ARI) đạt **0.46182**.
  - IMM: ARI đạt **0.46501**.
  - Kernel K-means: ARI đạt **0.89969**.
  - Kernel IMM: ARI đạt **0.61449**, PoE: **1.06645**.
  - Kernel ExKMC: ARI đạt **0.90863**, PoE: **1.00143**.
  - Kernel Expand: ARI đạt **0.90863**, PoE: **1.00143**.
- **Nhận xét:**
- **Nhận xét:** K-means tiêu chuẩn thất bại hoàn toàn do hạn chế của việc phân chia dựa trên tâm cụm Voronoi. Trong khi phương pháp xấp xỉ ban đầu (Kernel IMM) đã mang lại sự cải thiện nhất định dù PoE còn khá cao (≈ 1.066), bước tinh chỉnh trong Kernel ExKMC đã tạo ra sự đột phá: giảm PoE xuống mức gần như tối ưu (≈ 1.001) và nâng độ chính xác ARI lên mức cao nhất (0.90863), vượt qua cả mô hình Kernel gốc (0.89969). Đồng thời, việc IMM tiêu chuẩn cũng thất bại (ARI $\approx$ 0.465) tương tự K-means đã khẳng định giới hạn của các mô hình tuyến tính, làm nổi bật sự cần thiết của việc áp dụng Kernel.

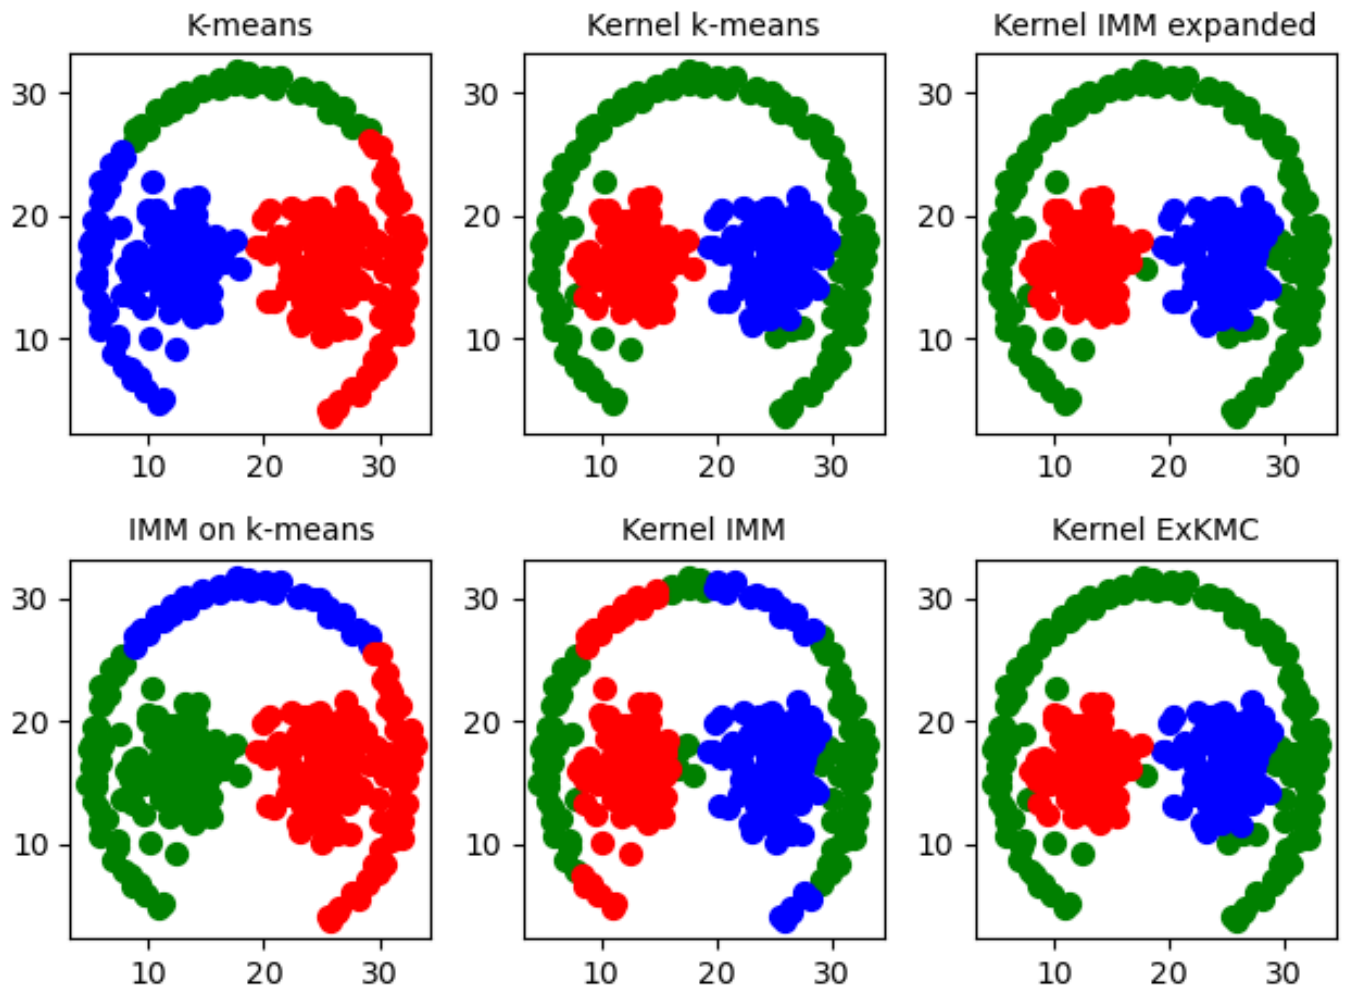

Hình 10: Kết quả phân cụm trên tập Pathbased. K-means (trên-trái) thất bại trong việc tách cụm bao ngoài, trong khi Kernel ExKMC (dưới-phải) tái tạo tốt cấu trúc hình học này bằng các đường cắt song song trục.

Nhận xét từ hình ảnh: Quan sát hình ảnh cho thấy sự hạn chế cốt lõi của **K-means** khi cố gắng phân chia tập dữ liệu dạng "móng ngựa" bằng một đường thẳng đơn giản, dẫn đến việc gộp sai các điểm ở hai đầu móng ngựa vào cùng một cụm. Ngược lại, **Kernel ExKMC** đã khắc phục hoàn toàn vấn đề này bằng cách tạo ra chuỗi các nhát cắt song song với trục (axis-aligned cuts). Các nhát cắt này hình thành nên cấu trúc dạng "bậc thang" ôm sát lấy đường cong phi tuyến của dữ liệu, chứng minh khả năng xấp xỉ hình học phức tạp bằng các luật đơn giản.

b) Tập dữ liệu Aggregation

- **Đặc điểm dữ liệu:** Các cụm có hình dạng bất định, mật độ khác nhau nhưng mức độ chồng lấn thấp hơn Pathbased.
- **Thiết lập:** Sử dụng Laplace Kernel với $\gamma = 0.1$ (theo khuyến nghị của bài báo gốc).

- **Kết quả định lượng:**
  - K-means: Adjusted Rand Index (ARI) đạt **0.76003**.
  - IMM: ARI đạt **0.75979**.
  - Kernel K-means: ARI đạt **0.78315**.
  - Kernel IMM: ARI đạt **0.77820**, PoE: **1.00028**.
  - Kernel ExKMC: ARI đạt **0.78283**, PoE: **1.00010**.
  - Kernel Expand: ARI đạt **0.78283**, PoE: **1.00010**.
- **Nhận xét:** Mặc dù chênh lệch hiệu năng giữa K-means và Kernel K-means tương đối thấp (0.023), điểm quan trọng nằm ở hiệu quả của quá trình tinh chỉnh. Sự chuyển tiếp từ Kernel IMM sang Kernel ExKMC đã giúp giảm chỉ số PoE từ 1.00028 xuống mức tối ưu 1.00010 Kết quả này đồng nghĩa với việc thuật toán đã tìm ra được một cây quyết định có khả năng giải thích hoàn hảo mô hình Kernel mà không phải đánh đổi bất kỳ độ chính xác nào.

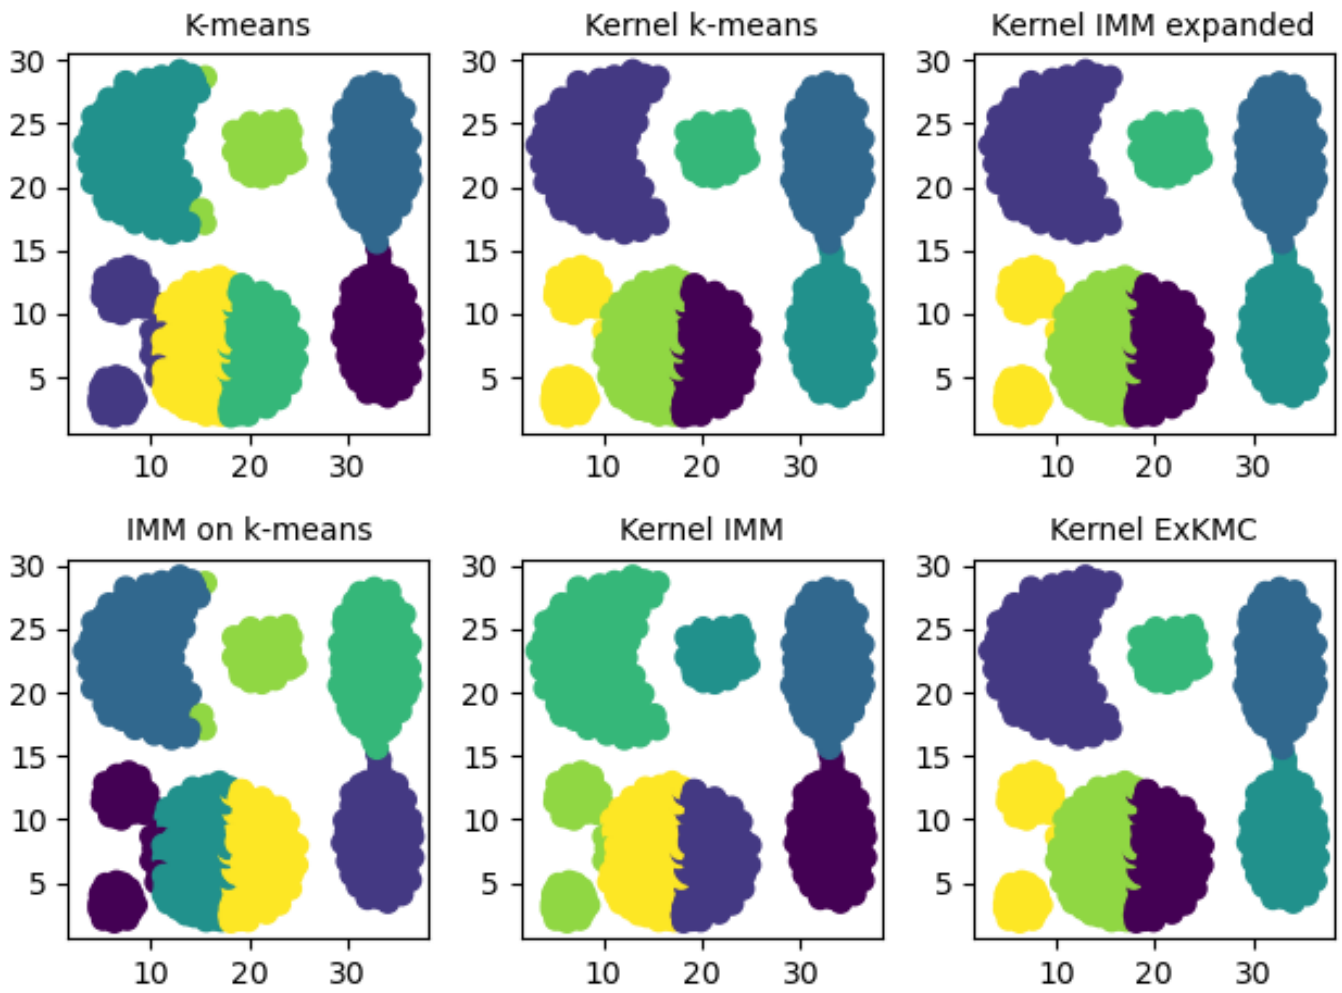

Hình 11: Kết quả phân cụm trên tập Aggregation. Kernel ExKMC (dưới-phải) bám sát ranh giới phân lớp tối ưu của Kernel K-means.

Nhận xét từ hình ảnh: Trên tập dữ liệu có mật độ phân bố đa dạng này, ranh giới phân lớp của **Kernel ExKMC** thể hiện sự linh hoạt cao. Thay vì các đường cong trơn phức tạp, thuật toán tạo ra các vùng phân chia hình chữ nhật (box-like regions) bao bọc gọn gàng từng cụm dữ liệu. Hình ảnh cho thấy các nhát cắt này len lỏi chính xác vào các khoảng hở tự nhiên giữa các cụm, mô phỏng lại gần như hoàn hảo hiệu quả phân lớp của mô hình **Kernel K-means** gốc.

c) Tập dữ liệu Flame

- **Đặc điểm dữ liệu:** Hai cụm hình ngọn lửa với mật độ không đồng đều và ranh giới phức tạp ngay cạnh nhau.
- **Thiết lập:** Sử dụng Gaussian Kernel với $\gamma = 0.05$.
- **Kết quả định lượng:**

  - K-means: Adjusted Rand Index (ARI) đạt **0.45341**.
  - IMM: ARI đạt **0.52354**.
  - Kernel K-means: ARI đạt **0.49979**.
  - Kernel IMM: ARI đạt **0.21095**, PoE: **1.01167**.
  - Kernel ExKMC: ARI đạt **0.56069**, PoE: **1.00341**.
  - Kernel Expand: ARI đạt **0.56069**, PoE: **1.00341**.

- **Nhận xét:** Đây là trường hợp đặc biệt quan trọng. Phương pháp xấp xỉ Taylor (Taylor IMM) thất bại nặng nề về độ chính xác (ARI chỉ 0.21095) do xấp xỉ không phù hợp với phân phối hình học của dữ liệu, dù chỉ số PoE tương đối thấp (1.01167). Tuy nhiên, nhờ cơ chế tinh chỉnh tham lam (greedy refinement), thuật toán Kernel ExKMC đã khắc phục hoàn toàn lỗi này: đưa PoE về mức tối ưu 1.00341 và nâng ARI lên 0.56069, vượt qua cả hiệu suất của mô hình Kernel K-means gốc (0.49979).

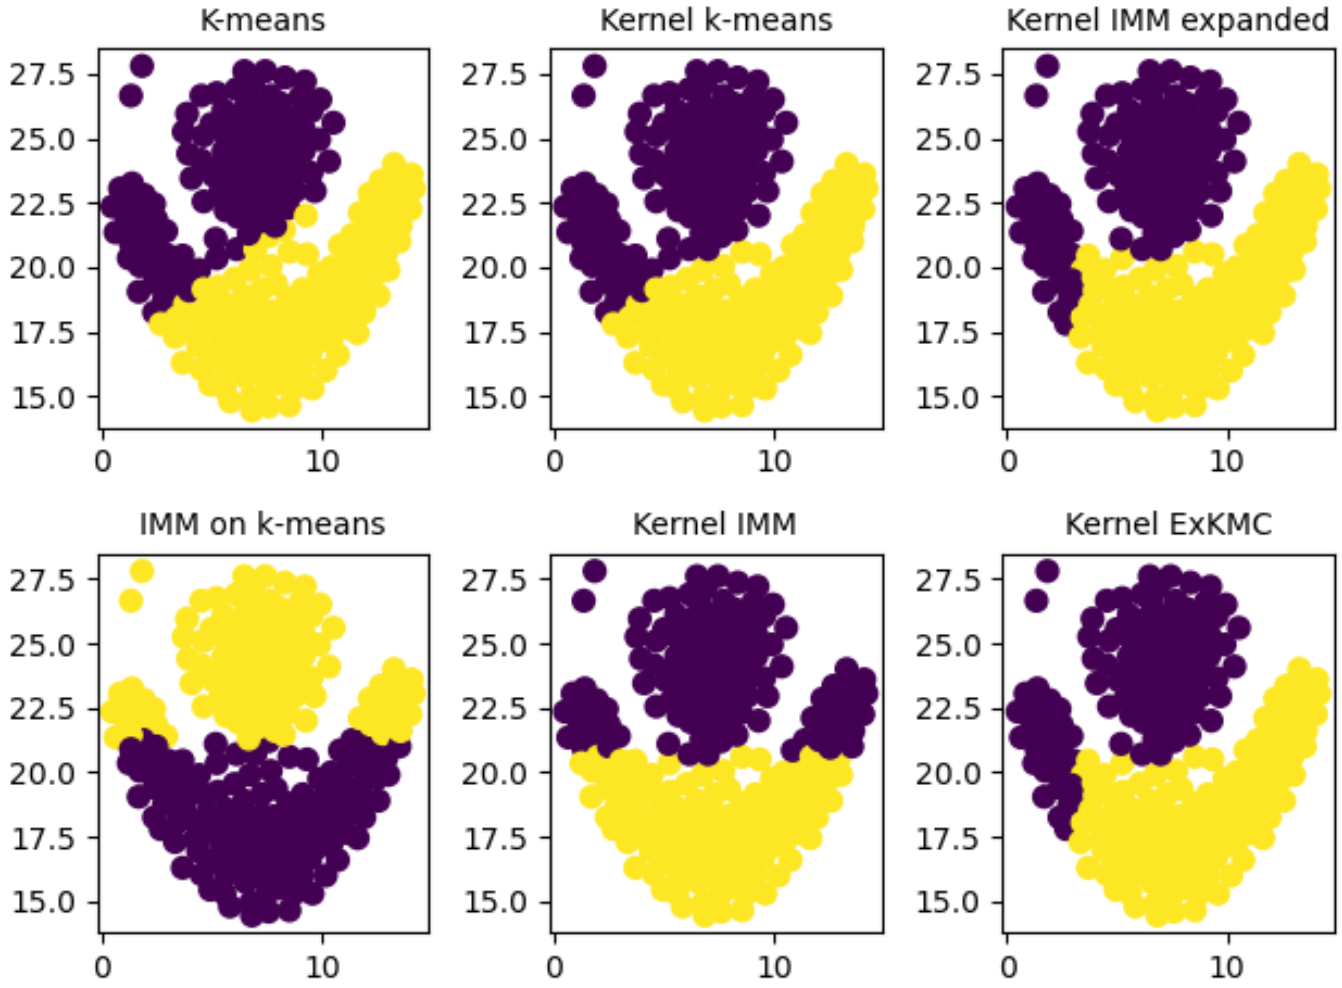

Hình 12: Kết quả phân cụm trên tập Flame. Lưu ý sự thất bại của Taylor IMM (giữa-dưới) và sự phục hồi hiệu năng ấn tượng của Kernel ExKMC (dưới-phải).

Nhận xét từ hình ảnh: Đây là ví dụ trực quan nhất về sự "sửa sai" của bước tinh chỉnh. Trong khi hình ảnh của Taylor IMM (bước xấp xỉ ban đầu) cho thấy các đường cắt bị phân mảnh, lộn xộn và cắt ngang cấu trúc dữ liệu, thì **Kernel ExKMC** đã tự động điều chỉnh lại hoàn toàn. Hình ảnh kết quả cho thấy thuật toán đã tìm ra được khe hẹp tự nhiên giữa hai "ngọn lửa" và đặt các nhát cắt chính xác vào đó để tách biệt hai cụm, khẳng định tính mạnh mẽ của cơ chế tinh chỉnh tham lam.

6.3.2 Phân tích các tập dữ liệu thực tế

Phần này đánh giá hiệu năng trên dữ liệu nhiều chiều, tập trung vào các chỉ số định lượng do hạn chế về khả năng trực quan hóa.

a) Tập dữ liệu Iris

- **Đặc điểm dữ liệu:** 150 mẫu, 4 chiều (đặc trưng kích thước đài hoa và cánh hoa), phân thành 3 lớp.
- **Thiết lập:** Sử dụng Gaussian Kernel với $\gamma = 1$.
- **Kết quả định lượng:**
  - K-means: Adjusted Rand Index (ARI) đạt **0.73024**.
  - IMM: ARI đạt **0.73230**.
  - Kernel K-means: ARI đạt **0.74368**.
  - Kernel IMM: ARI đạt **0.73230**, PoE: **1.01122**.
  - Kernel ExKMC: ARI đạt **0.75920**, PoE: **1.00479**.
  - Kernel Expand: ARI đạt **0.75920**, PoE: **1.00479**.
- **Nhận xét:** Kernel ExKMC đạt hiệu quả tốt nhất trong các mô hình thử nghiệm với ARI cao nhất (0.75920), đồng thời giảm đáng kể chỉ số PoE từ 1.01120 (ở bước Kernel IMM) xuống 1.00479 (ExKMC). Điều này cho thấy các luật cắt song song với trục (axis-aligned cuts) của cây quyết định phù hợp với bản chất sinh học của dữ liệu Iris hơn là không gian biến đổi RBF thuần túy.

b) Tập dữ liệu Wisconsin Breast Cancer

- **Đặc điểm dữ liệu:** 569 mẫu, 30 chiều (các đặc trưng tế bào học từ hình ảnh), phân lớp lành tính/ác tính.
- **Thiết lập:** Sử dụng Gaussian Kernel với $\gamma \approx 5 \times 10^{-6}$.
- **Kết quả định lượng:**
  - K-means: Adjusted Rand Index (ARI) đạt **0.49142**.

  - IMM: ARI đạt **0.49142**.
  - Kernel K-means: ARI đạt **0.66444**.
  - Kernel IMM: ARI đạt **0.67588**, PoE: **1.00179**.
  - Kernel ExKMC: ARI đạt **0.67588**, PoE: **1.00179**.
  - Kernel Expand: ARI đạt **0.67020**, PoE: **1.00036**.

- **Nhận xét:** Trên không gian cao chiều, mô hình tuyến tính (K-means) hoạt động kém. Kernel K-means cải thiện đáng kể. Cả Kernel IMM và ExKMC đều duy trì được độ chính xác cao (0.67588) với PoE cực thấp (1.00179), chứng minh khả năng tạo ra mô hình chẩn đoán minh bạch có độ chính xác ngang bằng mô hình hộp đen. Riêng Kernel Expand có PoE tốt hơn (1.00036) nhưng ARI thấp hơn nhẹ (0.67020), cho thấy ExKMC là lựa chọn tối ưu hơn khi ưu tiên độ chính xác phân cụm trong y tế.

6.3.3 Tổng hợp

Các bảng sau tổng hợp chỉ số Adjusted Rand Index (ARI) và chỉ số Price of Explainability (PoE) của các phương pháp.

Tập dữ liệu	**Mô hình cơ sở**		**Mô hình giải thích (Cây quyết định)**		
	K-means	**Kernel KM**	**Kernel IMM**	**Kernel Expand**	**Kernel ExKMC**
Pathbased	0.46182	0.89969	0.61449	**0.90863**	**0.90863**
Aggregation	0.76003	0.78315	0.77820	**0.78283**	**0.78283**
Flame	0.45341	0.49979	0.21095	**0.56069**	**0.56069**
Iris	0.73024	0.74368	0.73230	**0.75920**	**0.75920**
Cancer	0.49142	0.66444	**0.67588**	0.67020	**0.67588**

Bảng 4: So sánh độ chính xác phân cụm (Adjusted Rand Index - ARI) giữa các phương pháp

Tập dữ liệu	**Kernel IMM**	**Kernel Expand**	**Kernel ExKMC**
Pathbased	1.06645	**1.00143**	**1.00143**
Aggregation	1.00028	**1.00010**	**1.00010**
Flame	1.01167	**1.00341**	**1.00341**
Iris	1.01122	**1.00479**	**1.00479**
Cancer	1.00179	**1.00036**	1.00179

Bảng 5: So sánh chi phí giải thích (Price of Explainability - PoE) (Giá trị càng gần 1 càng tốt)

Sau khi tổng hợp được các bảng ghi lại số liệu qua quá trình chạy thực nghiệm, nhóm chúng em tiến hành

vẽ lại các biểu đồ và so sánh với 9 (biểu đồ ghi nhận kết quả thực nghiệm của tác giả trong bài báo gốc). Nhóm nhận được các biểu đồ tương tự.

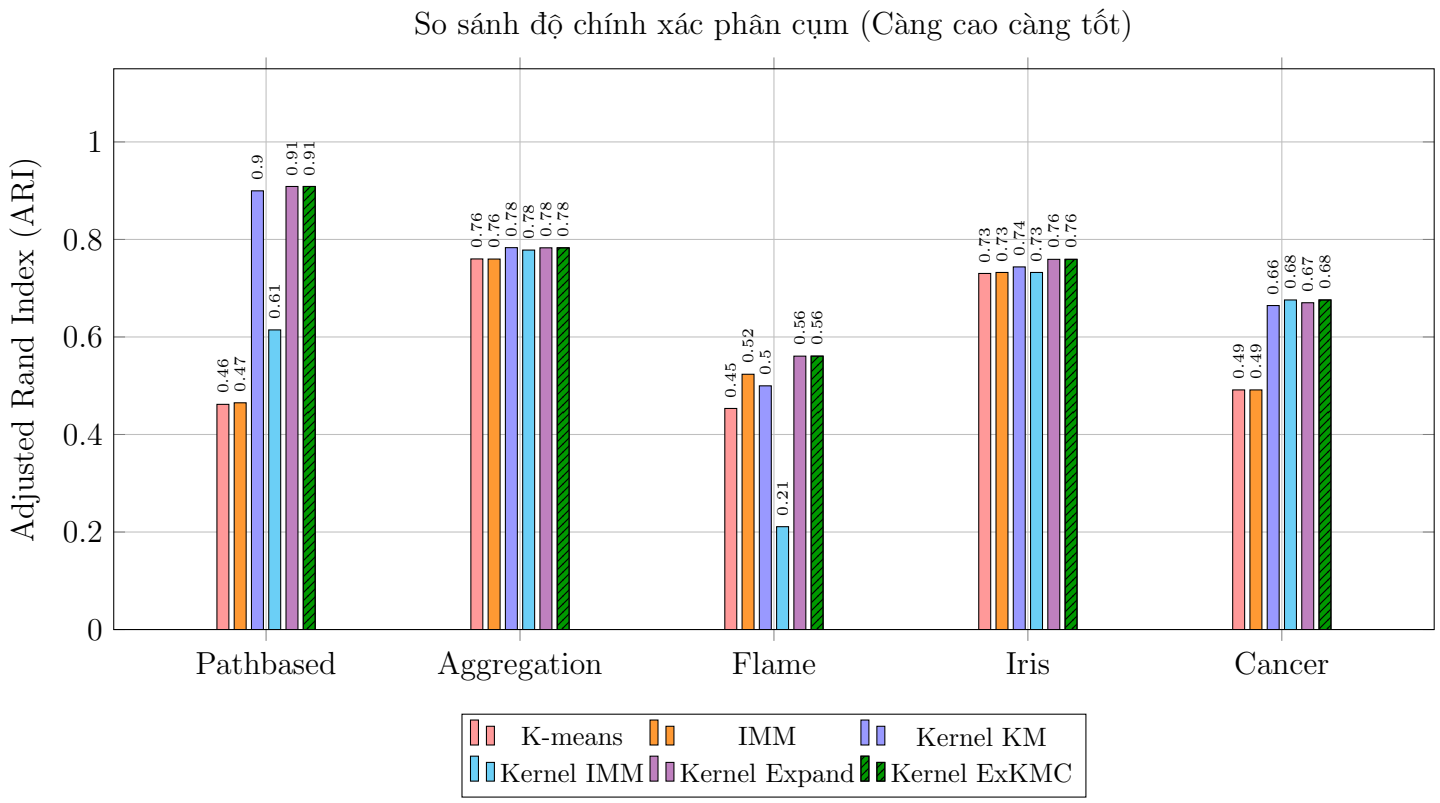

Hình 13: Biểu đồ ARI đầy đủ: So sánh hiệu năng của cả 6 thuật toán.

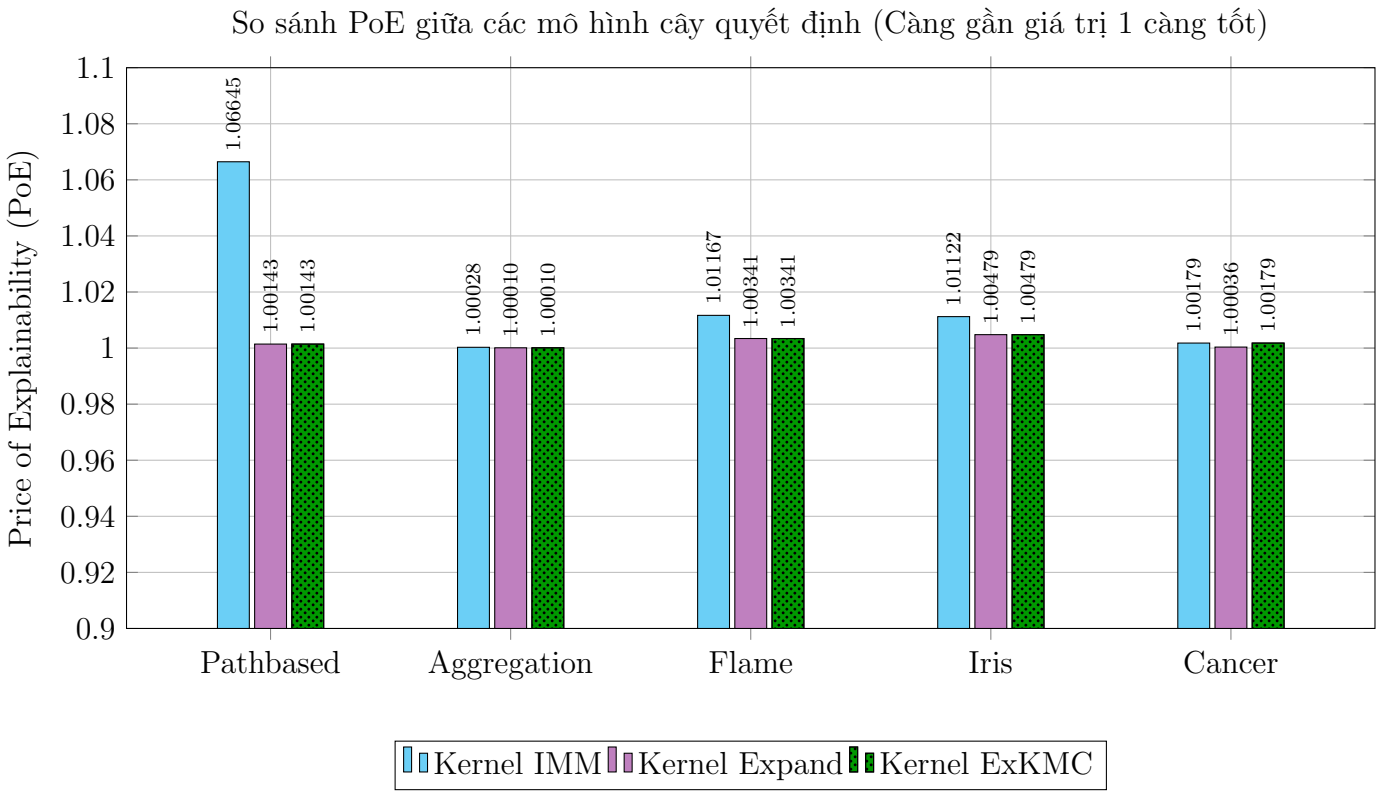

Hình 14: Biểu đồ PoE: Kernel Expand và ExKMC giảm đáng kể sai số so với Kernel IMM.

Nhận xét tổng quan: Từ hai bảng số liệu tổng hợp và sự trực quan hóa trên các biểu đồ 13 và 14, rút ra được bốn kết luận chính:

1. **Hiệu quả vượt trội của bước Tinh chỉnh (Refinement):** Trên 4/5 tập dữ liệu (Pathbased, Flame, Iris, Cancer), thuật toán Kernel ExKMC đạt chỉ số ARI cao hơn cả mô hình Kernel K-means gốc (ví dụ: Pathbased 0.90863 so với 0.89969). Điều này khẳng định rằng việc tối ưu hóa trực tiếp hàm mục tiêu trên cấu trúc cây quyết định giúp mô hình loại bỏ nhiễu và tổng quát hóa tốt hơn so với việc chỉ đơn thuần xấp xỉ tâm cụm.

2. **Khắc phục hạn chế của xấp xỉ Taylor:** Trường hợp tập Flame là minh chứng rõ rệt nhất cho tính mạnh mẽ của thuật toán. Quan sát biểu đồ ARI cho thấy, ngay cả khi bước xấp xỉ ban đầu thất bại (cột Kernel IMM rất thấp, ARI ≈ 0.210), thuật toán ExKMC vẫn có thể phục hồi và đạt hiệu suất cao nhất (ARI ≈ 0.560), vượt qua cả mô hình gốc.

3. **Tối ưu hóa Chi phí giải thích (PoE):** Biểu đồ PoE cho thấy độ cao của các cột giảm mạnh từ bước Xấp xỉ (IMM) sang bước Tinh chỉnh (ExKMC), tiệm cận mức lý tưởng 1.0. Sự chênh lệch này đặc biệt lớn trên các tập dữ liệu phức tạp (Pathbased giảm từ 1.066 xuống 1.001). Điều này chứng tỏ chúng ta có thể đạt được sự minh bạch (Explainability) với cái giá (Price) gần như bằng không sau quá trình tối ưu hóa.

4. **Sự ổn định và đánh đổi giữa các biến thể:** Dữ liệu cho thấy Kernel Expand và Kernel ExKMC hội tụ về cùng một kết quả trên hầu hết các tập dữ liệu, khẳng định tính ổn định của chiến lược tinh chỉnh. Tuy nhiên, sự khác biệt trên tập *Cancer* (Expand có PoE tốt hơn nhưng ExKMC có ARI cao hơn) chỉ ra một sự đánh đổi nhỏ: ExKMC có xu hướng ưu tiên tối đa hóa độ chính xác phân cụm thực tế, trong khi Expand bám sát hơn vào cấu trúc hình học nguyên bản của không gian Kernel.

6.3.4 Phân tích tác động của tham số M

Như đã đề cập trong Định nghĩa 3 thuộc phần phương pháp, M đóng vai trò quan trọng trong việc cân bằng giữa sự chính xác của xấp xỉ kernel và độ phức tạp tính toán. Ngoài ra, tác giả cũng khẳng định ở cuối phần 4.3.3, với các giá trị $M \leq 5$ cũng đã đủ độ linh hoạt để thu được các phân cụm diễn giải tốt. Do đó, phần này đánh giá tác động của tham số M (bậc khai triển Taylor) đến hiệu quả của thuật toán Kernel IMM trên các tập dữ liệu sử dụng Gaussian Kernel và kiểm chứng lời khẳng định của tác giả về ảnh hưởng của các giá trị $M \leq 5$.

Kết quả thực nghiệm được tổng hợp trong Bảng 6 và minh họa trực quan trong Hình 15 và Hình 16.

Dataset	M	Rand Score	PoE	Num Cuts
Pathbased	1	0.4545	**1.0719**	2
	5	0.4545	**1.0719**	2
	20	0.4585	1.0770	2
	35	**0.4892**	1.0736	2
Aggregation	1	0.2543	1.0868	6
	5	0.2994	1.0828	6
	20	**0.3842**	**1.0748**	6
	35	0.3438	1.0761	6
Flame	1	0.5965	**1.0257**	1
	5	0.5965	**1.0257**	1
	20	**0.6081**	1.0308	1
	35	**0.6081**	1.0308	1

Bảng 6: Tác động của tham số M đến hiệu suất của Kernel IMM trên các tập dữ liệu

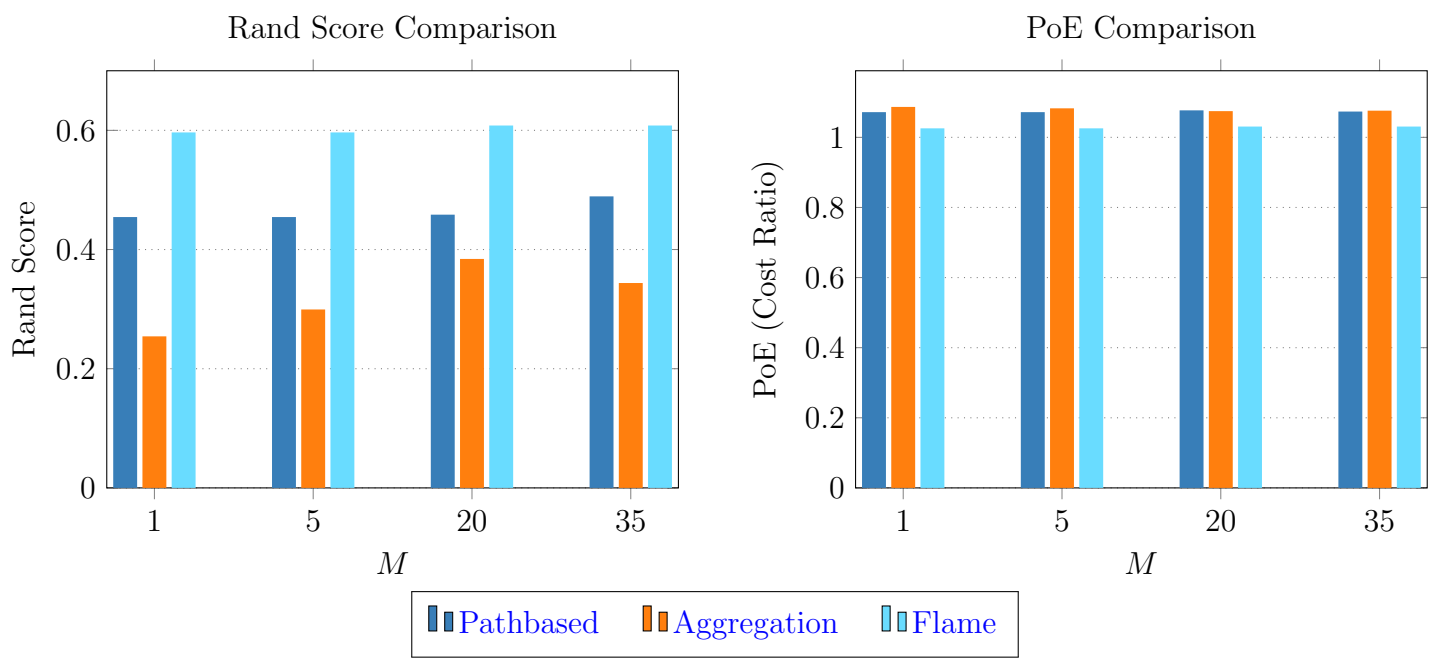

Hình 15: So sánh chi tiết Rand Score và PoE theo từng tập dữ liệu với các giá trị M khác nhau

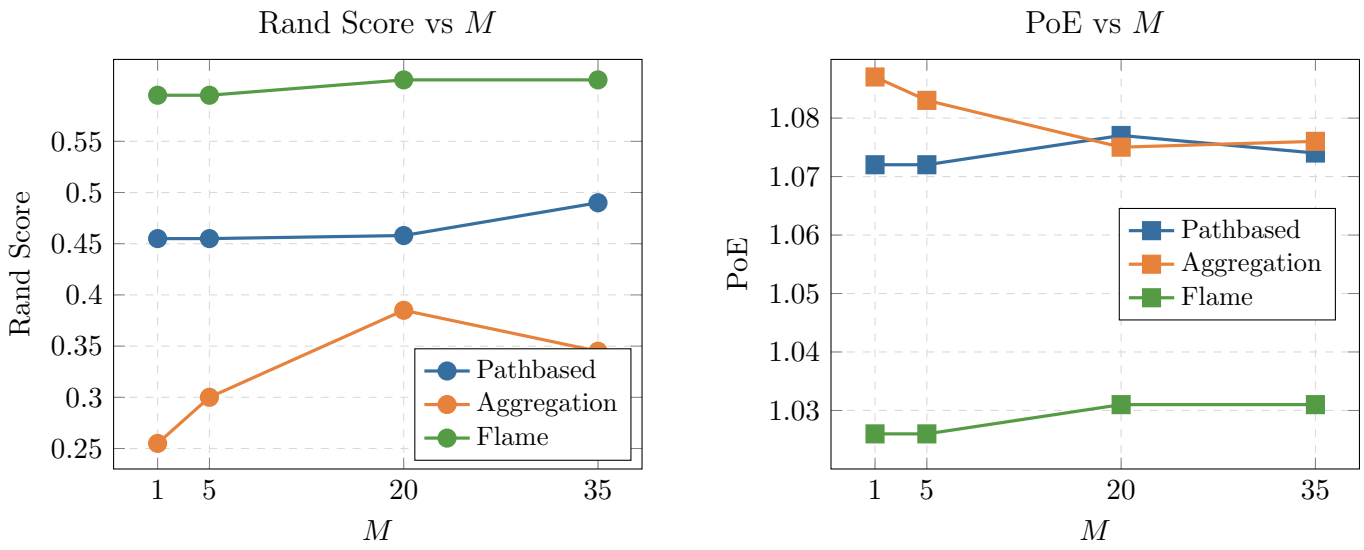

Hình 16: Biểu đồ xu hướng của Rand Score và PoE khi thay đổi M

Về độ chính xác (Rand Score): Nhìn chung, khi M tăng, chỉ số Rand Score có xu hướng cải thiện.

- Với tập *Pathbased*, Rand Score tăng dần và đạt đỉnh tại $M = 35$ (0.4892), cho thấy việc xấp xỉ chi tiết hơn ở bậc cao giúp nắm bắt tốt hơn cấu trúc phức tạp của các cụm hình vòng cung.
- Với tập *Aggregation*, hiệu suất tăng đáng kể từ $M = 1$ đến $M = 20$ (đạt đỉnh 0.3842), nhưng lại giảm nhẹ khi $M = 35$. Điều này cho thấy việc tăng M quá cao không phải lúc nào cũng mang lại lợi ích tốt hơn (có thể do nhiễu hoặc sự phức tạp không cần thiết).

- Với tập *Flame*, kết quả khá ổn định và đạt mức cao nhất ngay từ $M = 20$.

Về khả năng giải thích và chi phí (PoE): Chỉ số PoE duy trì ở mức thấp (gần 1.0) trên mọi giá trị M, khẳng định tính ổn định của thuật toán. Đáng chú ý, ở một số trường hợp như *Flame* và *Pathbased*, giá trị M nhỏ ($M = 1, 5$) lại cho PoE tốt nhất. Điều này gợi ý rằng một xấp xỉ đơn giản đôi khi đã đủ để tìm ra các nhát cắt tối ưu về mặt chi phí sai số (objective function), ngay cả khi chi tiết phân cụm (Rand Score) chưa đạt mức tối đa. Tại *Aggregation*, $M = 20$ là điểm tối ưu giúp cải thiện cả PoE lẫn Rand Score.
Kết luận về việc chọn M: Kết quả thực nghiệm phù hợp với phân tích lý thuyết: mặc dù sai số xấp xỉ giảm khi M tăng, ta phải đánh đổi bằng chi phí tính toán cao hơn. Thực tế cho thấy mức $M \approx 20$ (hoặc thậm chí thấp hơn như $M = 5$) thường là điểm cân bằng hợp lý (*sweet spot*), nơi thuật toán đạt độ chính xác cao tương đương hoặc tốt hơn các bậc cao hơn mà không làm bùng nổ số chiều dữ liệu. Điều này xác nhận lại tính khả thi và hiệu quả của việc sử dụng Taylor Kernel IMM trong thực tế mà không cần M quá lớn.

7 Thảo luận phản biện

Dựa trên kết quả thực nghiệm và các phân tích lý thuyết, phần này thảo luận chi tiết về các ưu điểm nổi bật, những hạn chế còn tồn tại và đề xuất các hướng phát triển tiếp theo cho nghiên cứu về phân cụm kernel diễn giải được.

7.1 Ưu điểm và Đóng góp chính

1. **Tính tiên phong trong hướng tiếp cận:** Nghiên cứu này là một trong những nỗ lực đầu tiên nhằm giải quyết bài toán *Kernel Clustering diễn giải được* một cách hệ thống và có cơ sở toán học. Khác với các phương pháp trước đây thường chỉ tập trung vào K-Means tuyến tính hoặc sử dụng các kỹ thuật giải thích *hộp đen* (post-hoc explanations), phương pháp đề xuất tích hợp tính diễn giải ngay trong quá trình xây dựng mô hình.

2. **Cân bằng tối ưu giữa Diễn giải và Chính xác:** Phương pháp Kernel IMM thành công trong việc giải quyết mâu thuẫn kinh điển giữa khả năng diễn giải và hiệu suất mô hình. Thông qua việc sử dụng cấu trúc cây quyết định trên không gian đặc trưng thay thế, thuật toán không chỉ cung cấp các luật phân loại tường minh mà còn duy trì được các đảm bảo lý thuyết về độ chính xác (approximation guarantees), cụ thể là giới hạn sai số $O(dk^2)$ so với phân cụm tối ưu.

3. **Định hình vai trò của Bản đồ đặc trưng (Feature Maps):** Một đóng góp quan trọng là việc xác định vai trò then chốt của việc lựa chọn bản đồ đặc trưng phù hợp (interpretable feature maps). Kết quả này không chỉ giới hạn trong bài toán hiện tại mà còn đặt nền móng lý thuyết cho việc nghiên cứu tính diễn giải của các họ phương pháp kernel khác trong tương lai.

4. **Hiệu quả thực tế ấn tượng:** Các thực nghiệm cho thấy mặc dù ranh giới phân lớp của mô hình diễn giải (cây quyết định) có sự khác biệt về hình học so với phân lớp phi tuyến phức tạp của kernel gốc, nhưng chi phí phân cụm (Cost) lại tiệm cận rất sát với mức tối ưu. Chỉ số Price of Explainability (PoE) xấp xỉ 1.0 trong nhiều bộ dữ liệu thực tế là minh chứng rõ ràng cho tính khả thi của phương pháp.

7.2 Hạn chế và Thách thức

Tuy nhiên, nghiên cứu vẫn còn những tồn tại nhất định cần được xem xét cẩn trọng:

1. **Giới hạn về phạm vi áp dụng (Theorem 7):** Phương pháp Kernel IMM không phải là lời giải vạn năng cho mọi loại kernel. Định lý 7 đã chỉ ra rằng với các kernel như *Quadratic Kernel* hay *ϵ-neighborhood kernel*, chỉ số PoE có thể tiến tới vô cùng. Điều này đồng nghĩa với việc không gian đặc trưng của các kernel này quá phức tạp để có thể được xấp xỉ hiệu quả bằng các đường cắt trục song song của cây quyết định.

2. **Sự phụ thuộc vào thước đo đánh giá:** Việc sử dụng PoE như thước đo chính đôi khi có thể dẫn đến các nhận định chủ quan. Trong trường hợp dữ liệu chứa nhiều nhiễu làm cho chi phí tối ưu (mẫu số) rất lớn, một tỷ số PoE nhỏ ($O(1)$) không nhất thiết phản ánh rằng cây quyết định đã học được cấu trúc hình học thực sự của dữ liệu, mà có thể chỉ là sự che lấp bởi sai số lớn của chính bài toán gốc.

3. **Thách thức với Kernel phi Euclid:** Khi mở rộng sang các kernel dựa trên khoảng cách (như Laplace) sử dụng phương pháp điểm mốc (landmarks), không gian đặc trưng thu được thường là phi Euclid. Hệ quả là các đảm bảo lý thuyết chặt chẽ (worst-case bounds) của trường hợp Gaussian không còn được giữ nguyên, mà thay vào đó phụ thuộc vào các hằng số đặc thù của dữ liệu (κ_1, κ_2), làm giảm tính tổng quát của lý thuyết.

Các đề xuất cải thiện tiềm năng được tác giả trình bày ở phần kết luận 9.

8 Chứng minh các định lý

8.1 Chứng minh Định lý 1

Định lý. (Gaussian kernel không thể có bản đồ đặc trưng diễn giải được). Xét Gaussian kernel trong không gian $d > 1$ chiều. Tồn tại một tập dữ liệu X sao cho với mọi bản đồ đặc trưng $\phi : X \to \mathbb{R}^D$ thỏa mãn $\langle \phi(x), \phi(y) \rangle = K(x, y)$ với mọi $x, y \in X$, luôn tồn tại một chỉ số $j \in [D]$ sao cho ϕ_j phụ thuộc vào nhiều hơn một chiều đầu vào của $x \in X$.

Chứng minh. Xét một tập dữ liệu đơn giản X sao cho không có bản đồ đặc trưng nào của Gaussian kernel $K(x, y) = \exp(-\gamma \|x - y\|^2)$ có thể phụ thuộc chỉ vào một tọa độ đầu vào trong mỗi thành phần $\phi_1, \ldots, \phi_D$, bất kể D lớn đến đâu. Xét ba vector trong $\mathbb{R}^2$ được cho bởi:

$$x^{(1)} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \quad x^{(2)} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \quad x^{(3)} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

Với $\gamma > 0$ đủ lớn, ta biết rằng $K_{1,2} + K_{2,3} < 1$. Giả sử tồn tại một bản đồ đặc trưng diễn giải được $\phi : X \to \mathbb{R}^D$. Khi đó, ta có thể viết $\phi(x) = (f(x), g(x))$, trong đó $f(x)$ là hàm của x_1 và $g(x)$ là hàm của x_2. Theo cách chọn các điểm giả định, ta có thể viết:

$$\begin{aligned} \phi(x^{(1)}) &= (a, b) \\ \phi(x^{(2)}) &= (c, b) \\ \phi(x^{(3)}) &= (c, d) \end{aligned}$$

với các vector a, b, c, d nào đó. Điều này suy ra:

$$\begin{aligned}
K_{1,3} &= a^T c + b^T d \\
&= a^T c + \|b\|^2 + (b^T d - \|b\|^2) \\
&= K_{1,2} + (b^T d + \|c\|^2 - 1) \\
&= K_{1,2} + K_{2,3} - 1 \\
&< 0
\end{aligned}$$

Điều này mâu thuẫn với $K_{1,3} \geq 0$. Với các giá trị $\gamma > 0$ khác, ta chỉ cần thay đổi tỉ lệ dữ liệu cho phù hợp. □

8.2 Chứng minh Định lý 2

Định lý. Xét Gaussian kernel một chiều $K(x, y) = \exp\big(-|x-y|^2\big)$. Khi đó, tồn tại một tập dữ liệu $X \subset \mathbb{R}$ sao cho với mọi bản đồ đặc trưng $\phi = (\phi_j)_{j=1}^D$, luôn tồn tại ít nhất một thành phần ϕ_j không đơn điệu.

Chứng minh. Xét Gaussian kernel $K(x, y) = \exp\big(-(x-y)^2\big)$ trên $\mathbb{R}$. Chọn tập dữ liệu $X = \{x^{(1)}, x^{(2)}, x^{(3)}\}$ với $x^{(1)} < x^{(2)} < x^{(3)}$, và ma trận kernel tương ứng K thỏa mãn:

$$K_{1,2} + K_{2,3} < K_{1,3} + 1$$

Điều này chắc chắn xảy ra khi các điểm nằm cách nhau đủ xa. Giả sử tồn tại một bản đồ đặc trưng $\phi : X \to \mathbb{R}^D$, $\phi(x^{(i)}) = (v_i, w_i)$, trong đó (v_i) là không giảm và (w_i) là không tăng với $i = 1, 2, 3$. Nói cách khác, giả sử tồn tại hai vector v_1, w_1 và các vector không âm $\epsilon_1, \epsilon_2, \epsilon_3, \delta_1, \delta_2, \delta_3$ sao cho:

$$\Phi = \begin{pmatrix} v_1 & v_1 + \epsilon_1 & v_1 + \epsilon_1 + \epsilon_2 \\ w_1 & w_1 - \delta_1 & w_1 - \delta_1 - \delta_2 \end{pmatrix} = \begin{pmatrix} v_1 & v_1 + \epsilon_1 & v_1 + \epsilon_3 \\ w_1 & w_1 - \delta_1 & w_1 - \delta_3 \end{pmatrix}.$$

Ta có $\Phi^T \Phi = K$, do đó:

$$\begin{aligned}
&v_1^T v_1 + w_1^T w_1 = 1 \\
&(v_1 + \epsilon_1)^T (v_1 + \epsilon_1) + (w_1 - \delta_1)^T (w_1 - \delta_1) = 1 \\
&v_1^T (v_1 + \epsilon_1) + w_1^T (w_1 - \delta_1) = K_{1,2}
\end{aligned}$$

Suy ra:

$$v_1^T \epsilon_1 - w_1^T \delta_1 = K_{1,2} - 1. \tag{13}$$

Với $\phi(x^{(2)}) = (v_1 + \epsilon_1, w_1 - \delta_1)$ và $K(x, x) = e^0 = 1$, ta được:

$$\begin{aligned}
\|\phi(x^{(2)})\|^2 = 1 &= \|v_1 + \epsilon_1\|^2 + \|w_1 - \delta_1\|^2 \\
&= (\|v_1\|^2 + 2v_1^T\epsilon_1 + \|\epsilon_1\|^2) + (\|w_1\|^2 - 2w_1^T\delta_1 + \|\delta_1\|^2) \\
&= (\|v_1\|^2 + \|w_1\|^2) + (\|\epsilon_1\|^2 + \|\delta_1\|^2) + 2(v_1^T\epsilon_1 - w_1^T\delta_1) \\
&= 1 + (\|\epsilon_1\|^2 + \|\delta_1\|^2) + 2(K_{1,2} - 1).
\end{aligned}$$

Từ đó suy ra:

$$\|\epsilon_1\|^2 + \|\delta_1\|^2 = 2 - 2K_{1,2}.$$

Sử dụng lập luận tương tự cho hai cặp điểm còn lại trong X, ta thu được:

$$\|\epsilon_2\|^2 + \|\delta_2\|^2 = 2 - 2K_{2,3},$$

$$\|\epsilon_3\|^2 + \|\delta_3\|^2 = 2 - 2K_{1,3}.$$

Vì $\epsilon_3 = \epsilon_1 + \epsilon_2$ và $\delta_3 = \delta_1 + \delta_2$, ta có:

$$\begin{aligned}
2 - 2K_{1,3} &= \|\epsilon_3\|^2 + \|\delta_3\|^2 \\
&= \|\epsilon_1 + \epsilon_2\|^2 + \|\delta_1 + \delta_2\|^2 \\
&= \|\epsilon_1\|^2 + \|\epsilon_2\|^2 + 2\epsilon_1^T\epsilon_2 + \|\delta_1\|^2 + \|\delta_2\|^2 + 2\delta_1^T\delta_2 \\
&= (\|\epsilon_1\|^2 + \|\delta_1\|^2) + (\|\epsilon_2\|^2 + \|\delta_2\|^2) + 2(\epsilon_1^T\epsilon_2 + \delta_1^T\delta_2) \\
&= (2 - 2K_{1,2}) + (2 - 2K_{2,3}) + 2(\epsilon_1^T\epsilon_2 + \delta_1^T\delta_2).
\end{aligned}$$

Điều này tương đương với:

$$2(\epsilon_1^T\epsilon_2 + \delta_1^T\delta_2) = (2 - 2K_{1,3}) - (2 - 2K_{1,2}) - (2 - 2K_{2,3}) = 2K_{1,2} + 2K_{2,3} - 2 - 2K_{1,3}.$$

Hay:

$$\epsilon_1^T\epsilon_2 + \delta_1^T\delta_2 = K_{1,2} + K_{2,3} - 1 - K_{1,3}.$$

Theo giả thiết $K_{1,2} + K_{2,3} < K_{1,3} + 1$, vế phải âm, tức là $\epsilon_1^T\epsilon_2 + \delta_1^T\delta_2 < 0$. Tuy nhiên, vì ϵ_i, δ_i là các vector không âm, tích vô hướng của chúng phải không âm, tức là $\epsilon_1^T\epsilon_2 + \delta_1^T\delta_2 \geq 0$. Điều này dẫn đến mâu thuẫn. □

8.3 Chứng minh Định lý 3

Định lý. (Các vết cắt ngưỡng trong không gian đặc trưng thay thế của kernel Taylor có thể diễn giải tạo ra các cây quyết định có thể diễn giải). Xét K là tích của các kernel Taylor có thể diễn giải, và gọi ϕ là bản đồ đặc trưng thay thế của nó. Khi đó, một vết cắt ngưỡng có dạng $\phi_{i,j}(x_i) \gtrless \theta$ dẫn đến một cây quyết định có thể diễn giải trong $\mathbb{R}^d$.

Chứng minh. Nhắc lại khái niệm của chúng tôi về các đặc trưng thay thế cho các kernel Taylor có thể diễn giải: Với mọi $i \in [d]$ và $x \in X$, ta định nghĩa:

$$\phi_i(x) = \left(f(x_i) x_i^j \sqrt{\frac{g^{(j)}(0)}{j!}} \right)_{j=0}^{M}$$

Gọi việc ghép nối $\phi(x) = (\phi_i(x_i))_{i=1}^d$ là bản đồ đặc trưng thay thế bậc M. Với $\phi_{i,j}(x) = f(x_i)x_i^j\sqrt{\frac{g^{(j)}(0)}{j!}}$ nên:

$$\begin{aligned}
\phi'_{i,j}(x) &= \sqrt{\frac{g^{(j)}(0)}{j!}} \left(f'(x_i) \cdot x_i^j + f(x_i) \cdot j x_i^{j-1} \right) \\
&= \sqrt{\frac{g^{(j)}(0)}{j!}} \cdot x_i^{j-1} \left(f'(x_i) x_i + j f(x_i) \right).
\end{aligned}$$

Từ đó, ta thấy rằng:

$$\phi'_{i,j}(x) \propto x_i^{j-1} \left(f'(x_i) x_i + j f(x_i) \right).$$

Đối với các kernel Taylor có thể diễn giải, biểu thức này bằng 0 tại tối đa một điểm x trong miền xác định của kernel. Do đó, khi chúng ta chạy IMM trên các đặc trưng thay thế này, các vết cắt ngưỡng $\phi_{i,j}(x) \gtrless \theta$ có thể được chuyển đổi thành các cây quyết định có thể diễn giải trong không gian đầu vào.

□

8.4 Chứng minh Định lý 4

Chứng minh. Bắt đầu bằng việc lưu ý rằng với mọi $i \in [d]$ và $x, y \in X$, cùng với một số nguyên M bất kỳ, công thức Taylor đảm bảo rằng:

$$\begin{aligned}
|K_i(x,y) - \langle \phi_i(x), \phi_i(y) \rangle| &= f(x_i) f(y_i) \cdot \left| \sum_{j=M}^{\infty} \frac{g^{(j)}(0)}{j!} (x_i y_i)^j \right| \\
&\leq \left(\max_{x \in X} |f(x_i)|^2 \right) \cdot \frac{\|g^{(j)}\|_\infty (x_i y_i)^M}{M!}
\end{aligned}$$

Vì g được giả định là hàm giải tích, ta có $\lim_{M\to\infty}\langle\phi_i(x),\phi_i(y)\rangle = K_i(x,y)$ với mọi x, y. Do đó, các đặc trưng thay thế ϕ_i xấp xỉ các kernel một chiều K_i với một sai số $\delta > 0$ nào đó, và sai số này sẽ tiến về 0 khi $M \to \infty$.

Tiếp theo, cố định một tập dữ liệu X và gọi $\hat{C}_1, \ldots, \hat{C}_k$ là các cụm diễn giải được (interpretable clusters) được chọn bởi thuật toán IMM trên các đặc trưng thay thế ϕ. Gọi $C_1, \ldots, C_k$ là các cụm tham chiếu thu được từ kernel k-means không bị hạn chế (unrestricted) đối với kernel Taylor gốc K. Ký hiệu *cost* là chi phí kernel k-means đối với kernel tích K, $cost_i$ là chi phí đối với các kernel đơn biến K_i, và $\widetilde{cost}_i$ là chi phí đối với kernel xấp xỉ được xác định ngầm thông qua các bản đồ đặc trưng thay thế ϕ_i.

Sử dụng Bổ đề 3 và kiểm soát sai số xấp xỉ, ta thu được:

$$\begin{aligned}
cost(\hat{C}_1, \ldots, \hat{C}_k) &\le \sum_{i=1}^{d} cost_i(\hat{C}_1, \ldots, \hat{C}_k) \\
&\le \sum_{i=1}^{d} \left(\widetilde{cost}_i(\hat{C}_1, \ldots, \hat{C}_k) + O(\delta)\right) \\
&= O(d\delta) + \sum_{i=1}^{d} \left(\widetilde{cost}_i(\hat{C}_1, \ldots, \hat{C}_k) +\right)
\end{aligned}$$

Trên không gian đặc trưng thay thế, thuật toán IMM đảm bảo rằng cây quyết định nó tìm được $(\hat{C})$ không tệ hơn quá $O(k^2)$ lần so với cụm tối ưu (C). Tức là: $\widetilde{\text{cost}}(\hat{C}) \le O(k^2) \cdot \widetilde{\text{cost}}(C)$ nên bất đẳng thức sau sử dụng các đảm bảo của thuật toán IMM tuyến tính áp dụng trên không gian đặc trưng thay thế:

$$\begin{aligned}
cost(\hat{C}_1, \ldots, \hat{C}_k) &\le O(d\delta) + \sum_{i=1}^{d} \left(O(k^2) \cdot \widetilde{cost}_i(C_1, \ldots, C_k)\right) \\
&\le O(d\delta) + \sum_{i=1}^{d} O(k^2) \left(cost_i(C_1, \ldots, C_k) + O(\delta)\right) \\
&= d \cdot O(k^2\delta) + \sum_{i=1}^{d} O(k^2) \cdot cost_i(C_1, \ldots, C_k) \\
&= O(dk^2\delta) + \sum_{i=1}^{d} O(k^2) \cdot cost_i(C_1, \ldots, C_k) \\
&\le O(dk^2) \cdot cost(C_1, \ldots, C_k) + O(dk^2\delta)
\end{aligned}$$

trong đó bất đẳng thức $\le O(d\delta) + \sum_{i=1}^{d} O(k^2) \left(cost_i(C_1, \ldots, C_k) + O(\delta)\right)$ cho thấy việc chuyển đổi chi phí tối ưu trong không gian xấp xỉ $(\widetilde{\text{cost}}_i(C))$ về ngược lại thành chi phí tối ưu thật $(\text{cost}_i(C))$ tốn thêm một lần sai số δ. và bất đẳng thức cuối cùng sử dụng Bổ đề 3 cho các cụm tham chiếu $C_1, \ldots, C_k$: tổng chi phí các chiều $(\sum \text{cost}_i)$ bị chặn bởi d lần chi phí tổng thể $(d \cdot \text{cost})$. Cuối cùng, chia cả hai vế cho $cost(C_1, \ldots, C_k) = \text{cost}_{opt}(X)$, ta thu được kết quả cần chứng minh. □

8.5 Chứng minh Định lý 5

Định lý. (Định lý 5). Xét $C_1, \ldots, C_k$ là các cụm của một tập dữ liệu $X \subset \mathbb{R}^d$ thu được từ kernel k-means, trong đó kernel K là một *distance-based product kernel*. Ký hiệu $\Phi = \phi(X)$ là các đặc trưng thay thế cho K trên X, với $\phi_{i,j}(x) = K_i(x, x^{(j)})$. Khi đó, cây quyết định diễn giải được T thu được từ Kernel IMM trên Φ thỏa mãn $p(T, X) = O(Cdk^2)$, trong đó C phụ thuộc vào tập dữ liệu X và kernel K.

Chứng minh. Để chứng minh Định lý 5, tác giả áp dụng chiến lược chứng minh tổng quát từ IMM và một lần nữa tách biệt các chiều. Một lần nữa, $cost_i$ biểu thị chi phí đối với mỗi kernel một chiều K_i.

$$\begin{aligned} cost(\hat{C}_1, \ldots, \hat{C}_k) &\leq \sum_{i=1}^{d} cost_i(\hat{C}_1, \ldots, \hat{C}_k) \\ &= \sum_{l=1}^{k} \sum_{x \in \hat{C}_l} \|\phi(x) - \mu(x)\|_{\mathcal{V}}^2 \\ &\leq 2 \cdot cost_{\mathcal{V}}(C_1, \ldots, C_k) + 2 \sum_{u \in T} t(u) D(u) \end{aligned} \tag{14}$$

Bổ đề 2. Giả sử $u \in T$ là một nút bất kỳ của cây quyết định IMM T. Ký hiệu X_{cor}^u là tập hợp con các điểm x đến nút u cùng với tâm đúng của chúng $c(x)$.

1. Với mọi $i \in [d]$, ta có
$$t(u) \cdot \max_{a,b \in \mathcal{M}^u} (a_i - b_i)^2 \leq 4k \cdot \sum_{x \in X_{cor}^u} (x_i - c_i(x))^2 \tag{10}$$

2. Điều này trực tiếp suy ra
$$t(u) D(u) \leq 4k \cdot \sum_{x \in X_{cor}^u} \|x - c(x)\|^2 \tag{11}$$

Ở đây, về nguyên tắc chúng ta muốn sử dụng Bổ đề 2. Tuy nhiên, không gian $\mathcal{V}$ mà Kernel IMM chạy trên đó được trang bị tích vô hướng phi Euclid. Do đó, phần thứ hai (11) của Bổ đề 2 không còn suy ra

từ phần thứ nhất (10). Thay vào đó, chúng ta có:

$$\begin{aligned}
t(u)D(u) &:= t(u) \cdot \max_{a,b \in \mathcal{M}^u} \|a-b\|_{\mathcal{V}}^2 \\
&= t(u) \cdot \max_{a,b \in \mathcal{M}^u} \sum_{i=1}^{d} (a_i - b_i)^T \mathbf{K}_i^{-1} (a_i - b_i) \\
&\leq \kappa_1 \cdot t(u) \cdot \max_{a,b \in \mathcal{M}^u} (a-b)^T (a-b) \\
&\leq 4\kappa_1 \cdot k \sum_{x \in X_{cor}^u} (\phi(x) - c(x))^T (\phi(x) - c(x)) \\
&\leq 4\kappa_1\kappa_2 \cdot k \sum_{x \in X_{cor}^u} \|\phi(x) - c(x)\|_{\mathcal{V}}^2
\end{aligned}$$

trong đó chúng ta sử dụng phần đầu của Bổ đề 2 ở bất đẳng thức thứ hai. Các hằng số κ_1, κ_2 được cho bởi:

$$\begin{aligned}
\kappa_1 &= \max_{a,b \in \mathcal{M}^u} \frac{\sum_{i=1}^{d} (a_i - b_i)^T \mathbf{K}_i^{-1} (a_i - b_i)}{\sum_{i=1}^{d} (a_i - b_i)^T (a_i - b_i)} \\
\kappa_2 &= \max_{x \in X} \frac{\sum_{i=1}^{d} (\phi_i(x) - c_i(x))^T (\phi_i(x) - c_i(x))}{\sum_{i=1}^{d} (\phi_i(x) - c_i(x))^T \mathbf{K}_i^{-1} (\phi_i(x) - c_i(x))}
\end{aligned}$$

và phụ thuộc vào dữ liệu. □

8.6 Chứng minh Định lý 6

Định lý. (ExKMC không thừa nhận các giới hạn trong trường hợp xấu nhất). Với bất kỳ số nguyên $m \in \mathbb{N}$, luôn tồn tại một tập dữ liệu $X \subset \mathbb{R}$ sao cho price of explainability trên X là $p(X) = 1$ khi IMM đạt được giá trị tối thiểu này, nhưng thuật toán ExKMC khi được khởi tạo trên một cây rỗng lại xây dựng nên một cây quyết định T với $p(T, X) \geq m$.

Chứng minh. Xét 1 ví dụ phản chứng với tập X có n dữ liệu, gồm $k = 3$ cụm với tâm cụm được chọn là $c_1 = -1$, $c_2 = 0$, $c_3 = 1$. Giả sử mọi điểm trên cụm C_i nằm cách tâm cụm c_i đúng 1 khoảng ϵ rất nhỏ, nửa trong số đó tại vị trí $c_i - \epsilon$ và nửa còn lại tại $c_i + \epsilon$. Ta có chi phí k-means tối ưu là

$$cost_{opt} = \sum_{i \in [k]} \sum_{x \in C_i} \|x - c_i\|^2 = \sum_{i \in [k]} \sum_{x \in C_i} \|c_i \pm \epsilon - c_i\|^2 = n\epsilon^2$$

Thuật toán IMM có thể phân cụm trong ví dụ này 1 cách hoàn hảo mà không bị mắc lỗi nào, do đó $p(X) = 1$. Tại vòng lặp đầu tiên trong thuật toán ExKMC để chia thành k lá, giả sử thuật toán chọn ngưỡng mà không tách rời các điểm trong cùng 1 cụm. Không mất tính tổng quát, chọn $(i, \theta) = (1, 0.5)$,

khi đó nút bên phải sẽ có $c_R = c_3$ và không mất tính tổng quát, nút bên trái có $c_L = c_1$. Khi đó:

- Chi phí của các điểm được gán đúng ở mỗi cụm trong C_1, C_3 là ϵ^2
- Các điểm ở cụm C_2 sẽ có chi phí $\sum_{x \in C_2} \|x - c_1\|^2$, với 1 nửa điểm ở $-\epsilon$ sẽ là $\|-\epsilon-(-1)\|^2 = (1-\epsilon)^2$, và nửa điểm ở ϵ sẽ là $\|\epsilon - (-1)\|^2 = (1+\epsilon)^2$

Như vậy, tổng chi phí cho nhát cắt này là

$$f(i,\theta) = \frac{2n}{3}\epsilon^2 + \sum_{x \in C_2} \|x - c_1\|^2 = \frac{2n}{3}\epsilon^2 + \frac{n}{6}(1-\epsilon)^2 + \frac{n}{6}(1+\epsilon)^2$$

Tuy nhiên, ExKMC có thể tìm thấy nhát cắt tối ưu hơn tại ngưỡng $(i,\theta) = (1,0)$ với $c_L = c_1$, $c_R = c_3$. Chi phí ở $-\epsilon$ sẽ là $\|-\epsilon-(-1)\|^2 = (1-\epsilon)^2$ còn ở ϵ là $\|\epsilon - 1\|^2 = (1-\epsilon)^2$, dẫn đến tổng chi phí là

$$f(i,\theta) = \frac{2n}{3}\epsilon^2 + \frac{n}{3}(1-\epsilon)^2 = \frac{2n}{3}\epsilon^2 + \frac{n}{6}(1-\epsilon)^2 + \frac{n}{6}(1-\epsilon)^2 \leq \frac{2n}{3}\epsilon^2 + \frac{n}{6}(1-\epsilon)^2 + \frac{n}{6}(1+\epsilon)^2$$

Bây giờ ExKMC chỉ có thêm được 1 lá nữa, nên chắc chắn sẽ tồn tại ít nhất $\frac{n}{6}$ điểm không nằm trong cụm chính xác của chúng do thuật toán chỉ tách được thêm ở 1 lá nên sẽ còn ít nhất 1 lá chứa nửa dữ liệu của cụm C_2.
Ta có: $\mu_i = \frac{1}{|\hat{C}_i|}\sum_{x \in \hat{C}_i} x$
thế nên $\sum_{x \in \hat{C}_i} \mu_i = |\hat{C}_i|\frac{1}{|\hat{C}_i|}\sum_{x \in \hat{C}_i} x = \sum_{x \in \hat{C}_i} x$
tương đương $\sum_{x \in \hat{C}_i}(x - \mu_i) = 0$
Ta lại có:

$$\begin{aligned}
cost(\hat{C}_i) &= \sum_{x \in \hat{C}_i} \|x - c_i\|^2 \\
&= \sum_{x \in \hat{C}_i} \|x - \mu_i + \mu_i - c_i\|^2 \\
&= \sum_{x \in \hat{C}_i} \|x - \mu_i\|^2 + \sum_{x \in \hat{C}_i} \|\mu_i - c_i\|^2 + 2\langle \sum_{x \in \hat{C}_i}(x - \mu_i), \mu_i - c_i \rangle \\
&= \sum_{x \in \hat{C}_i} \|x - \mu_i\|^2 + |\hat{C}_i|\|\mu_i - c_i\|^2
\end{aligned}$$

mà

$$\begin{aligned}
\sum_{x_1,x_2\in\hat{C}_i}\|x_1-x_2\|^2 &= \sum_{x_1,x_2\in\hat{C}_i}\|x_1-\mu_i-(x_2-\mu_i)\|^2\\
&= \sum_{x_1,x_2\in\hat{C}_i}\|x_1-\mu_i\|^2+\sum_{x_1,x_2\in\hat{C}_i}\|x_2-\mu_i\|^2-2\langle\sum_{x_1\in\hat{C}_i}(x_1-\mu_i),\sum_{x_2\in\hat{C}_i}(x_2-\mu_i)\rangle\\
&= |\hat{C}_i|\sum_{x_1\in\hat{C}_i}\|x_1-\mu_i\|^2+|\hat{C}_i|\sum_{x_2\in\hat{C}_i}\|x_2-\mu_i\|^2\\
&= |\hat{C}_i|\sum_{x\in\hat{C}_i}\|x-\mu_i\|^2+|\hat{C}_i|\sum_{x\in\hat{C}_i}\|x-\mu_i\|^2\\
&= 2|\hat{C}_i|\sum_{x\in\hat{C}_i}\|x-\mu_i\|^2
\end{aligned}$$

nên

$$cost(\hat{C}_i)=\frac{1}{2|\hat{C}_i|}\sum_{x_1,x_2\in\hat{C}_i}\|x_1-x_2\|^2+|\hat{C}_i|\|\mu_i-c_i\|^2$$

Do đó, sẽ tồn tại 1 lá mà có $\frac{n}{6}$ điểm bị gán sai trong khi $\frac{n}{3}$ đã gán đúng, và sẽ có $\frac{n}{6}\cdot\frac{n}{3}=\frac{n^2}{18}$ cặp điểm có khoảng cách $\geq 1-2\epsilon$ (không mất tính tổng quát, giả sử lá đang xét có dữ liệu cụm C_3 và nửa dữ liệu cụm C_2 tại $\epsilon\to|\epsilon-(1-\epsilon)|=1-2\epsilon$). Và từ đó, ta có chi phí cuối cùng của quyết định T tương ứng với lá $\hat{C}_i$ là lá có dữ liệu bị sai nhãn và không bị tách ở nhát cắt thứ 2 như sau

$$cost(T)\geq\frac{n\epsilon^2}{2}+cost(\hat{C}_i)\geq\frac{n\epsilon^2}{2}+\frac{1}{n}\cdot\frac{2n^2(1-2\epsilon)^2}{18}=\frac{n\epsilon^2}{2}+\frac{n(1-2\epsilon)^2}{9}$$

Price of Explainability của T là

$$p(T,X)=\frac{cost(T)}{cost_{opt}}\geq\frac{n\epsilon^2}{2n\epsilon^2}+\frac{n(1-2\epsilon)^2}{9n\epsilon^2}=\frac{1}{2}+\frac{(1-2\epsilon)^2}{9\epsilon^2}$$

Do đó, khi $\epsilon\to 0$ thì $\lim_{\epsilon\to 0}\frac{(1-2\epsilon)^2}{9\epsilon^2}=+\infty$, tức $p(T,X)\to+\infty$. Như vậy có nghĩa là ExKMC khởi tạo từ cây rỗng rõ ràng tạo ra các cây quyết định mà có hạn chế luôn tồn tại 1 số $m\in\mathbb{N}$ tùy ý sao cho $p(T,X)\geq m$. □

8.7 Chứng minh Định lý 7

Định lý. (Định lý 7). Chi phí diễn giải (Price of Explainability), như được định nghĩa trong Định nghĩa 4, có thể không hữu hạn đối với tất cả các kernel.

Mệnh đề 1. (Chi phí vô hạn cho kernel bậc hai). Xét $K(x,y)=\langle x,y\rangle^2$. Khi đó, tồn tại một tập dữ liệu $X\subset\mathbb{R}^2$ sao cho $p(X)=\infty$.

Chứng minh. Xét $x = (0, 1), y = (0, -1), z = (1, 0), w = (-1, 0) \in \mathbb{R}^2$. Xét kernel bậc hai $K(s, t) = (\langle s, t\rangle)^2$ hoạt động trên $X = \{x, y, z, w\}$.
Khi đó, kernel 2-means đạt được chi phí bằng 0 bằng cách phân hoạch X thành hai cụm $C_1 = \{x, y\}, C_2 = \{z, w\}$, vì $K(s, t) = 1$ cho mọi $s, t \in X$ cùng cụm.
Tuy nhiên, không có cây quyết định diễn giải được nào có thể tái tạo lại phân hoạch này của X:

- Mọi cây quyết định T với hai lá đều gán một cặp điểm (s, t) từ các cụm khác nhau vào cùng một lá.
- Do $K(s, t) = 0$ cho cặp này, $cost(T) > 0$ và do đó $p(X) = \infty$.

□

Điều này có thể không gây ngạc nhiên khi xem xét cấu trúc hình học đặc biệt của kernel bậc hai. Tuy nhiên, kết quả sau đây chứng minh rằng ngay cả các kernel dựa trên khoảng cách cũng có thể dẫn đến các vấn đề tương tự. Đối với điều này, chúng ta xét ϵ-neighborhood kernel:

$$K(x, y) = \mathbf{1}(\|x - y\| \leq \epsilon)$$

Mặc dù K không phải là một kernel xác định dương (ma trận kernel của nó có thể có các giá trị riêng âm), nhưng nó vẫn thường được sử dụng trong phân cụm phổ và phân cụm kernel.
Mệnh đề 2. (Chi phí vô hạn cho ϵ-neighborhood kernel). Cho $\epsilon > 0$ và $K(x, y) = \mathbf{1}(\|x - y\| \leq \epsilon)$. Khi đó, tồn tại một tập dữ liệu X sao cho $p(X) = \infty$.

Chứng minh. Đối với bốn điểm $x^{(1)}, \ldots, x^{(4)}$, có chính xác $d' = 6$ cách để gán giá trị 0 cho hai điểm trong số chúng, và giá trị 1 cho hai điểm còn lại. Tương tự, đối với bốn điểm khác $x^{(5)}, \ldots, x^{(8)}$, có chính xác $d' = 6$ cách để gán giá trị 0 cho hai điểm, và giá trị -1 cho hai điểm còn lại. Có $d = (d')^2 = 36$ tổ hợp có thể có của tất cả các phép gán này.
Chúng ta định nghĩa phân hoạch như sau:

- Cụm C_1: Nối tất cả các tổ hợp cho mỗi điểm $x^{(1)} \ldots x^{(4)}$. Do đó, mỗi $x \in C_1$ là một vector trong $\{0, 1\}^d$.
- Cụm C_2: Nối tất cả các tổ hợp cho mỗi điểm $x^{(5)}, \ldots, x^{(8)}$. Do đó, các vector $y \in C_2$ thuộc $\{0, -1\}^d$.

Tính chất khoảng cách:

- Với bất kỳ $x, x' \in C_1$, chúng khớp nhau ở chính xác $d/3$ chiều nhưng khác nhau 1 ở mọi nơi khác. Do đó $\|x - x'\|^2 = 24$.
- Tương tự cho bất kỳ cặp logic $y, y' \in C_2$.
- Tuy nhiên, với bất kỳ cặp $x \in C_1, y \in C_2$ từ các cụm khác nhau, chúng khớp nhau trên $d/4 = 9$ chiều, khác nhau 1 dọc theo $d/2 = 18$ chiều và cách nhau 2 ở những nơi khác. Do đó, khoảng cách của chúng là $\|x - y\|^2 = 18 + 36 = 54$.

Bằng cách chọn ϵ-neighborhood kernel với $\epsilon = \sqrt{24}$, ta thấy rằng $K(x, x') = K(y, y') = 1$ cho mọi $x, x' \in C_1, y, y' \in C_2$. Điều này ngụ ý chi phí kernel k-means tối ưu bằng 0.
Tuy nhiên, bất kỳ vết cắt ngưỡng nào dọc theo bất kỳ chiều nào trong số d chiều cũng sẽ gán ít nhất một cặp (x, y) từ các cụm khác nhau vào cùng một lá, ngụ ý $K(x, y) = 0$. Do đó, chi phí kernel k-means cho phân hoạch diễn giải được này là dương ngặt. Điều này chứng minh $p(X) = \infty$. □

9 Kết luận

Những nghiên cứu trong bài báo *Explaining Kernel Clustering via Decision Tree* đã đóng góp vào những nhu cầu ngày càng tăng về các phương pháp phân cụm có khả năng giải thích. Tác giả đề xuất thuật toán Kernel IMM cùng các biến thể, Kernel ExKMC và Kernel Expand cho phép có thể giải thích thuật toán kernel k-means thông qua việc sử dụng cây quyết định để có những luật đơn giản. Bằng cách hoạt động trên các đặc trưng được lựa chọn cẩn thận bằng các bản đồ đặc trưng mang tính giải thích, khả năng diễn giải của mô hình được bảo toàn cùng với đó là sự đảm bảo về khả năng xấp xỉ chính xác của thuật toán. Đồng thời, những bản đồ đặc trưng này đóng vai trò quan trọng khi tiến hành phân cụm dựa trên kernel, vì chúng có thể diễn giải cho các phương pháp kernel, vốn phụ thuộc vào phương pháp giải thích sau khi huấn luyện.
Hướng nghiên cứu được đề xuất trong tương lai:

- Các bản đồ đặc trưng mang tính diễn giải rất hữu ích để giải thích cho phương pháp kernel, chính vì thế có thể mở rộng nghiên cứu xây dựng tạo bản đồ đặc trưng cho các bài toán kernel khác để có thể đạt được mô hình có thể hiểu được ngay từ đầu mà không cần áp dụng các thuật toán giải thích khác sau khi huấn luyện.

- Mở rộng nghiên cứu và thực nghiệm các loại Kernel khác ngoài Gaussian và Laplace Kernel cho các thuật toán được đề xuất để có thể biết được liệu có thể mở rộng phương pháp này cho các loại kernel đa thức (polynomial) hay kernel phức tạp hơn hay không, như cách tác giả thực nghiệm thêm với additive χ^2 kernel cho dữ liệu histogram và distribution.

- Rand Index chỉ có thể dùng để đánh giá khi chúng ta biết được nhãn thật của dữ liệu (ground truth), do đó câu hỏi cơ bản được đưa ra là: "Dưới điều kiện nào của dữ liệu thì cây quyết định có thể xấp xỉ tốt với các cụm phi tuyến tính của kernel k-means?", dẫn đến các hướng nghiên cứu các điều kiện của dữ liệu để có thể áp dụng thuật toán cho các bài toán phân cụm với dữ liệu không có ground truth.

- Tiến hành nghiên cứu cho một câu hỏi khác được đặt ra rằng liệu có thể cải thiện được độ chính xác xấp xỉ hay không, khi rất có thể các kernel cụ thể ở đây được hưởng lợi từ các thuật toán được thiết kế riêng cho hàm chi phí của chúng.

- Cuối cùng, việc nghiên cứu các giới hạn dưới (lower bounds), vượt ra ngoài những giới hạn mà kernel tuyến tính kế thừa từ các kết quả hiện có trong các thuật toán explainable k-means cũng là một hướng nghiên cứu thú vị trong tương lai được đề xuất.

10 Lời cảm ơn

Em xin cảm ơn thầy ***Lê Hoài Bắc***, thầy ***Lê Nhựt Nam***, và thầy ***Nguyễn Ngọc Đức*** đã giúp đỡ, và giải đáp thắc mắc của chúng em trong quá trình học cũng như trong quá trình làm đồ án này.

A Phụ lục: Chứng minh công thức đạo hàm bậc cao

Phần này trình bày chứng minh bằng quy nạp toán học để tìm ra công thức tổng quát cho đạo hàm bậc j của hàm $g(u) = e^{2\gamma u}$. Kết quả này đồng thời khẳng định tính không âm của các hệ số Taylor cần thiết.

Mệnh đề. Cho hàm số $g(u) = e^{2\gamma u}$ với $\gamma > 0$. Khi đó, đạo hàm bậc j của hàm số là:

$$g^{(j)}(u) = (2\gamma)^j e^{2\gamma u}, \quad \forall j \in \mathbb{N}.$$

Chứng minh. Ta sử dụng phương pháp quy nạp toán học.
Bước cơ sở ($j = 0$): Đạo hàm bậc 0 chính là hàm số gốc:

$$g^{(0)}(u) = g(u) = e^{2\gamma u} = (2\gamma)^0 e^{2\gamma u}.$$

Mệnh đề đúng với $j = 0$.
Bước quy nạp: Giả sử mệnh đề đúng với $j = k$, tức là:

$$g^{(k)}(u) = (2\gamma)^k e^{2\gamma u}. \tag{15}$$

Ta cần chứng minh mệnh đề đúng với $j = k + 1$. Xét đạo hàm bậc $k + 1$:

$$g^{(k+1)}(u) = \frac{d}{du}\left(g^{(k)}(u)\right).$$

Thay giả thiết (15) vào:

$$\begin{aligned} g^{(k+1)}(u) &= \frac{d}{du}\left((2\gamma)^k e^{2\gamma u}\right) \\ &= (2\gamma)^k \cdot \frac{d}{du}(e^{2\gamma u}) \\ &= (2\gamma)^k \cdot (2\gamma e^{2\gamma u}) \\ &= (2\gamma)^{k+1} e^{2\gamma u}. \end{aligned}$$

Vậy công thức cũng đúng với $j = k + 1$.
Kết luận: Theo nguyên lý quy nạp toán học, $g^{(j)}(u) = (2\gamma)^j e^{2\gamma u}$ với mọi $j \in \mathbb{N}$.
Hệ quả: Tại $u = 0$, ta có $g^{(j)}(0) = (2\gamma)^j$. Vì $\gamma > 0$, suy ra $g^{(j)}(0) > 0$. Điều này xác nhận điều kiện về tính không âm của hệ số trong Gaussian Kernel. □

B Phụ lục: Hàm giải tích và Bất đẳng thức AM-GM

Hàm giải tích

Trong toán học, một **hàm giải tích** (analytic function) là một hàm số mà tại mọi điểm trong miền xác định của nó, hàm số đó có thể được biểu diễn dưới dạng một chuỗi lũy thừa hội tụ (thường là chuỗi Taylor).
Định nghĩa: Một hàm số f được gọi là giải tích thực tại điểm x_0 nếu tồn tại một lân cận của x_0 sao cho với mọi x trong lân cận đó, ta có thể viết:

$$f(x) = \sum_{n=0}^{\infty} a_n(x - x_0)^n = a_0 + a_1(x - x_0) + a_2(x - x_0)^2 + \dots$$

trong đó các hệ số a_n là các số thực và chuỗi này hội tụ về $f(x)$.
Tính chất quan trọng:

- **Khả vi vô hạn:** Nếu một hàm là giải tích, thì nó có đạo hàm mọi cấp (smooth function). Điều này rất quan trọng trong bài báo cáo vì hàm Gaussian $e^{-\gamma x^2}$ là hàm giải tích, do đó ta có thể khai triển Taylor nó tại bất kỳ điểm nào (ví dụ tại 0) để xấp xỉ kernel.
- **Duy nhất:** Nếu hai hàm giải tích trùng nhau trên một tập hợp con nhỏ (có điểm tụ), thì chúng trùng nhau trên toàn bộ miền liên thông xác định của chúng.

Bất đẳng thức AM-GM

Bất đẳng thức trung bình cộng và trung bình nhân (Arithmetic Mean - Geometric Mean inequality), thường gọi tắt là Bất đẳng thức AM-GM, khẳng định rằng trung bình cộng của một danh sách các số thực không âm luôn lớn hơn hoặc bằng trung bình nhân của chúng.
Công thức tổng quát: Với mọi bộ n số thực không âm $x_1, x_2, \dots, x_n \geq 0$, ta luôn có:

$$\frac{x_1 + x_2 + \cdots + x_n}{n} \geq \sqrt[n]{x_1 x_2 \dots x_n}$$

Dấu bằng xảy ra khi và chỉ khi: $x_1 = x_2 = \cdots = x_n$.
Ví dụ minh họa:

- Với $n = 2$: Cho hai số $a, b \geq 0$, ta có $\frac{a+b}{2} \geq \sqrt{ab}$. $\Leftrightarrow a + b \geq 2\sqrt{ab}$.
- Áp dụng trong tối ưu hóa: Bất đẳng thức này thường được dùng để tìm giá trị nhỏ nhất của một biểu thức tổng khi biết tích các thành phần là hằng số, hoặc ngược lại tìm giá trị lớn nhất của tích khi tổng không đổi.

C Phụ lục: Danh sách các bảng ký hiệu

Ký hiệu	**Ý nghĩa**
x_i	Đặc trưng thứ i của điểm dữ liệu
$x^{(i)}$	Điểm dữ liệu thứ i (mẫu thứ i)

Bảng 7: Các ký hiệu sử dụng chung

Bảng kí hiệu cho Định nghĩa 1

Ký hiệu	**Ý nghĩa**
ϕ	Bản đồ đặc trưng (Feature map) - Ánh xạ: $\phi : \mathbb{R}^d \to \mathbb{R}^D$
X	Tập dữ liệu (Dataset)
$\mathbb{R}^D$	Không gian đặc trưng D chiều
$K(x, y)$	Hàm kernel
$\langle \cdot, \cdot \rangle$	Tích vô hướng
$\phi_j(x)$	Thành phần thứ j của bản đồ đặc trưng

Bảng 8: Các ký hiệu sử dụng trong Định nghĩa 1

Bảng kí hiệu cho Định nghĩa 2

Ký hiệu	**Ý nghĩa**
T	Cây quyết định đang xây dựng
$X \subset \mathbb{R}^d$	Tập dữ liệu đầu vào
$\mathbb{R}^d$	Không gian số thực d chiều
d	Số lượng đặc trưng
k	Số lượng lá (leaves) hay số lượng nhóm (clusters) mong muốn
$u \in T$	Một nút (node) bất kỳ nằm trên cây T
X_u	Tập hợp con các điểm dữ liệu đi đến nút u
$i \in [d]$	Chỉ số của đặc trưng được chọn để cắt (với $[d] = \{1, 2, \ldots, d\}$)
$\theta_1 < \theta_2 \in \mathbb{R}$	Ngưỡng dưới và Ngưỡng trên
X_L^u, X_R^u	Hai tập con dữ liệu sau khi chia tách tại nút u (Nhánh Trái và Nhánh Phải)

Bảng 9: Các ký hiệu sử dụng trong Định nghĩa 2

Bảng kí hiệu cho phần Đặc trưng thay thế (Surrogate Features)

Ký hiệu	Ý nghĩa
$\mathcal{H}$	Không gian Hilbert sinh bởi kernel (RKHS) tổng quát
$\mathcal{H}_i$	Không gian RKHS thành phần tương ứng với chiều thứ i
$\psi(x)$	Bản đồ đặc trưng ngầm định (Infinite-dimensional feature map)
$\psi_i(x_i)$	Bản đồ đặc trưng ngầm định thành phần trên chiều i
$\phi(x)$	Bản đồ đặc trưng thay thế (Finite-dimensional surrogate feature map)
$\mathcal{M}$	Tập hợp các tâm cụm (cluster centers) trong không gian đặc trưng thay thế

Bảng 10: Các ký hiệu sử dụng trong phần Surrogate Features

Bảng kí hiệu cho phần Kernel Taylor có thể diễn giải

Ký hiệu	Ý nghĩa
$K_i(z, z')$	Kernel thành phần trên chiều thứ i
$f(z)$	Hàm con thứ nhất trong phân tách kernel ($e^{-\gamma z^2}$ đối với Gaussian)
$g(u)$	Hàm giải tích trong phân tách kernel ($e^{2\gamma u}$ đối với Gaussian)
$g^{(j)}$	Đạo hàm bậc j của hàm g
γ	Tham số bandwidth của Gaussian kernel
M	Bậc cắt cụt của chuỗi Taylor (số lượng thành phần xấp xỉ)
$\phi_{i,j}(z)$	Thành phần thứ j của vector đặc trưng thay thế cho chiều i
$\Phi(x)$	Bản đồ đặc trưng tổng quát ghép từ các ϕ_i
$K_{Surrogate}$	Kernel xấp xỉ trong không gian đặc trưng thay thế

Bảng 11: Các ký hiệu sử dụng trong phần Interpretable Taylor Kernels

Bảng kí hiệu cho Phần Phân tích Lý thuyết và Kernel Tích dựa trên khoảng cách

Ký hiệu	Ý nghĩa
M	Bậc của khai triển Taylor (hoặc bản đồ đặc trưng thay thế)
$\delta(M)$	Giới hạn sai số xấp xỉ phụ thuộc vào M
d'	Số chiều đặc trưng sau khi xấp xỉ ($d' \approx d \cdot M$)
$h(t)$	Hàm cơ sở của kernel (ví dụ e^{-t^2} hoặc $e^{-\lvert t\rvert}$)
$x^{(j)}$	Các điểm mốc (landmarks) được chọn từ tập dữ liệu
$p(T, X)$	Chi phí của cây quyết định T trên tập X
$\text{cost}_{opt}(X)$	Chi phí phân cụm tối ưu trên X (bởi Kernel K-Means)

Bảng 12: Các ký hiệu sử dụng trong phân tích lý thuyết và Distance-based Kernels

Bảng kí hiệu cho phần Hàm mục tiêu của Kernel ExKMC và Kernel Expand

Ký hiệu	**Ý nghĩa**
(i, θ)	Ngưỡng cắt với tọa độ chiều i và giá trị ngưỡng θ
$cost_{exkmc}(u, i, \theta)$	Hàm mục tiêu (cost) của thuật toán Kernel ExKMC tại nút u với ngưỡng cắt (i, θ)
$cost_{exp}(u, i, \theta)$	Hàm mục tiêu (cost) của thuật toán Kernel Expand tại nút u với ngưỡng cắt (i, θ)
$\hat{C}_1, ..., \hat{C}_p$	Các nút lá (cụm) của cây quyết định đang triển khai

Bảng 13: Các ký hiệu sử dụng trong phần Hàm mục tiêu của Kernel ExKMC và Kernel Expand

Bảng kí hiệu cho Chứng minh Định lý 1

Ký hiệu	**Ý nghĩa**
γ	Tham số của Gaussian kernel
$\|\cdot\|_2$	Chuẩn Euclidean (L_2 norm)
$[D]$	Tập hợp các chỉ số $\{1, \ldots, D\}$
$x^{(i)}$	Điểm dữ liệu mẫu thứ i
$K_{i,j}$	Phần tử của ma trận kernel, $K_{i,j} = K(x^{(i)}, x^{(j)})$

Bảng 14: Các ký hiệu sử dụng trong Định lý 1

Bảng kí hiệu cho Chứng minh Định lý 2

Ký hiệu	**Ý nghĩa**
ϵ_i, δ_i	Các vector không âm (trong chứng minh phản chứng)
v_i, w_i	Các thành phần vector của $\phi(x^{(i)})$ (trong chứng minh)
Φ	Ma trận các vector đặc trưng

Bảng 15: Các ký hiệu sử dụng trong Định lý 2

Bảng kí hiệu cho Chứng minh Định lý 3

Ký hiệu	**Ý nghĩa**
$f(x_i)$	Hàm con thứ nhất trong phân tách kernel Taylor
$g^{(j)}(0)$	Đạo hàm bậc j của hàm con thứ hai tại 0
$\phi'_{i,j}(x)$	Đạo hàm của đặc trưng thay thế theo biến x
θ	Ngưỡng cắt (threshold) tại một nút lá
$\gtrless$	Ký hiệu so sánh (lớn hơn hoặc nhỏ hơn) trong điều kiện cắt
$\propto$	Tỷ lệ thuận

Bảng 16: Các ký hiệu sử dụng trong Định lý 3 (Tính diễn giải của các vết cắt)

Bảng kí hiệu cho Chứng minh Định lý 4

Ký hiệu	**Ý nghĩa**
M	Bậc cắt cụt của chuỗi Taylor
δ	Sai số xấp xỉ kernel ($\lvert K - \hat{K}\rvert \leq \delta$)
$\hat{C}_l$	Các cụm tìm được bởi thuật toán xấp xỉ (IMM trên Φ)
C_l	Các cụm tối ưu tham chiếu (IMM trên K gốc)
$cost_i$	Chi phí phân cụm tính trên kernel gốc một chiều K_i
$\widetilde{cost}_i$	Chi phí phân cụm tính trên kernel xấp xỉ $\langle \phi_i, \phi_i \rangle$
$\lVert g^{(j)} \rVert_\infty$	Chuẩn vô cùng (giá trị lớn nhất) của đạo hàm bậc j

Bảng 17: Các ký hiệu sử dụng trong Định lý 4 (Sai số xấp xỉ)

Bảng kí hiệu cho Chứng minh Định lý 5

Ký hiệu	**Ý nghĩa**
$\mathcal{V}$	Không gian vector thực nghiệm (có thể phi Euclid)
$\lVert \cdot \rVert_{\mathcal{V}}$	Chuẩn trong không gian đặc trưng $\mathcal{V}$
C	Hằng số phụ thuộc vào dữ liệu và kernel (đại diện cho độ biến dạng)
$t(u)$	Số lượng điểm dữ liệu đi đến nút u
$D(u)$	Đường kính (diameter) của cụm dữ liệu tại nút u
$c(x)$	Tâm đúng (correct center) của điểm x trong phân cụm tối ưu
X^u_{cor}	Tập hợp con các điểm tại nút u cùng với tâm tương ứng

Bảng 18: Các ký hiệu sử dụng trong Định lý 5 (Distance-based Product Kernels)

Bảng kí hiệu cho Chứng minh Định lý 6

Ký hiệu	**Ý nghĩa**
ϵ	Khoảng cách của điểm dữ liệu so với tâm cụm của chúng, thường rất nhỏ
$f(i, \theta)$	Hàm chi phí trong 1 ngưỡng cắt cụ thể (i, θ)
μ_i	Tâm cụm trung bình của nút lá $\hat{C}_i$

Bảng 19: Các ký hiệu sử dụng trong Định lý 6 (ExKMC trong trường hợp xấu nhất)

Tài liệu

[1] S. Dasgupta, M. Moshkovitz, N. Frost **and** C. Rashtchian, "Explainable k-means and k-medians clustering," *International conference on machine learning*, 2020. DOI: 10.48550/arXiv.2002.12538.

[2] N. Frost, M. Moshkovitz **and** C. Rashtchian, "ExKMC: Expanding Explainable k-Means Clustering," *arXiv preprint arXiv:2006.02399*, 2020. **url**: https://arxiv.org/pdf/2006.02399.

[3] W.-Y. Loh, "Classification and regression trees," *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, 2011. DOI: 10.1002/widm.8.

[4] P. Franti **and** S. Sieranoja, "K-means properties on six clustering benchmark datasets," *Applied Intelligence*, 2018. DOI: 10.1007/s10489-018-1238-7.

[5] R. A. Fisher, "The use of multiple measurements in taxonomic problems," *Annals of Eugenics*, 1936. DOI: 10.1111/j.1469-1809.1936.tb02137.x.

[6] W. N. Street, W. H. Wolberg **and** O. L. Mangasarian, "Nuclear feature extraction for breast tumor diagnosis," *Biomedical image processing and biomedical visualization*, 1993. DOI: 10.1117/12.148698.

[7] W. M. Rand, "Objective criteria for the evaluation of clustering methods," *Journal of the American Statistical Association*, 1971. DOI: 10.2307/2284239.

[8] L. Hubert **and** P. Arabie, "Comparing partitions," *Journal of classification*, 1985.

[9] W. contributors, "Analytic function," *Wikipedia*, 2025. **url**: https://en.wikipedia.org/wiki/Analytic_function.

[10] W. contributors, "AM–GM inequality," *Wikipedia*, 2025. **url**: https://en.wikipedia.org/wiki/AM%E2%80%93GM_inequality.

[11] maxf14, *explaining_kernel_clustering*, 2025. **url**: https://github.com/maxf14/explaining_kernel_clustering/tree/main.